



UNIVERSIDADE ESTADUAL PAULISTA
Faculdade de Engenharia
Campus de Bauru



Jeferson André Bigheti

NAVEGAÇÃO DE ROBÔS EM AMBIENTES INTERNOS USANDO SLAM

**BAURU
2011**

Jeferson André Bigheti

**NAVEGAÇÃO DE ROBÔS EM AMBIENTES
INTERNOS USANDO SLAM**

Dissertação apresentada à Faculdade de
Engenharia da UNESP - Campus de Bauru,
como parte dos requisitos para obtenção do
título de Mestre em Engenharia Elétrica.

Orientador: Prof. Dr. Marcelo Nicoletti Franchin

**BAURU
2011**

Bigheti, Jeferson André.

Navegação de robôs em ambientes internos usando
SLAM / Jeferson André Bigheti, 2011

114 f.

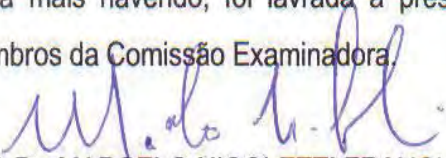
Orientador: Prof. Dr. Marcelo Nicoletti Franchin

Dissertação (Mestrado)-Universidade Estadual
Paulista. Faculdade de Engenharia, Bauru, 2011

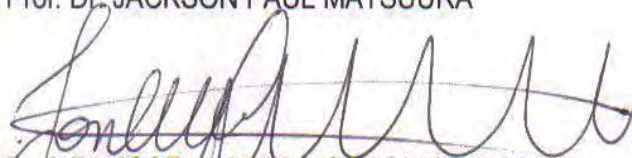
1. Robótica Móvel. 2. SLAM. 3. Localização e
mapeamento simultâneo. 4. Filtro de Kalman Estendido.
I. Universidade Estadual Paulista. Faculdade de
Engenharia. II. Título.

ATA DA DEFESA PÚBLICA DA DISSERTAÇÃO DE MESTRADO DE JÉFERSON ANDRÉ BIGHETI, DISCENTE DO PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA, DO(A) FACULDADE DE ENGENHARIA DE BAURU.

Aos 18 dias do mês de agosto do ano de 2011, às 09:00 horas, no(a) ANFITEATRO DA SEÇÃO DE PÓS-GRADUAÇÃO DA FACULDADE DE ENGENHARIA, reuniu-se a Comissão Examinadora da Defesa Pública, composta pelos seguintes membros: Prof. Dr. MARCELO NICOLETTI FRANCHIN do(a) Departamento de Engenharia Elétrica / Faculdade de Engenharia de Bauru - UNESP, Prof. Dr. JACKSON PAUL MATSUURA do(a) Departamento de Engenharia Eletrônica / Instituto Tecnológico de Aeronáutica - ITA, Prof. Dr. JOSE ALFREDO COVOLAN ULSON do(a) Departamento de Engenharia Elétrica / Faculdade de Engenharia de Bauru - UNESP, sob a presidência do primeiro, a fim de proceder a arguição pública da DISSERTAÇÃO DE MESTRADO de JÉFERSON ANDRÉ BIGHETI, intitulado "ESTUDO E IMPLEMENTAÇÃO DE NAVEGAÇÃO DE ROBÔS MÓVEIS USANDO SLAM EM AMBIENTES INTERNOS". Após a exposição, o discente foi argüido oralmente pelos membros da Comissão Examinadora, tendo recebido o conceito final: APROVADO. Nada mais havendo, foi lavrada a presente ata, que, após lida e aprovada, foi assinada pelos membros da Comissão Examinadora.


Prof. Dr. MARCELO NICOLETTI FRANCHIN


Prof. Dr. JACKSON PAUL MATSUURA


Prof. Dr. JOSE ALFREDO COVOLAN ULSON

*À minha adorada esposa Gláucia, companheira e grande
incentivadora, presença indispensável em minha vida e à minha
filha, Helena e ao meu filho Matheus (luzes da minha vida).*

Agradecimentos

À minha família, em especial à minha esposa Gláucia, que sempre me apoiou e estimulou em todos os momentos.

Gostaria de registrar aqui meus profundos agradecimentos ao meu orientador, Prof. Dr. Marcelo Nicoletti Franchin pela inspiração, amizade e constante disponibilidade que proporcionou durante todo o programa de mestrado. É um professor que foi além das obrigações profissionais do magistério, revelando-se uma pessoa iluminada pelo idealismo da excelência na profissão que abraçou. Seus profundos e comprovados conhecimentos técnicos são coroados por sua elevada qualidade moral.

Agradeço aos meus pais que sempre me proporcionaram todos os recursos necessários para que eu trilhasse meu caminho acadêmico com segurança.

Ao Professor Dr. Doutor Paulo R. de Aguiar pelo incentivo e apoio.

Ao Professor Mario Eduardo Cazão pelo incentivo e apoio.

Ao SENAI pela colaboração e apoio.

A aos meus amigos e Professores do SENAI, pelas discussões e idéias.

As Três Leis da Robótica, segundo Isaac Asimov

- *Primeira Lei: um robô não pode ferir um ser humano, ou, por omissão, permitir que um ser humano sofra algum mal.*

- *Segunda Lei: um robô deve obedecer às ordens que lhe sejam dadas por seres humanos, exceto nos casos em que tais ordens contrariem a Primeira Lei.*

- *Terceira Lei: um robô deve proteger sua própria existência enquanto tal proteção não entrar em conflito com a Primeira ou Segunda Lei.*

Ref.: Isaac Asimov, "Eu, robô", Editora Expressão e Cultura, 8a. edição, pág 61, 1974.

SUMÁRIO

SUMÁRIO.....	I
LISTA DE FIGURAS	III
LISTA DE TABELAS	VI
LISTA DE SÍMBOLOS	VII
RESUMO	IX
ABSTRACT	X
1. INTRODUÇÃO.....	1
1.1 INTRODUÇÃO À ROBÓTICA MÓVEL	1
1.2 DEFINIÇÃO DO PROBLEMA	2
1.3 CONTRIBUIÇÕES	3
1.4 ORGANIZAÇÃO DO TEXTO	4
1.5 TRABALHOS PUBLICADOS EM EVENTOS CIENTÍFICOS	4
2. FUNDAMENTAÇÃO TEÓRICA DO PROBLEMA DE SLAM	5
2.1 MAPEAMENTO	5
2.1.1 Mapas topológicos	6
2.1.2 Mapas métricos	7
2.1.3 <i>Landmarks</i>	9
2.1.4 <i>Landmark</i> artificial	9
2.1.5 <i>Landmark</i> natural	10
2.1.6 Detecção dos landmarks	11
2.1.7 Tipos de ambientes para criação dos mapas	12
2.2 LOCALIZAÇÃO	15
2.3 SLAM - LOCALIZAÇÃO E MAPEAMENTO SIMULTÂNEO	18
2.3.1 A origem do SLAM	19
2.3.2 Trabalhos relevantes do problema de SLAM	19
2.3.3 O problema de SLAM	21
2.3.4 Considerações sobre o problema de SLAM	21
2.4 PRINCIPAIS ALGORITMOS RELACIONADOS AO SLAM	25
2.4.1 Filtro de Bayes	26
2.4.2 Filtro de Kalman	26
2.4.3 Filtro de Kalman Estendido	28
2.4.4 FastSLAM	28
2.4.5 Extended Information Form SLAM	29
2.4.6 Sparse Extended Information Form SLAM	29
2.4.7 Filtro de Partícula	30
2.5 Considerações finais	30
3. EKF- SLAM	31
3.1 ALGORITMOS DE SLAM	31
3.2 O PROBLEMA DE LOCALIZAÇÃO	32
3.3 O PROBLEMA DE MAPEAMENTO	34
3.4 O PROBLEMA DE LOCALIZAÇÃO E MAPEAMENTO SIMULTÂNEOS (SLAM)	35
3.5 FUNDAMENTOS DO SLAM	37
3.5.1 Modelo de processo	38
3.5.2 Modelo de observação	39
3.6 FILTRO DE KALMAN	40
3.6.1 Predição	41
3.6.2 Observação	41

3.6.3	Atualização	42
3.7	FILTRO DE KALMAN DISCRETO	42
3.7.1	Modelo do Processo	42
3.7.2	Modelo de Observação	43
3.8	FILTRO DE KALMAN ESTENDIDO	44
3.8.1	Parâmetros de Ruídos	44
3.8.2	Limitações do Filtro de Kalman Estendido	48
3.9	CONSIDERAÇÕES FINAIS	48
4.	MATERIAIS E MÉTODOS	49
4.1	MAPA DO AMBIENTE E O ESTUDO DE CASO PROPOSTO	49
4.2	MODELO DO ROBÔ UTILIZADO NA SIMULAÇÃO E NOS TESTES EM AMBIENTES REAIS	51
4.3	AS EQUAÇÕES DA CINEMÁTICA DO ROBÔ	53
4.4	MODELO DO SISTEMA DO RÔBO	54
4.4.1	As equações da cinemática do robô	54
4.4.2	<i>Landmark</i>	55
4.4.3	Modelo do processo	56
4.4.4	Modelo de observação	57
4.5	PROCESSO DE ESTIMAÇÃO DO FILTRO DE KALMAN EXTENDIDO (EKF) 58	58
4.5.1	Predição	58
4.5.2	Observação	59
4.5.3	Atualização de medição	60
4.6	SENSOR DE ULTRA-SOM	61
4.6.1	Funcionamento	61
4.6.2	Erros típicos do sensor	65
4.7	Modelo de predição para leituras do sonar	65
4.7.1	Modelamento dos alvos	65
4.7.2	Algoritmo para selecionar os objetos do ambiente	70
1.1	Para todos os planos	70
4.8	SIMULADOR EKF-SLAM	71
4.9	SISTEMA DETECÇÃO POR MEIO DE SENSOR DE ULTRA-SOM PARA MEDIR A DISTÂNCIA ENTRE O ROBÔ E OS OBJETOS	72
4.9.1	Sistema de detecção desenvolvido	73
4.10	CONSIDERAÇÕES FINAIS	73
5.	RESULTADOS EXPERIMENTAIS	74
5.1	SIMULAÇÃO DO ROBÔ NO CHÃO DE FÁBRICA	74
5.2	SIMULAÇÃO DO ESTUDO DE CASO	77
5.2.1	Resultados da simulação	78
5.3	EXPERIMENTOS PRÁTICOS	80
5.3.1	Avaliação Experimental da coleta de dados referente a medidas de distância para construção do mapa do ambiente	80
5.3.2	Resultados dos experimentos práticos do sensor de ultra-som	83
5.3.3	As medidas coletadas do ambiente	85
5.3.4	Avaliação Experimental do Robô	101
5.3.5	Resultados dos experimentos práticos	103
5.4	CONSIDERAÇÕES FINAIS	104
6.	CONCLUSÕES	105
6.1	As sugestões de trabalhos futuros incluem:	106
7.	REFERÊNCIAS	108

LISTA DE FIGURAS

Figura 2. 1. (a) Representação de um ambiente não mapeado, (b) representação de um mapa topológico.	7
Figura 2. 2. (a) Representação de um ambiente não mapeado, (b) representação de um mapa métrico.	8
Figura 2. 3. Sensor de um sonar, células claras denotam regiões livres e células escuras, áreas ocupadas.	8
Figura 2. 4. <i>Landmark</i> artificial fixado na parede do ambiente de trabalho do Robô para detecção pelo sensor de imagem.....	10
Figura 2. 5. Landmarks naturais detectados com sensor de imagem.	11
Figura 2. 6. Ambiente interno estruturado e estático.....	13
Figura 2. 7. Ambiente interno desestruturado e estático.	13
Figura 2. 8. Ambiente externo estruturado, estático.....	14
Figura 2. 9. Ambiente externo desestruturado, dinâmico.....	14
Figura 2. 10. Representação do funcionamento do algoritmo de localização por Markov.	18
Figura 2. 11. (a) O problema da Associação quando o robô não finaliza o mapeamento num ambiente onde sua navegação é fechada, em que o ponto inicial de mapeamento deveria ser o mesmo que o ponto final. (b) Mapa do ambiente de navegação do robô.	23
Figura 2. 12. Erro acumulativo de localização de um robô decorrente de pequenos erros de odometria causados pelo escorregamento das rodas.	25
Figura 3. 1. Diagrama do problema de localização.	33
Figura 3. 2. Diagrama do problema de mapeamento.....	34
Figura 3. 3. Diagrama do problema de localização e mapeamento simultâneo.	36
Figura 3. 4. Um veículo com um modelo cinemático conhecido é equipado com um sensor com a possibilidade de tomar medidas da posição relativa entre algum <i>landmark</i> , move-se através de um ambiente contendo uma população de <i>landmarks</i>	38
Figura 3. 5. Seqüência em bloco do funcionamento do fluxo dos dados no Filtro de Kalman Estendido.	47
Figura 4. 1. Visão geral do mapa do ambiente de navegação do robô.	50
Figura 4. 2. Trajetória do ambiente estudado na simulação.	51
Figura 4. 3. Foto do Robô móvel usado nos ensaios e teste deste trabalho.....	52
Figura 4. 4. Robô móvel usado neste trabalho na forma de diagrama de blocos.	52
Figura 4. 5. Desenho em CAD do Robô móvel usado neste trabalho.	53
Figura 4. 6. Representação do sistema de coordenadas do veículo.	55
Figura 4. 7. A observação simultânea de dois landmarks por um robô móvel com representação do sistema de coordenadas.....	56
Figura 4. 8. Foto do Robô móvel usado nos ensaios com o sensor de ultra-som.	62
Figura 4. 9. Foto do sensor de ultra-som (EZ-1) usado neste trabalho.	62
Figura 4. 10. Padrão de propagação do sinal do sensor de ultra-som.....	63
Figura 4. 11. Diagrama de bloco de um sensor de ultra-som.	64
Figura 4. 12. Alvo Plano.....	66
Figura 4. 13. Alvo canto.	67
Figura 4. 14. Alvo Quina.....	68
Figura 4. 15. Alvo cilindro	69

Figura 4. 16. Representação do sistema de navegação do robô, simulado no EKF-SLAM ...	71
Figura 4. 17. Tela de controle do aplicativo feito Labview para aquisição de distância do sensor de ultra - som para detecção dos objetos.	72
Figura 4. 18. Tela do painel frontal do aplicativo de aquisição de distância do sensor de ultra-som para detecção dos objetos.....	73
Figura 5. 1. Foto do ambiente industrial com tornos comuns e tornos com CNC onde são fabricadas as peças mecânicas que serviu como modelo para a simulação.....	75
Figura 5. 2. Foto do robô construído que serviu como modelo para a simulação e coleta de dados experimentais.....	75
Figura 5. 3. Representação do ambiente industrial com a localização dos tornos comuns e tornos com CNC que serviu como modelo para simulação.....	76
Figura 5. 4. Representação do ambiente industrial com a localização dos tornos comuns e tornos com CNC que serviu como modelo para simulação do caminho de navegação do robô.	76
Figura 5. 5. Trajetoria de navegação do robô que foi simulado no EKF-SIM.	77
Figura 5. 6. Erro de posição em relação ao desejado durante a trajetória (máx ~30 cm).....	79
Figura 5. 7. Variância do ângulo de posicionamento teta de orientação do robô.....	79
Figura 5. 8. Variação da matriz de covariâncias. A curva que vai até 0,75 é a variância da variável de estado do robô x; A curva com dois pequenos picos nos pontos B e B2 representa a variância da variável de estado do robô y; a curva rasteira no gráfico é a curva apresentada na Figura 5.6.....	80
Figura 5. 9. Corredor de onde os dados foram obtidos a partir da leitura do sensor de ultra-som (sonar) colocado na frente do Robô, a cada 50 cm com 180 medidas do sensor de ultra-som em uma varredura de 180 graus relativo a parte frontal do robô, para construção do mapa do ambiente.	81
Figura 5. 10. . Leitura do sensor de ultra-som (sonar) colocado na frente do Robô, em uma varredura de 180 graus relativo a parte frontal do robô é demonstrado no diagrama polar o formato do ambiente a partir dos dados obtidos.....	82
Figura 5. 11. Aplicativo desenvolvido para aquisição das medidas de distância obtidas através do sensor de ultra-som.	83
Figura 5. 12. Diagrama polar sobreposto com o caminho de navegação do robô onde é observada a imprecisão de medição do sensor de ultra-som.	84
Figura 5. 13. Diagrama polar sobreposto com o caminho de navegação do robô onde é observado uma maior imprecisão nas medições do sensor de ultra-som, a maioria das medições realizadas não representam o ambiente do local onde robô está....	84
Figura 5. 14. Diagrama polar da medida 01.	86
Figura 5. 15. Diagrama polar da medida 02.	87
Figura 5. 16. Diagrama polar da medida 03.	88
Figura 5. 17. Diagrama polar da medida 04.	89
Figura 5. 18. Diagrama polar da medida 05.	90
Figura 5. 19. Diagrama polar da medida 06.	91
Figura 5. 20. Diagrama polar da medida 07.	92
Figura 5. 21. Diagrama polar da medida 08.	93
Figura 5. 22. Diagrama polar da medida 09.	94
Figura 5. 23. Diagrama polar da medida 10.	95
Figura 5. 24. Diagrama polar da medida 11.	96
Figura 5. 25. Diagrama polar da medida 12.	97
Figura 5. 26. Diagrama polar da medida 13.	98
Figura 5. 27. Diagrama polar da medida 14.	99

Figura 5. 28. Diagrama polar da medida 15.	100
Figura 5. 29. Diagrama polar da medida 16.	101
Figura 5. 30. Teste para avaliar quantitativamente os erros sistemáticos e não sistemáticos referentes a odômetria obtida do deslocamento do robô móvel construído.	102

LISTA DE TABELAS

Tabela 5. 1. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 01.....	82
Tabela 5. 2. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 01.....	85
Tabela 5. 3. Tabela com os ângulos e medidas de distância obtida pelo sensor de ultra-som (sonar) da medida 02.	86
Tabela 5. 4. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 03.....	87
Tabela 5. 5. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 04.....	88
Tabela 5. 6. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 05.....	89
Tabela 5. 7. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 06.....	90
Tabela 5. 8. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 07.....	91
Tabela 5. 9. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 08.....	92
Tabela 5. 10. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 09.....	93
Tabela 5. 11. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 10.....	94
Tabela 5. 12. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 11.....	95
Tabela 5. 13. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 12.....	96
Tabela 5. 14. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 13.....	97
Tabela 5. 15. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 14.....	98
Tabela 5. 16. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som (sonar) da medida 15.	99
Tabela 5. 17. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 16.....	100
Tabela 5. 18. Resultado do teste 01 UMBmark de navegação do robô por odômetria.	103
Tabela 5. 19. Resultado do teste 02 UMBmark de navegação do robô por odômetria.	103

LISTA DE SÍMBOLOS

A	Matriz jacobiana das derivadas parciais de f , em função de \mathbf{x}_v ;
D	Distância do deslocamento do robô gerado pelo <i>encoder</i>
F_v	Matriz de transição de estado
H_i	Matriz do modelo de observação de \mathbf{p}_i
H_{pi}	Partição dos <i>landmarks</i> de H_i
H_v	Partição do veículo de H_i
J_h	Matriz jacobiana das derivadas parciais de h , em função de $\tilde{\mathbf{x}}_v$;
K	Ganho de kalman da observação dos <i>landmarks</i>
\mathbf{p}_i	Vetor de Estado i^{th} <i>landmark</i>
P_v	Covariâncias de $\hat{\mathbf{x}}_v$
P_v^-	Estado predito P_v
Q_v	Covariâncias de \mathbf{v}_v
r_i	Distância entre o sensor e o <i>landmark</i>
R_i	Covariâncias de \mathbf{w}_v
S_i	Covariâncias de v_i
\mathbf{u}_v	Vetor de entradas de controle
U_v	Histórico das entradas de controle $\{\mathbf{u}_v(1), \mathbf{u}_v(2), \mathbf{u}_v(3), \dots, \mathbf{u}_v(k)\}$
v_i	Inovação das observações de \mathbf{p}_i
\mathbf{v}_v	Vetor de erro de ruído do processo
V	Matriz jacobiana das derivadas parciais de h , em função de \mathbf{v}_v .
\mathbf{w}_i	Vetor de erro de ruído de observação
W	Matriz jacobiana das derivadas parciais de f , em função de \mathbf{w}_i ;
x	Coordenada x do veículo
x_i	Coordenada x do landmark
x_r	Coordenada x do sensor do veículo
\mathbf{x}_v	Vetor de Estado do veículo

$\hat{\mathbf{x}}_v$	Estimativa de \mathbf{x}_v
$\hat{\mathbf{x}}_v$	Estimativa de \mathbf{x}_v
\mathbf{x}	Vetor expandido de estado contendo tanto o estado do veículo, como o estado de todos os <i>landmarks</i>
$\tilde{\mathbf{x}}$	Vetor de Erro de $\hat{\mathbf{x}}_v$
$\hat{\mathbf{x}}_v^-$	Estado predito $\hat{\mathbf{x}}_v$
X_v	Histórico dos estados do veiculo $\{\mathbf{x}_v(1), \mathbf{x}_v(2), \mathbf{x}_v(3), \dots, \mathbf{x}_v(k)\}$
y	Coordenada y do veiculo
y_r	Coordenada y do sensor do veiculo
y_i	Coordenada y do <i>landmark</i>
\tilde{y}	Inovação do estado de observação
\mathbf{z}_i	Vetor de observação para o i-ésimo <i>landmark</i>
$\hat{\mathbf{z}}_i$	Estimativa de \mathbf{z}_i
θ	Orientação do veiculo
θ_i	Orientação de \mathbf{r}_i

BIGHETI, J. A. Navegação de robôs em ambientes internos usando SLAM. Bauru, 2011, 128p. Dissertação (Mestrado) – Faculdade de Engenharia, Campus de Bauru, Universidade Estadual Paulista “Júlio de Mesquita Filho”.

RESUMO

A proposta deste trabalho é dotar um robô móvel com a capacidade de mapear e se localizar no ambiente simultaneamente onde tal problema é conhecido na literatura clássica como SLAM (*Simultaneous Localization and Mapping*). Para operar, o robô deve ser capaz de manter uma estimativa da sua posição com base nos sensores embarcados no veículo, adquirir e utilizar conhecimento sobre o mundo ao seu redor, possuir a habilidade de reconhecer obstáculos, e responder em tempo real as situações que possam ocorrer neste ambiente. Este trabalho propõe também a utilização de um sensor de ultra-som com varredura frontal de 180 graus, para detecção de *landmarks* (marcos) naturais em um ambiente interno para construção do mapa na memória do sistema de controle do robô. As informações do deslocamento do robô são fornecidas pelo sistema de odometria com *encoder*. Essas informações de deslocamento do robô e distância dos *landmarks* são combinadas através da aplicação do Filtro de Kalman Estendido (EKF), para o cálculo de posição e orientação estimados do robô bem como a posição estimada dos *landmarks* (mapa). Trata-se de um trabalho com resultados preliminares, que tem como contribuição específica realizar a tarefa de localização e mapeamento simultaneamente (SLAM) usando um sensor de ultra-som rotativo. São apresentados também os resultados de simulação da técnica de localização e mapeamento simultâneos usando o Filtro de Kalman Estendido (EKF) e complementadas com avaliações experimentais em ambiente reais, aplicado a um robô móvel trabalhando como um transportador de materiais automatizado no chão de fábrica. Discussões são apresentadas sobre os sensores usados, a complexidade computacional, a associação de dados e a modelagem e controle do robô móvel.

Palavras-chave: Robótica Móvel, SLAM, Localização e Mapeamento Simultâneos, Filtro de Kalman Estendido .

ABSTRACT

The purpose of this paper is to provide a mobile robot with the ability to simultaneously map and locate the environment. This problem is known in classical literature as SLAM (Simultaneous Localization and Mapping). To operate, the robot must be able to maintain an estimation of its position based on sensors attached to the vehicle, acquire and use knowledge about the world around it, have the ability to recognize obstacles and respond in real time situations that may occur in this environment. This paper also proposes the use of an ultrasonic sensor to scan an angle of 180 degrees, for detection of landmarks in a natural environment in order to build the internal map inside the robot's controller memory. The displacement information is provided by the robot odometry system with encoder. This information is combined through the application of Extended Kalman filter (EKF). This is a preliminary work, which has the specific contribution the task of locating and mapping simultaneously (SLAM) using a rotating ultrasonic sensor. There is also presented the simulation results of the technique of simultaneous localization and mapping using the extended Kalman filter (EKF) in addition of experimental evaluations in real environment, applied to a mobile robot working as an automated carrier materials on the factory floor. Discussions are presented on the used sensors, the computational complexity, data combination and modeling and control of mobile robot.

Keywords: Mobile Robotics, SLAM, Extended Kalman Filter, EKF and Landmarks.

Capítulo 1

1. INTRODUÇÃO

1.1 INTRODUÇÃO À ROBÓTICA MÓVEL

Com o grande desenvolvimento das tecnologias de *hardware* e *software*, potentes computadores podem ser usados para desenvolver novas técnicas de controle robótico. As novas técnicas estão permitindo que os robôs móveis possam ser usados em diversas aplicações novas como, por exemplo: transporte de materiais em hospitais, em depósitos e no chão de fábrica no lugar dos AGVs, veículos agrícolas autônomos, veículos urbanos autônomos, guia em museus, etc (BURGARD, 1998)(NEWMAN, 1999) (BAILEY, 2002). Estas novas aplicações demonstram que os robôs móveis executam tarefas complexas que até então só eram executadas por seres humanos, com habilidades como aprender com a experiência, navegar por ambientes desconhecidos, desviar de obstáculos imprevistos e reagir de forma inteligente a estímulos do ambiente (THRUN, 2002). Conseqüentemente, as pesquisas com robótica móvel têm direcionado seus esforços para o desenvolvimento de agentes autônomos capazes de interagir com o seu ambiente de trabalho. Para atingir este objetivo, é imprescindível que os robôs tenham a capacidade de localizar-se com aceitável

precisão em relação a um sistema de referência. As metodologias de localização têm defendido que é necessário que o robô tenha o conhecimento do seu local de trabalho para determinar a sua localização de forma eficiente (BAILEY, 2006).

O problema de localização surge devido à dificuldade que um robô apresenta ao navegar por um ambiente desconhecido, construindo um mapa das regiões por onde já passou ao mesmo tempo em que se localiza dentro dele. O acúmulo de erros gerados pela incerteza dos sensores utilizados para estimar os estados de localização e mapeamento impede que sejam obtidos resultados coerentes após períodos de navegação suficientemente longos (THRUN, 1999).

Os algoritmos de SLAM (*Simultaneous Localization and Mapping*) procuram minimizar esses erros resolvendo ambos os problemas de localização e mapeamento simultaneamente, utilizando as informações de uma etapa para aumentar a precisão dos resultados alcançados na outra e vice-versa. Uma das maneiras de se alcançar isso se baseia no estabelecimento de marcos no ambiente que o robô pode utilizar como pontos de referência para se localizar conforme navega. Na literatura clássica, os marcos são referenciados também como *landmarks*.

A Localização e Mapeamento Simultâneo são conhecidos como um dos problemas mais difíceis da área da robótica móvel. Uma das primeiras propostas para o problema de SLAM, foi apresentada por (SMITH et al 1990), a qual utilizava uma abordagem estocástica para o mapeamento, permitindo a aplicação do Filtro de Kalman para manter uma estimativa simultânea da localização do robô e do mapa, e vem sendo estudada ativamente desde a década de 80 e intensificou-se em meados da década de 90 (THRUN, 2005)(BAILEY2006).

1.2 DEFINIÇÃO DO PROBLEMA

Este trabalho propõe a utilização de sistemas de navegação de robôs móveis usando o SLAM com sensores de baixo custo (sensor de ultra-som) em ambientes internos usando a técnica do Filtro de Kalman Estendido para o mapeamento e localização simultâneos do robô e, conseqüentemente, uma navegação robusta em tempo real. O método evita a criação de

landmarks artificiais no ambiente que o robô atua, trabalhando com *landmarks* naturais, ou seja, objetos e lugares naturais do ambiente.

1.3 CONTRIBUIÇÕES

Neste trabalho é apresentada uma solução para o problema do SLAM que faz uso de um sensor de ultra-som de baixo custo para encontrar os *landmarks* naturais com um sistema de movimento do robô que utiliza motores de passo e controladores de alto nível de micro passo para se locomover, este equipamento também é equipado com um sistema de *encoder* para odometria. As situações de navegação propostas foram testadas em ambiente de simulação e complementadas com avaliações experimentais em ambiente reais. Os testes foram realizados em um ambiente de chão de fábrica real composto por diversas máquinas de usinagem.

Os sensores mais usados nos robôs para SLAM encontrados na literatura são: a) *laser range finder*, que lê distâncias de obstáculos de até dezenas de metros em um plano com um raio de abertura de 180 graus; b) câmeras de vídeo, onde algoritmos de processamento de imagens são utilizados para extrair as características dos elementos observados de um ambiente, bem como calcular a distância dos obstáculos; c) ultra-som ou sonar, usado para ler distâncias de obstáculos à frente do robô em um cone de 30 graus com alcance de alguns metros; d) *encoders*, usados para medir o deslocamento do robô durante a navegação (odometria). Os sensores a e b são caros e demandam um poder de processamento computacional grande (processadores de 32 bits) para extrair as informações. Por outro lado, os sensores c e d são baratos e necessitam um poder de processamento pequeno (microcontroladores de 8 ou 16 bits) (LEONARD, 1992).

Desta forma, neste trabalho consideram-se robôs móveis equipados com *encoders* e ultra-som para gerar uma contribuição de baixo custo e ao mesmo tempo de alto nível, com o uso do Filtro de Kalman Estendido. Os resultados obtidos também estão disponíveis para a reprodução dos experimentos ou análise e criação de trabalhos futuros.

1.4 ORGANIZAÇÃO DO TEXTO

Este documento está dividido em 6 capítulos.

- O capítulo 1 apresenta o contexto no qual este trabalho está inserido e suas contribuições;
- O capítulo 2 retrata a fundamentação teórica sobre as abordagens existentes do problema de SLAM;
- O capítulo 3 apresenta a fundamentação matemática envolvida sobre o Filtro de Kalman Estendido aplicado no problema SLAM;
- O capítulo 4 descreve os materiais e métodos utilizados no trabalho proposto;
- O capítulo 5 relata os experimentos realizados e discute a qualidade deles;
- Por fim, o capítulo 6 traz as conclusões e novas perspectivas sobre o presente trabalho.

1.5 TRABALHOS PUBLICADOS EM EVENTOS CIENTÍFICOS

A seguir tem-se o artigo publicado em congresso relativo à divulgação dos resultados desta dissertação:

BIGHETI, J. A., FRANCHIN, M. N., AGUIAR, P. R., BORDON, M. E., CASTANHO, J. E. C.; **Navegação em tempo real de Robôs Móveis em chão de fábrica usando métodos com Filtro de Kalman Estendido.** In: 6º Congresso Brasileiro de Engenharia de Fabricação – COBEF 2011, Caxias do SUL- RS, COF11-0466, 2011.

Capítulo 2

2. FUNDAMENTAÇÃO TEÓRICA DO PROBLEMA DE SLAM

Este capítulo tem como objetivo apresentar um breve histórico e os conceitos básicos existentes sobre o problema de SLAM. Os principais tópicos abordados são: Mapeamento, *landmark*, localização e o problema de Mapeamento e Localização Simultâneos (SLAM – do inglês *Simultaneous Localization and Mapping*). Por fim, um sumário do capítulo é apresentado nas considerações finais.

2.1 MAPEAMENTO

Mapeamento é o nome dado à tarefa de construir representações do ambiente com dados obtidos a partir dele. Este tipo de tarefa é comum em várias atividades humanas, como a arquitetura, construção civil, cartografia, aviação, geografia, geologia, atividades militares, e

outras. Quando se trata de mapeamento robótico, a utilização de mapas é necessária para que um robô consiga construir um modelo do mundo ao seu redor na memória do sistema de controle do robô e utilizar esse conhecimento para conseguir cumprir os seus objetivos. Para que um robô possa lidar com o mundo ao seu redor ele deve primeiramente ser capaz de perceber os objetos que estão ao seu redor. Isso é feito através de sensores que interagem com o ambiente de alguma forma, como, por exemplo, explorando propriedades da luz (câmeras, laser, infravermelho) ou de ondas mecânicas (sonares). Conforme se movimenta pelo ambiente o robô realiza observações das estruturas que se encontram ao seu redor, e pode decidir por apenas reagir a elas de acordo com comportamentos programados ou então armazenar a informação contida nessas observações para que possam ser recuperadas posteriormente (THRUN, 2002).

As pesquisas em mapeamento na robótica móvel iniciaram-se na década de 80 e durante essa década e no início da década de 90 o mapeamento era amplamente dividido em dois tipos: topológico e métrico. Segundo Thrun (2002), a diferença entre topológico e métrico não é clara, ou seja todo o mapa topológico é virtualmente dependente de informações geométricas, e que, na prática, o que os diferencia é a grande quantidade de subdivisões do mapa, sendo essas subdivisões maiores nos métricos.

2.1.1 Mapas topológicos

Mapas topológicos, também chamados de mapas relacionais, fornecem as relações entre os vários locais ou objetos presentes no ambiente, geralmente sob a forma de um gráfico. Mapas topológicos, de forma geral, registram informações sobre determinados elementos ou locais do ambiente, chamados marcos. Assim, marcos e relações são os elementos dos mapas topológicos (MATARIC, 1990).

Como pode ser observado na Figura 2.1 (b), o mapa topológico representa o ambiente do robô através de grafos, onde os nós desses grafos correspondem a situações, locais ou marcos distintos. Caso exista um caminho direto que ligue dois pontos distintos do ambiente ele será representado através de um arco que conectará os dois nós correspondentes no grafo.




Figura 2. 1. (a) Representação de um ambiente não mapeado, (b) representação de um mapa topológico.

Fonte: OLIVEIRA (2010)

2.1.2 Mapas métricos

Os mapas métricos são representados normalmente através de um plano dividido em células de tamanhos iguais, que também é chamada de grade (ou *grid*) como ilustrado na Figura 2.2, ou seja, cada célula representa uma porção fixa do espaço e armazena um valor que indica o estado desta célula como, por exemplo, a presença ou a ausência de um obstáculo (THRUN, 1998).

Um exemplo de sensor de ultra-som é ilustrado na Figura 2.3 para geração de mapas métricos, sendo que os pontos escuros representam obstáculos e os claros, regiões livres. As formas mais conhecidas de representação do ambiente com mapas métricos é *occupancy-grid* (MORAVEC; ELFES, 1985).

A representação dos mapas na Grade de Ocupação é uma matriz de ocupação multidimensional (normalmente 2D ou 3D), que mapeia o espaço em células, de tal forma que

cada célula armazena uma estimativa probabilística de seu estado, sendo os possíveis estados: ocupado ou livre.




Figura 2. 2. (a) Representação de um ambiente não mapeado, (b) representação de um mapa métrico.

Fonte: OLIVEIRA (2010)

As estimativas do estado de cada célula são obtidas através da interpretação das leituras de distâncias utilizando modelos probabilísticos dos sensores.




Figura 2. 3. Sensor de um sonar, células claras denotam regiões livres e células escuras, áreas ocupadas.

Fonte: GOOGLE IMAGES

2.1.3 Landmarks

A literatura define os *landmarks* como informações que estão presentes no ambiente de navegação do robô que servem de referência para a construção do mapa desse ambiente e depois são convertidas em dados que são carregados no sistema de controle do robô, permitindo com isso a sua localização a partir dessas referências (BORENSTEIN et al, 1996).

Para localização do robô em ambientes que podem ser estruturados ou desestruturados utilizamos os *landmarks* que são elementos externos. As informações presentes no ambiente que podem ser caracterizadas como *landmarks* dependem do tipo de sensor utilizado pelo robô para adquirir os dados e do algoritmo de processamento adotado para interpretar esses dados. Os *landmarks* podem ser classificados em dois grupos:

- Naturais;
- Artificiais.

Independentemente do tipo de sensor, do algoritmo de processamento e da informação a serem obtidos do ambiente original ou modificados, os *landmarks* devem ser confiáveis. Ou seja, as características que os identificam devem permanecer estáveis enquanto servirem de referência para o robô.

2.1.4 Landmark artificial

O *landmark*, de acordo com (LAJES, 1998), é considerado artificial quando é inserido de forma intencional no ambiente de navegação do robô. Esse tipo de *landmark* é detectado facilmente pelos sensores do robô, pois suas características foram artificialmente criadas com o intuito de serem explícitas no ambiente de navegação do robô. O *landmark* artificial não somente serve de referência para a localização e navegação do robô, como também serve de fonte de informação utilizada para outro fim. A Figura 2.4 mostra um exemplo de *landmark* artificial fixado nas paredes do ambiente de trabalho do robô para detecção pelo sensor de imagem.




Figura 2. 4. *Landmark* artificial fixado na parede do ambiente de trabalho do Robô para detecção pelo sensor de imagem.

Fonte: LAJES (1998)

A desvantagem de um sistema baseado em *landmark* artificial é a necessidade de adequação do ambiente para que o robô possa navegar.

2.1.5 Landmark natural

O *landmark* é considerado natural quando faz parte do ambiente original de navegação do robô. O ideal é desenvolver sistemas que tenham a capacidade de identificar referências naturais do ambiente. Desse modo, sistemas cada vez mais eficientes para lidar com o mundo real são criados.

A Figura 2.5 apresenta exemplos de *landmarks* naturais detectados com sensor de imagem. Conforme pode ser notado, os *landmarks* naturais podem basear-se na estrutura do ambiente como bordas e cantos de portas e janelas. Mas, também podem basear-se na variação da intensidade de luminosidade de certa região de uma imagem.




Figura 2. 5. Landmarks naturais detectados com sensor de imagem.

Fonte: DAVISON (2011)

2.1.6 Detecção dos landmarks

Para detecção de *landmark* no ambiente do robô são usadas basicamente, as seguintes fases:

1. Capturar os dados do ambiente através do sensor;
2. Analisar os dados capturados a fim de identificar as informações que caracterizam um *landmark*;
3. Armazenar as características que correspondem aos *landmarks* na memória do sistema de controle do robô para representar o mapa do ambiente. Esses *landmarks* também serão usados para estimar a localização do robô.

Para se determinar o tipo de sensor que será adotado na aquisição de dados para detecção dos *landmarks* analisa-se basicamente o tipo de ambiente e o poder de processamento do robô. Conhecer as características do ambiente de navegação do robô é

muito importante, pois os sensores possuem limitações e essas devem ser respeitadas para a implementação de um sistema robusto.

Por exemplo, um sensor de imagem necessita de um nível mínimo de luminosidade do ambiente para poder capturar as imagens; e um sensor *laser range finder* não é capaz de capturar dados onde a luz emitida pelo mesmo é absorvida pelo ambiente ou não é refletida. A escolha do sensor também está relacionada ao poder de processamento do robô, dado que o volume de informações gerado pelo sensor e o processamento necessário para interpretar essas informações variam. Por exemplo, o sensor de imagem gera um volume de informações superior ao do *laser range finder* e o seu processamento consome muito mais recursos computacionais do sistema.

Um *landmark* é identificado a partir de um conjunto de informações que são capturadas pelo sensor. Em seguida, as informações capturadas são processadas por algum algoritmo que busca identificar um padrão ou uma característica dentro desse conjunto. Num ambiente interno, o *landmark* pode ser, por exemplo, uma porta ou o marco de uma janela. Já num ambiente externo pode ser uma árvore ou a borda de uma calçada.

2.1.7 Tipos de ambientes para criação dos mapas

Os tipos de ambiente são classificados em: estático ou dinâmico, estruturado ou desestruturado e interno (*indoor*) ou externo (*outdoor*). As Figuras 2.6 a 2.9 mostram essa estrutura de ambientes.

Um ambiente é classificado como dinâmico quando existem objetos móveis na cena e estático quando todos os objetos são fixos.

É exibida na Figura 2.6 uma imagem de um local fabril onde há tornos e equipamentos de manufatura que representam um ambiente interno estruturado e estático.



Figura 2. 6. Ambiente interno estruturado e estático.

Fonte: SENAI - L. Paulista

A imagem da Figura 2.7 exibe um escritório onde as mesas, cadeiras, computadores e outros objetos são colocados de forma desorganizada que representa um ambiente interno desestruturado e estático.




Figura 2. 7. Ambiente interno desestruturado e estático.

Fonte: GOOGLE IMAGENS

Na figura 2.8 é apresentada uma imagem de uma estrada onde é representado um ambiente externo estruturado, estático com luminosidade não controlada e solo irregular.



Figura 2. 8. Ambiente externo estruturado, estático.

Fonte: GOOGLE IMAGENS

É representado na Figura 2.9 um ambiente externo desestruturado, dinâmico com luminosidade não controlada e solo irregular.



Figura 2. 9. Ambiente externo desestruturado, dinâmico.

Fonte: GOOGLE IMAGENS

Em aplicações do mundo real dificilmente são encontrados ambientes totalmente estáticos. Na prática, a maioria dos algoritmos considera os objetos móveis como sendo ruídos do sistema. Portanto, quando o ambiente é altamente dinâmico, as implementações tradicionais não conseguem lidar de maneira eficiente com esse problema. Em Bailey (2002) é descrito em seu trabalho sobre SLAM a diferenciação entre objetos móveis e estáticos. Já a classificação entre ambiente estruturado e desestruturado depende das características geométricas dos objetos presentes na cena. A informação geométrica freqüentemente extraída do ambiente é a reta. Logo, quando se torna difícil a identificação na cena de formas geométricas conhecidas, o ambiente é classificado como desestruturado. Tanto no ambiente interno como no externo existem informações geométricas conhecidas. Porém, no ambiente interno a geometria é geralmente mais definida do que no externo. Por exemplo, janelas, portas e corredores são facilmente representados por retas. Assim, conhecer o ambiente é importante na implementação dos algoritmos de mapeamento, uma vez que isso influencia diretamente no tipo de informação que pode ser extraída dos sensores e no nível de ruído do sistema.

2.2 LOCALIZAÇÃO

A localização consiste em estimar a posição do robô no ambiente. Determinar sua própria posição é uma capacidade básica para que qualquer tarefa de navegação seja executada. Conhecer a posição do robô no ambiente é muito importante tanto para a sua navegação, como para a construção do mapa. Geralmente a localização do robô não é obtida diretamente de um único sensor. Ela é calculada a partir da localização anterior do robô, dos comandos de movimentação do mesmo e dos dados dos sensores gerados na posição atual. Essa junção de informações é necessária, principalmente, para lidar com as mudanças do ambiente e com os ruídos dos sensores. O nível de dificuldade para calcular a localização do robô é variável. Uma das soluções amplamente utilizadas é associar informações providas de outros sensores ao odometro para aumentar a precisão da localização (THRUN, 1998). O uso conjunto de sensores (por exemplo, sensor laser ou sonar) com o odômetro possibilita a utilização de técnicas que associam as leituras atuais com as anteriores para se estimar a posição atual. Pelo fato das leituras dos sensores serem armazenadas nos mapas, é essencial que esses últimos não contenham erros para evitar falhas no processo de localização.

De acordo com Thrun (2005) e Borenstein (1996), o problema de localização pode ser classificado em três tipos:

- O problema de Rastreamento da Posição (ou *Position Tracking*): nesse problema, é considerado que a posição inicial do robô em relação ao mapa (posição global) é conhecida. Entretanto, com a movimentação do robô, a localização é prejudicada devido aos erros de leitura do sensor, como por exemplo, o odômetro. O problema de rastreamento da posição tem como foco estimar esses erros, de forma a calcular corretamente a posição local do robô. Normalmente os erros são aproximados por meio de uma distribuição unimodal (por exemplo, distribuição normal);
- O problema de Localização Global (ou *Global Localization*): ao contrário do problema de rastreamento da posição, na localização global o robô não conhece a sua posição inicial no mapa. Dessa forma, são buscadas estratégias para se estimar a posição inicial do robô, considerando inclusive, o problema de rastreamento da posição;
- O problema do Robô Raptado (ou *Kidnapped Robot Problem*): esse problema é uma extensão da localização global. No problema do robô raptado, assume-se que a qualquer momento, o robô poderá ser transferido para outra posição sem ser informado. Caso isso ocorra, o robô deverá detectar a alteração em sua posição e logo em seguida, calcular a sua nova localização. Em termos práticos, a ocorrência dessa situação é mínima. Porém, esse problema pode ser utilizado para verificar a capacidade de recuperação do robô em falhas repentinas, de forma que possa manter o sistema de localização intacto.

Atualmente, existem diversas técnicas que possibilitam estimar a posição do robô. A maioria delas tem foco nos problemas de rastreamento da posição. Em relação ao problema de localização global, muitos focam o uso de métodos estatísticos conforme apontado por (THRUN, 2002). Entre eles destacam-se: Filtro de Kalman (SMITH et al, 1990).

Com o intuito de ilustrar o funcionamento do processo de localização por método de Markov, considere o ambiente representado na Figura 2.10. Assume-se que o espaço de posições do robô tem uma única dimensão, isto é, o robô só pode se mover horizontalmente. O robô é colocado em algum lugar do ambiente, mas a sua posição não é informada.

A localização por método de Markov representa um estado de incerteza com uma distribuição uniforme sobre todas as possíveis posições, como mostra a Figura 2.10 a. Em seguida o robô verifica os seus sensores e descobre que esta ao lado de uma porta. A localização pelo método de Markov modifica sua "crença" aumentando a probabilidade dos locais que são próximos a portas, e diminuindo a probabilidade para todos os outros locais (Figura 2.10 b).

Pode-se notar que a crença resultante é multimodal, refletindo o fato que a informação disponível é insuficiente para uma localização global. Nota-se também que os locais que não são próximos a portas não possuem probabilidade nula. Isto se deve ao fato de que os sensores apresentam muitos ruídos, e um único sinal de uma porta normalmente é insuficiente para excluir a possibilidade de não se estar perto de uma porta.

O próximo passo do robô é se mover um metro para frente. A localização pelo método de Markov incorpora esta informação deslocando a distribuição de probabilidade proporcionalmente, como pode ser visto na Figura 2.10 c. Para levar em conta o erro que sempre está presente quando um robô se move, o que inevitavelmente causa uma perda de informação, a nova crença de posição é menor do que a anterior.

Finalmente, o robô verifica seus sensores uma segunda vez, e novamente ele percebe que esta ao lado de uma porta. Esta observação é multiplicada pela distribuição de probabilidade atual, que gera a crença final que é apresentada na Figura 2.10 d. Neste instante de tempo, a maior parte da probabilidade esta centrada em volta de uma única posição. A certeza do robô sobre a sua posição é muito alta.

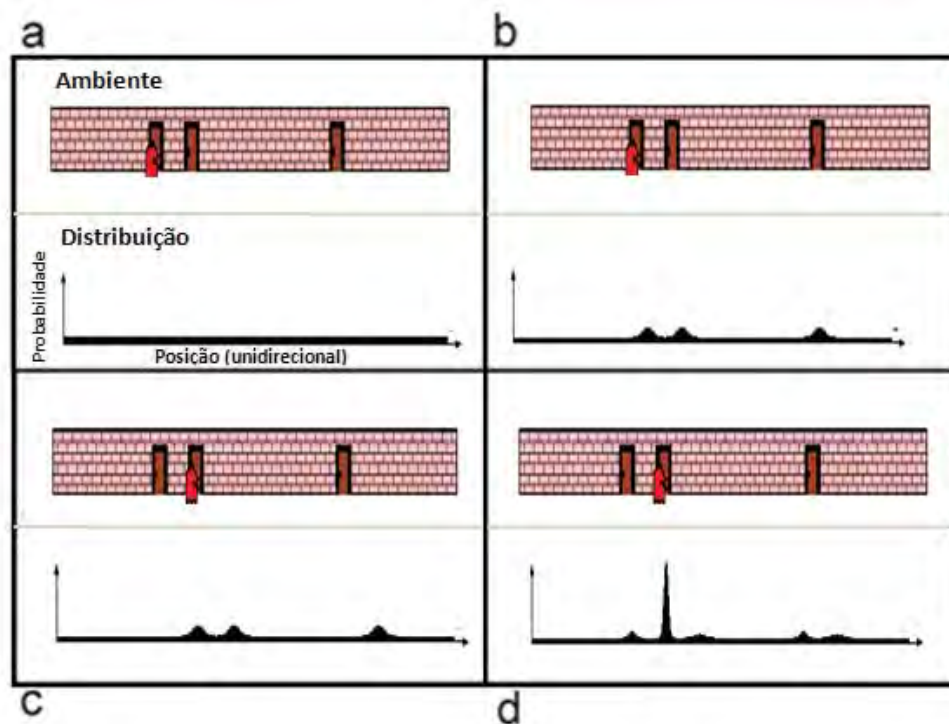


Figura 2. 10. Representação do funcionamento do algoritmo de localização por Markov.

2.3 SLAM - LOCALIZAÇÃO E MAPEAMENTO SIMULTÂNEO

Quando um ser humano está em um ambiente estranho, não conhecendo nada sobre o meio em que se encontra, ele tem a capacidade de integrar-se nesse ambiente apenas pela observação e exploração. Assim, o que antes era considerado desconhecido, aos poucos se torna familiar. O uso da memória como ferramenta é fundamental para que consiga distinguir entre locais já explorados de locais a serem explorados, permitindo que se navegue sem se perder. Suponha o caso de um ser humano, abandonado numa floresta sem nenhuma informação. Com o passar do tempo, após ter explorado todos os locais a sua volta, ele passa a conhecer o ambiente onde se encontra, pois criará na sua mente pontos de referência que lhe permitem localizar-se em cada instante. Este processo de localização e mapeamento, facilmente realizado por um ser humano, vem sendo muito estudado ao longo dos anos, em aplicações na robótica móvel, e conhecida com a sigla de SLAM.

2.3.1 A origem do SLAM

A Localização e Mapeamento Simultâneos é, conforme citado anteriormente, conhecido como um dos problemas mais difíceis da área da robótica móvel. Tal técnica é conhecida como SLAM (*Simultaneous Localization and Mapping*) ou CML (*Concurrent Mapping and Localization*), (THRUN, 2002). Comparando o SLAM a outros ramos da robótica, podemos considerá-lo como um assunto novo, já que a sua origem se deu em 1986, na Conferência de Robótica e Automação do IEEE em São Francisco com a discussão sobre métodos de localização e mapeamento pelos pesquisadores Hugh Durrant-Whyte, Peter Cheeseman, Jim Crowley, Raja Chatila, Oliver Faugeras e Randal Smith, (BAILEY, 2002). Nesse período, diversos métodos foram propostos para diferentes tipos de ambientes, tendo como resultado métodos robustos para ambientes que são estáticos, estruturados e de tamanho limitado. No entanto, quando o ambiente é dinâmico, desestruturado e de larga escala, ainda há muitos problemas que não foram solucionados. Desse modo, há diversas pesquisas que buscam resolver esses problemas, procurando tornar os robôs cada vez mais próximos do mundo real. Por exemplo, em (BAILEY, 2002) é abordado o problema de localização e mapeamento simultâneos (SLAM) em ambiente externo e desestruturado. Já o trabalho de Thrun (2004) apresenta um algoritmo de localização e mapeamento simultâneos com atualização do mapa em tempo constante, independente do seu tamanho. No trabalho de Bailey e Durrant-White (2006), o problema de Localização e Mapeamento Simultâneo questiona se é possível para um robô móvel ser colocado em uma localização desconhecida, em um ambiente desconhecido para que o robô de forma incremental construa um mapa consistente desse ambiente, enquanto simultaneamente determine sua localização. Thrun (2002) enfatiza em seu trabalho que para a construção de robôs móveis verdadeiramente autônomos é necessário que o mapeamento e a localização sejam estimados automaticamente e simultaneamente sem informação a priori.

2.3.2 Trabalhos relevantes do problema de SLAM

Vários trabalhos relevantes do problema de SLAM foram produzidos a partir de 1987. Pode-se destacar dentre eles “*On the representation of spatial uncertainty*” de Smith e Cheeseman em 1985, e “*Uncertain geometry in robotics*” de Durrant-White em 1988. Estes trabalhos estabeleceram as bases do uso de sistemas estocástico para descrever as relações

entre pontos de referência (*landmarks*) e a manipulação de incertezas geométricas. Neste mesmo ano de 1988, Ayache e Faugeras trabalhando em navegação de robôs com sensores de imagem publicaram “*Building, registering, and fusing noisy visual maps*”. Já no ano seguinte, em 1989, Crowley trabalhando em navegação baseada em sonar publicou “*World modeling and position estimation for a mobile robot using ultra-sonic ranging*”. Ambos os trabalhos usavam filtros de Kalman, e tiveram como influencia o trabalho de Chatila e Laumond, “*Position referencing and consistent world modeling for mobile robots*”, publicado em 1985. Estes trabalhos serviram de base para Smith, Self e Cheeseman, que em 1990 escreveram sobre *landmarks* no artigo “*Estimating uncertain spatial relationships in robotics*”. Em 1991, Leonard e Durrant-White publicaram o artigo “*Simultaneous map building and localisation for an autonomous mobile robot*”, onde chegariam a conclusão que uma solução consistente teria de levar em conta que localização e mapeamento estavam interligados. Neste trabalho, Infelizmente não consideraram as propriedades de convergência do mapa, e seu comportamento no estado estacionário, o que resultou em uma estagnação na procura pela solução do problema de localização e mapeamento combinados. Somente em 1995, durante o 7º Simpósio Internacional de Pesquisa em Robótica, os trabalhos neste sentido retomaram sua evolução. Lá os pesquisadores perceberam que os problemas de mapeamento e localização, quando combinados em um só problema de estimativas, se tornavam convergentes. Neste mesmo simpósio também foram apresentados o acrônimo “SLAM”, bem como a estrutura do problema. Duas edições mais tarde, no 9º Simpósio Internacional de Pesquisa em Robótica, realizado em 1999, ocorreu a primeira sessão sobre SLAM. Nesta sessão foi alcançada certa convergência entre os métodos de SLAM baseados em filtros de Kalman, e os métodos probabilísticos introduzidos por Thrun, Burgard e Fox no trabalho “*A Probabilistic Approach to Concurrent Mapping and Localization for Mobile Robots*” de 1998. Em 2000, ocorre o IEEE ICRA Workshop sobre SLAM e sua repercussão foi tamanha que atraiu muitos pesquisadores. Na edição de 2002 este número subiu para 150 pesquisadores. Em 2002 ocorreu o 1º SLAM Summer School no Royal Institute of Technology (KTH) em Estocolmo na Suécia. Este evento teve a participação dos principais pesquisadores da área juntamente com 50 estudantes de doutorado que vieram de várias partes do globo. As edições seguintes ocorreram em 2004 no Centre National de la Recherche Scientifique (CNRS) em Toulouse na França, e em 2006 na University of Oxford na Inglaterra. O 4º e mais recente SLAM Summer School ocorreu no período de 20 a 23 de janeiro de 2009 na University of Sydney, na Austrália.

2.3.3 O problema de SLAM

No artigo de Bayle e Durrant-White (2006), os pesquisadores questionam se é possível a nível teórico e conceitual, considerar o problema de SLAM um problema resolvido. Ou seja, a resposta à tal pergunta: “É possível para um robô móvel ser colocado em um ambiente desconhecido para que o robô de forma incremental construa um mapa que represente esse ambiente na memória do seu controlador, enquanto simultaneamente determine a sua localização?” é: “Sim, é possível“. No entanto isto não quer dizer que o problema de SLAM esteja resolvido e nada mais tenha que ser feito. Muitos problemas necessitam ser aprimorados, para que o SLAM seja implementável em ambientes diferentes dos de laboratório. Por este motivo é que os autores acima comentam neste mesmo artigo, que inovações precisam ser realizadas de formas substanciais para resolver o problema de SLAM.

2.3.4 Considerações sobre o problema de SLAM

Alguns aspectos inerentes ao SLAM devem ser considerados, e são apresentados conforme Bayle e Durrant-White (2006). Segundo Thrun (2002), a finalidade principal do SLAM é construir uma base de conhecimento que represente o ambiente, com uma localização no mapa na memória do sistema de controle do robô a partir das informações obtidas de sensores do tipo: câmera, sonar, *laser range finder*, infravermelho, radar, GPS, *encoder*, de toque, de colisão, entre outros. Além disso, as informações podem ser obtidas a partir de um único tipo de sensor ou da fusão entre eles, dependendo do tipo de ambiente a ser explorado, da capacidade de processamento do robô e do tipo de informação que o sensor tem capacidade de fornecer. No entanto, apesar dos sensores serem distintos em suas funções, todos eles estão sujeitos a erros causados por interferência do próprio ambiente ou gerados internamente pelo sensor. Além de lidar com os erros e limitações dos sensores, durante a exploração do ambiente, erros de movimentação do robô também devem ser tratados, já que é necessário se conhecer a localização do robô para se construir o mapa simultaneamente, e é muito importante que se defina a forma de como lidar com erros gerados pelos sensores, com a dimensão dos objetos da cena que estão sendo mapeados, com o problema da associação de dados, com a mudança do ambiente e com a estratégia de exploração.

2.3.4.1 O problema da mudança do ambiente

Em relação às mudanças no ambiente, os objetos existentes no ambiente podem ser estáticos ou dinâmicos. No caso do dinâmico, esse dinamismo deve ser interpretado corretamente para que robôs aptos a trabalhar com o mundo real sejam construídos. A mudança pode ocorrer lentamente, tal como o crescimento de uma árvore; ou rapidamente, tal como a mudança do estado de uma porta de aberta para fechada. O dinamismo do ambiente é difícil de ser tratado, pois muitas vezes é difícil definir o que é realmente dinâmico e o que é ruído gerado pelo sensor. Por exemplo, se um robô está em frente a uma porta fechada que estava aberta quando mapeada, isso pode causar inconsistência, visto que o robô pode assumir que a porta mudou de estado de aberta para fechada, ou ainda, que o robô pode não estar na posição em que ele realmente acredita estar. No início do século, a maioria dos algoritmos de mapeamento não considerava o ambiente dinâmico, ou seja, o ambiente é estático e tudo que se move nele é considerado ruído do sensor. Conseqüentemente, a maioria das técnicas eram aplicadas somente num pequeno intervalo de tempo, durante o período em que o ambiente permanece estático (THRUN, 2002).

2.3.4.2 O problema da associação de dados

O problema de relacionar as observações realizadas pelo robô em um determinado instante com a informação armazenada em seu mapa é conhecido como o problema de associação de dados (NIETO et al, 2003). Segundo Tardós (2002), associação de dados é o problema de determinar se as medidas de um sensor obtidas em diferentes pontos correspondem ao mesmo objeto no ambiente. Esse tipo de problema pode ser evidente quando o robô finaliza o mapeamento num ambiente com circuito fechado, em que o ponto inicial de mapeamento deve ser o mesmo que o ponto final. Ou seja, o robô deverá perceber, mesmo estando num ângulo de visão diferente, que ele retornou ao ponto inicial e que um trajeto deve ser fechado. Nesse exemplo, o problema de correspondência é difícil, pois o número de posições possíveis que o robô pode assumir cresce exponencialmente com o passar do tempo. Na Figura 2.11 (a) é mostrado o problema da associação de dados e na Figura 2.11 (b) o mapa do ambiente de navegação do robô.

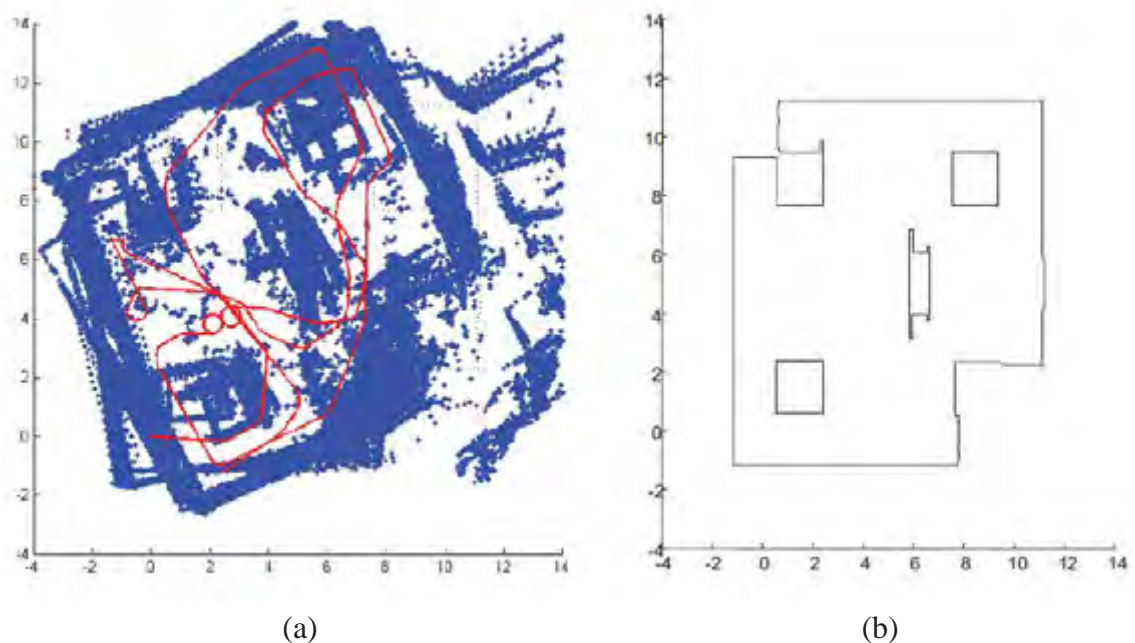


Figura 2. 11. (a) O problema da Associação quando o robô não finaliza o mapeamento num ambiente onde sua navegação é fechada, em que o ponto inicial de mapeamento deveria ser o mesmo que o ponto final. (b) Mapa do ambiente de navegação do robô.

Fonte: TARDÓS (2002).

Uma Associação de Dados bem sucedida envolve a associação das observações realizadas pelo robô em um determinado instante com as informações armazenadas em seu mapa. Associação de dados é indiscutivelmente um dos problemas mais difíceis de ser tratado em aplicações de SLAM. A principal razão é a representação do ambiente de forma errada comumente usadas por algoritmos de SLAM. Esse tipo de problema pode ser visto na Figura 2.11 (a). Para melhorar o processo de Associação de Dados, segundo Nieto (2005), quando acrescentado uma outra fonte de informação das observações do ambiente, além das comumente usadas como as de estimativas de posição de referência, pode melhorar drasticamente o processo de associação das observações realizadas pelo robô. Por exemplo, as informações de visão usadas em conjunto com os dados de sensores de ultra-som. A maioria dos algoritmos no entanto, é baseada apenas em informações vindas de uma única fonte de observação, como por exemplo, os sensores de ultra-som que representam a característica geométrica do ambiente de forma muito simples. Esta representação simples do ambiente faz com que os *landmarks* sejam identificados apenas por suas posições, restringindo o algoritmo

de Associação de Dados de informações do ambiente com representações métricas (LEONARD, 1992).

2.3.4.3 O problema na estratégia de exploração

Para definir a estratégia de exploração para construir o mapa, o robô deve escolher o seu caminho durante a exploração do ambiente; tarefa comumente referenciada na literatura como *robot exploration*. A exploração de um ambiente totalmente modelado é relativamente fácil se comparada com ambientes parcialmente modelados, pois a exploração de áreas desconhecidas pode gerar surpresas. Para lidar com isso, os robôs são programados com base no conhecimento das estratégias de navegação do programador. Durante a exploração, decidir qual caminho deve ser tomado é uma escolha que depende da estratégia de exploração e da expectativa sobre o que cada caminho pode fornecer. Por exemplo, a estratégia poderia ser visitar o maior número possível de áreas desconhecidas do ambiente no menor tempo possível, sem se preocupar com o consumo de energia e nem com o risco do robô se perder.

2.3.4.4 O problema da dimensionalidade dos objetos

Para determinar a dimensionalidade dos objetos no ambiente, o robô deve estabelecer quantos *landmarks* são necessários para descrever o objeto no ambiente. Por exemplo, para descrever uma casa através de um mapa topológico, onde a dimensão de um *landmark* pode ser um corredor, um quarto ou uma porta, apenas algumas dezenas de landmarks podem ser suficientes. Em uma representação bidimensional utilizando *landmarks* são necessários milhares de *landmarks* e numa representação tridimensional o número de *landmarks* pode chegar a milhões. Como descrito, a dimensionalidade dos objetos está diretamente relacionada com o nível de detalhamento do mapa do ambiente e com o formato das informações armazenadas no mesmo.

2.3.4.5 Erros gerados pelos sensores

Quando um erro é gerado pelos sensores, também conhecido como ruído, o tratamento deste ruído é um dos problemas mais complexos do mapeamento (THRUN, 2002). Ao acumular esses erros, a interpretação futura dos dados dos sensores pode ser afetada. Isso

pode ser notado no exemplo apresentado na Figura 2.12, em que pequenos erros de odometria, causados pelo escorregamento das rodas, acumulam-se durante a movimentação do robô, ocasionando erro de vários metros na estimação da posição do robô.



Figura 2. 12. Erro acumulativo de localização de um robô decorrente de pequenos erros de odometria causados pelo escorregamento das rodas.

Fonte: THRUN (2002).

2.4 PRINCIPAIS ALGORITMOS RELACIONADOS AO SLAM

Os principais algoritmos utilizados no problema de SLAM, de acordo com Thrun (2002), estão relacionados com o filtro de Bayes originado da regra de Bayes. Essa regra é um método probabilístico que utiliza evidências amostrais para calcular a probabilidade de eventos. Os principais algoritmos utilizados no problema de SLAM estão relacionados abaixo:

- Filtro de Kalman-KF;
- Filtro de Kalman Estendido- EKF;
- EIF SLAM;
- SEIF;
- *FastSLAM*;
- Filtro de Partículas.

2.4.1 Filtro de Bayes

A Equação 2.1 apresenta a equação discreta e generalizada da regra de *Bayes*, sendo y uma medida de um instrumento, ou seja, y é o valor observado da posição x_i sendo o dado amostral utilizado para calcular a probabilidade posterior da posição x_i . O denominador da equação da regra de *Bayes* é o somatório da probabilidade da variável discreta y em todas as combinações possíveis $p(y)$, sendo o denominador freqüentemente representado por uma variável de normalização, conforme a Equação 2.2.

$$p(x_i|y) = \frac{p(y|x_i)p(x_i)}{\sum_{j=1}^n p(y|x_j)p(x_j)} \quad (2.1)$$

$$p(x_i|y) = \eta p(y|x_i)p(x_i) \quad (2.2)$$

O filtro de Bayes vai além do cálculo baseado em amostras, ele também integra dados temporais a fim de calcular a probabilidade recursivamente. Em outras palavras, para o cálculo da probabilidade a posteriori desse filtro considera-se o resultado obtido no passo anterior, conforme mostram as Equações 2.3 e 2.4. Como pode ser notada, a Equação 2.4 integra a probabilidade do passo anterior e seu resultado é utilizado na Equação 2.5 para determinar a probabilidade posterior. Nessas equações, o controle temporal é realizado pela variável t , onde somente o estado $t-1$ é considerado para a integração. Essa definição ocorre para tornar o algoritmo computável, assumindo que o sistema dinâmico é do tipo modelo *Markov*. O modelo *Markov* assume que a informação amostral y no instante t depende somente da probabilidade de x do mesmo instante; e que a probabilidade de x no instante t depende somente do instante $t-1$.

$$p(x_i^t) = \int p(x_i^t|x_i^{t-1})p(x_i^{t-1})dx \quad (2.3)$$

$$p(x_i^t|y) = \eta p(y^t|x_i^t)p^-(x_i^t) \quad (2.4)$$

Na prática, na fase de localização, a informação amostral y representa a leitura do sensor e x representa um vetor contendo a localização do robô e as localizações dos *landmarks* no ambiente, sendo os elementos desse vetor referenciados através do x_i . Para que as equações do filtro de *Bayes* sejam aplicadas é necessário especificar o modelo de percepção $p(y^t|x_i^t)$, o

dinamismo do movimento $p(x^t|x^{t-1})$ e a representação da probabilidade posterior $p(x_i^t|y)$. A especificação pode ser realizada de várias formas, dependendo do tipo de sensor, da mecânica do robô e do tipo de ambiente. Essas diferentes formas de tratar os dados é a causa do grande número de algoritmos baseados no filtro de Bayes.

2.4.2 Filtro de Kalman

O Filtro de Kalman (KF) é uma das variações mais usadas do filtro de *Bayes*. Esse filtro é utilizado em sistemas dinâmicos normalmente perturbados por ruídos para estimar variáveis do sistema utilizando a distribuição Gaussiana. Seu uso para mapeamento na robótica foi introduzido por (SMITH, 1990) para a construção de mapa contendo a estimativa de relacionamento espacial de objetos e suas incertezas. Além disso, forneceu a base teórica necessária para que outras extensões pudessem ser desenvolvidas. O filtro de Kalman é um processo de estimação recursiva ótimo para solução de problemas lineares relacionados à filtragem de dados, onde o erro quadrático é minimizado (KALMAN, 1960). Através da observação da variável denominada “variável de observação” outra variável, não observável, denominada “variável de estado ou processo” pode ser estimada. Através desses cálculos recursivos estima-se o estado $x_v(k)$, que evolui de acordo com os modelos do processo e de observação. O filtro segue por três estágios:

1. Predição;
2. Observação;
3. Atualização.

A complexidade computacional para a execução do KF é $O(n^2)$, onde n representa o número de *landmarks*. Essa complexidade computacional quadrática permite que somente algumas centenas de *landmarks* possam ser utilizadas no mapeamento, enquanto que normalmente os mapas de ambientes naturais contêm milhões de *landmarks* (MONTERMELO et al, 2002).

Os modelos dos sensores e do controle do robô utilizados no KF são funções lineares. No entanto, os dados gerados pelos sensores e o resultado dos comandos executados com os dados de controle do robô às vezes não se comportam linearmente, o que pode ocasionar erros no mapeamento, portanto o KF é limitado a uma suposição linear, sendo, ineficiente para

sistemas não-lineares. Por exemplo, um robô que se move com velocidades de rotação e de translação constantes descrevem uma trajetória circular, a qual não pode ser modelada por transições de estados lineares. O Filtro de *Kalman* não poderia ser utilizado neste caso.

2.4.3 Filtro de Kalman Estendido

O Filtro de *Kalman* é limitado a uma suposição linear, portanto ineficiente para sistemas não-lineares. Para resolver essa limitação, foi introduzida uma extensão do KF, conhecida como EKF (*Extended Kalman Filter*), onde as funções lineares do KF passaram a se comportar de acordo com as condições que identificam o comportamento do robô e dos sensores. Com essa mudança os dados dos sensores e do controle são interpretados como localmente lineares com adição do ruído Gaussiano. A idéia básica do EKF é linearizar as funções em torno da estimação (NEBOT, 2002).

2.4.4 FastSLAM

O *FastSLAM* é um algoritmo de mapeamento proposto por Montemerlo (2002) que tem como base o filtro de Kalman para estimar a posição dos *landmarks* no ambiente numa distribuição Gaussiana e o filtro de partículas estendido para projetar a posição do robô no ambiente. Como resultado, é gerado um mapa composto por um conjunto de *landmarks* com suas posições estimadas numa distribuição Gaussiana.

Essa técnica pode ser considerada um avanço em relação a implementações puramente com o KF, que tem a complexidade computacional quadrática em relação ao número de *landmarks*. Nessa abordagem, o KF é utilizado somente para estimar a posição dos *landmarks*, sendo a posição do robô determinada pelo filtro de partículas. Com essa divisão, a complexidade computacional se reduz para uma proporção logarítmica definida na ordem $O(M \log N)$, onde M é o número de partículas e N de *landmarks*. Os experimentos realizados pelos autores dessa técnica mostraram que aproximadamente 100 partículas são o suficiente para obter bons resultados, o que a torna uma técnica com complexidade computacional inferior às implementações que utilizam o filtro de Kalman nas duas operações: estimação da posição do robô e dos *landmarks*.

2.4.5 *Extended Information Form SLAM*

Extended Information Form SLAM Algorithm (EIF SLAM) é um algoritmo de mapeamento baseado no Filtro de Informações Estendidas. O EIF SLAM é considerado um algoritmo *offline*, uma vez que constrói o mapa do ambiente somente após a sua exploração. Durante a exploração, as informações de controle e dos sensores são simplesmente armazenadas na memória do sistema controlador do robô. Esse tipo de algoritmo é indicado quando o conjunto de dados possui tamanho fixo e o sistema suporta todos esses dados na memória no momento em que o mapa está sendo construído. Os dados no mapa são representados pelos dois primeiros momentos da Gaussiana, semelhante ao EKF, conhecidos nessa abordagem por vetor e matriz de informação. Porém, o mecanismo de atualização dessas informações entre os dois algoritmos é diferente. A principal vantagem apontada para esse tipo de algoritmo é a capacidade de gerar mapas precisos e de grandes dimensões. Os dados utilizados na construção do mapa são compostos por um conjunto de medidas $\mathbf{z}_{1:t}$ associadas a variáveis de correspondências que indicam a posição dos *landmarks* $\mathbf{c}_{1:t}$ e por um conjunto de controle $\mathbf{u}_{1:t}$. Baseado nesses dados, o algoritmo, primeiramente, inicializa um vetor contendo todas as posições que o robô esteve durante a coleta dos dados. Após isso, passos conhecidos como construção, redução e resolução são repetidos até que um limite desejado de precisão seja alcançado. Os detalhes referentes a cada um desses passos podem ser obtidos em (THRUN et al 2004). O número de iterações depende do erro contido no vetor inicial de posições do robô. O mapa resultante é um vetor de medias (\mathbf{u}) que representa os relacionamentos espaciais dos *landmarks* e do caminho percorrido pelo robô.

2.4.6 *Sparse Extended Information Form SLAM*

Uma versão mais recente do EIF SLAM é o *Sparse Extended Information Form Algorithm* (SEIF). Nessa versão, o algoritmo realiza o mapeamento *online*, ou seja, durante a exploração do ambiente. O SEIF difere do EIF SLAM por manter uma matriz esparsa de informação. O principal motivo de manter uma matriz esparsa é computacional. Nesse caso, todas as equações de atualização do SEIF são executadas em tempo constante (THRUN et al, 2004).

2.4.7 Filtro de Partícula

O Filtro de Partículas (PF) é usado em localização nos algoritmos de SLAM, pois é um poderoso algoritmo que é baseado em amostras para redes Bayesianas dinâmicas (DBN), conhecidas em diversas áreas com o nome de Monte-Carlo (BAILEY, 2006). Esse filtro permite tratar qualquer tipo de distribuição de probabilidade, diferentemente do KF, em que a distribuição é Gaussiana, sendo esse um dos principais motivos de seu uso em técnicas de mapeamento na área da robótica. Apesar dessa vantagem, no mapeamento, o PF não é eficiente para lidar com a dimensionalidade dos mapas, já que o número de partículas necessárias para representar os estados no mapa cresce numa proporção que torna inviável o seu uso na maioria das situações reais de mapeamento. Para tornar o PF mais eficiente foi proposto o filtro de partículas Rao-Blackwellised (RBPF), que é uma extensão do PF tradicional capaz de explorar de forma mais eficiente a estrutura da DBN (BAILEY, 2006). Isso se reflete no mapeamento como uma forma mais eficiente de lidar com o aumento da dimensionalidade do mapa, reduzindo a proporção entre o tamanho do mapa e o número de partículas necessárias para representar os estados posteriores.

2.5 Considerações finais

Neste capítulo, foram apresentados os conceitos de *landmarks* e mapas e em seguida uma revisão dos principais algoritmos base de desenvolvimento da maioria dos algoritmos de mapeamento de ambientes para a navegação de robôs móveis existentes. Como pôde ser notado, o mapeamento implica na resolução de problemas difíceis, pois é necessário lidar com os ruídos dos sensores, tanto mecânicos como elétricos, e com as variações naturais do ambiente. Por isso, para tratar esses problemas a maioria dos algoritmos é baseada em técnicas probabilísticas que usam mapas estocásticos para armazenar as incertezas de estimação que são consideradas no procedimento de geração de mapas. O algoritmo que será usado neste trabalho é baseado no Filtro de Kalman Estendido (EKF) por ser tradicionalmente utilizado em soluções para o problema de localização e mapeamento simultâneos (SLAM), permitindo que o robô navegue no ambiente fundindo informações de odometria com as informações do sensor de ultra-som.

Capítulo 3

3. EKF- SLAM

Nesse capítulo é apresentada a base teórica das ferramentas utilizadas no desenvolvimento do trabalho. Dentre as ferramentas está o filtro de Kalman (KF) e filtro de Kalman Extendido (EKF), utilizado para realizar o SLAM. O uso do Filtro de Kalman Extendido neste trabalho é por ser tradicionalmente utilizado em soluções para o problema de localização e mapeamento simultâneo (SLAM), permitindo que o robô navegue no ambiente fazendo a fusão das informações do sensor de odometria com as informações do sensor de ultra-som. As palavras veículo e robô móvel serão usadas livremente no texto com o mesmo sentido.

3.1 ALGORITMOS DE SLAM

A primeira formalização matemática de uma solução para o problema do SLAM, conforme citado anteriormente, foi apresentada durante a década de 80 por uma série de


artigos (SMITH, CHEESEMAN, 1986) (SMITH, SELF e CHEESEMAN, 1987) (DURRANT-WHITE, 1988) (SMITH, SELF e CHEESEMAN, 1990), e em 1989 foram realizadas as primeiras implementações dessa solução por Mourtarlier e Chatila. Contudo, trabalhos anteriores como os de Taylor (1976) e Brooks (1982) já haviam tentado quantificar as incertezas inerentes a um processo através de limiares mínimos e máximos, estabelecendo faixas de tolerância para uma dada operação e tentando controlar essa faixa para que ela se mantivesse estável. Em Chatila, e Laumond (1985) foi determinado, para o robô HILARE, um valor escalar representativo da incerteza da localização de um robô que leva em consideração tanto a sua posição quanto a sua orientação. Essa solução para o problema do SLAM utiliza um filtro estocástico conhecido como Filtro Estendido de Kalman ou EKF, para acompanhar simultaneamente os estados de localização e mapeamento do robô, o que lhe rendeu o nome de EKF-SLAM ou SLAM Estocástico. A teoria de Filtros de Kalman fornece uma solução fechada e recursiva para o problema de se acompanhar uma variável aleatória de interesse conforme ela evolui no tempo (SIMON e UHLMANN, 1997), e já era tradicionalmente utilizada em soluções individuais para o problema de localização e mapeamento. O EKF-SLAM procurou unificar esses dois problemas ao utilizar um mesmo EKF para acompanhar simultaneamente o estado de localização do robô e dos marcos que ele observa no ambiente.

3.2 O PROBLEMA DE LOCALIZAÇÃO

O problema de localização consiste em responder a seguinte pergunta “Onde estou?”. O problema de localização pode ser definido quando um mapa H_i de posições de pontos de referência (*landmarks*) é conhecido a priori e a partir disso são obtidas as medidas da localização $z_i(k)$ dos *landmarks* (distância e posição) e determina-se a localização $x_v(k)$ do veículo baseado em $z_i(k)$. A Figura 3.1 representa o ambiente de navegação, onde o triângulo vermelho representa a incerteza relativa do robô em relação a sua posição inicial. Nota-se na figura que esta incerteza cresce à medida que o robô mantém a sua navegação. Esta incerteza cresce sem limites e chega a um ponto que é impossível para robô se localizar (DURRANT-WHITE; BAYLE, 2006).

Sendo:

- $\mathbf{x}_v(k)$: vetor de estado do veículo no tempo k ;
- \mathbf{p}_i : vetor de Estado i – ésimo *landmark*;
- $\mathbf{u}_v(k)$: vetor de distância aplicado em $k-1$ para dirigir o veículo de $\mathbf{x}_v(k-1)$ para $\mathbf{x}_v(k)$;
- $\mathbf{z}_i(k)$: vetor de observação de distancia do *landmark* tomado no instante k ;
- \mathbf{X}_v : histórico dos estados do veículo $\{\mathbf{x}_v(1), \mathbf{x}_v(2), \mathbf{x}_v(3), \dots, \mathbf{x}_v(k)\}$;
- \mathbf{U}_v : histórico das entradas de controle $\{\mathbf{u}_v(1), \mathbf{u}_v(2), \mathbf{u}_v(3), \dots, \mathbf{u}_v(k)\}$;
- \mathbf{H}_i : Matriz do modelo de observação de \mathbf{p}_i ;



	Robô	<i>Landmark</i>
Estimado		
Real		

Figura 3. 1. Diagrama do problema de localização.

Fonte: DURRANT-WHITE (2006)

3.3 O PROBLEMA DE MAPEAMENTO

O problema de mapeamento consiste em responder a seguinte pergunta: "O ambiente se parece com o que?". Segundo Durrant-White (2006), o problema de mapeamento é definido quando as posições \mathbf{X}_v do veículo são fornecidas, e a partir disso é obtido as medidas da localização $\mathbf{z}_i(k)$ dos *landmarks* (distância e posição), é construído o mapa \mathbf{H}_i do conjunto de *landmarks* baseado nas medidas de $\mathbf{z}_i(k)$, que é a representação bidimensional do mapa deste ambiente, onde a saída é a representação dos arredores do ambiente de navegação do robô. Desta forma, este mapa pode ser geométrico, de grade de ocupação ou de *landmarks*. A Figura 3.2 ilustra o problema de mapeamento onde as estrelas vermelhas na figura representam a incerteza relativa às observações dos *landmarks*, adquiridas durante a navegação do robô que são os erros de observações dos *landmarks*.




Figura 3. 2.Diagrama do problema de mapeamento.

Fonte: DURRANT-WHITE (2002)

Sendo:

- \mathbf{X}_v : histórico dos estados do veículo $\{\mathbf{x}_v(1), \mathbf{x}_v(2), \mathbf{x}_v(3), \dots, \mathbf{x}_v(k)\}$;
- $\mathbf{z}_i(k)$: vetor de observação de distancia do *landmark* tomado no instante k ;
- \mathbf{p}_i : localização real do i -ésimo *landmark*;
- \mathbf{H}_i : conjunto de todos os *landmarks*.

3.4 O PROBLEMA DE LOCALIZAÇÃO E MAPEAMENTO SIMULTÂNEOS (SLAM)

Conforme é demonstrado na Figura 3.3 o problema de localização e mapeamento simultâneos (SLAM) é definido quando a partir do conhecimento das observações $\mathbf{z}_i(k)$ é determinada a localização $\mathbf{x}_v(k)$ do veículo, e constrói-se o mapa \mathbf{H}_i do conjunto das posições dos *landmarks*, a partir do conhecimento das observações $\mathbf{z}_i(k)$, determina-se a localização $\mathbf{x}_v(k)$ do veículo, o mapa \mathbf{H}_i é construído com as posições dos *landmarks*. O acúmulo de erros gerados pela incerteza dos sensores utilizados para estimar os estados de localização e mapeamento impede que sejam obtidos resultados coerentes após períodos de navegação suficientemente longos. Os algoritmos de SLAM (*Simultaneous Localization and Mapping*) procuram minimizar esses erros resolvendo ambos os problemas de localização e mapeamento simultaneamente, utilizando as informações de uma etapa para aumentar a precisão dos resultados alcançados na outra e vice-versa.

Sendo:

- $\mathbf{x}_v(k)$: vetor de estado do veículo no tempo k ;
- \mathbf{p}_i : vetor de Estado i – éximo *landmark*;
- $\mathbf{u}_v(k)$: vetor de distância aplicado em $k-1$ para dirigir o veículo de $\mathbf{x}_v(k-1)$ para $\mathbf{x}_v(k)$;
- $\mathbf{z}_i(k)$: vetor de observação de distancia do *landmark* tomado no instante k ;
- \mathbf{X}_v : histórico dos estados do veículo $\{\mathbf{x}_v(1), \mathbf{x}_v(2), \mathbf{x}_v(3), \dots, \mathbf{x}_v(k)\}$;
- \mathbf{U}_v : histórico das entradas de controle $\{\mathbf{u}_v(1), \mathbf{u}_v(2), \mathbf{u}_v(3), \dots, \mathbf{u}_v(k)\}$;
- \mathbf{H}_i : Matriz do modelo de observação de \mathbf{p}_i ;




Figura 3. 3. Diagrama do problema de localização e mapeamento simultâneo.

Fonte: DURRANT-WHITE (2006).

Pode-se definir o problema de SLAM, em termos probabilísticos como um processo de Markov. Ou seja, um processo estocástico, portanto o estado do mapa no tempo $k-1$ engloba toda a informação necessária para propagar o sistema para o estado no tempo k . Assim, o problema de SLAM pode ser descrito na equação (3.1), sendo P o modelo probabilístico do processo, $\mathbf{x}_v(k-1)$ estado inicial do robô, \mathbf{z}_i a observação da distância entre o landmark \mathbf{p}_i e $\mathbf{x}_v(k-1)$, $\mathbf{u}_v(k)$ o vetor de controle de distância aplicado em $k-1$ para dirigir o robô de $\mathbf{x}_v(k-1)$ para $\mathbf{x}_v(k)$, \mathbf{H}_i a matriz de observação dos landmarks e $\mathbf{x}_v(k)$ a posição atual do robô.

$$P(\mathbf{x}_v(k), \mathbf{H}_i(k) | \mathbf{z}_i(k), \mathbf{u}_v(k), \mathbf{x}_v(0)) \quad (3.1)$$

3.5 FUNDAMENTOS DO SLAM

Como o próprio nome diz, o problema do SLAM surge quando ambos os problemas de localização e mapeamento precisam ser resolvidos simultaneamente, pois o robô não conta com informações precisas referentes a nenhum deles. Dessa forma, soluções individuais não são suficientes, pois os erros que cada estimativa possui se propagariam para a outra e rapidamente se acumulariam em um círculo vicioso.

Um mapa impreciso não será capaz de gerar uma estimativa precisa de localização, que por sua vez aumentará a incerteza de mapeamento. É necessário lidar com ambos os problemas simultaneamente, procurando uma solução que minimize globalmente as incertezas envolvidas, com isso define-se os fundamentos de SLAM em dois modelos de acordo com Nebot (2002):

- Modelo de processo;
- Modelo de observação.

Modelo de processo: Um veículo com um modelo cinemático conhecido move-se através de um ambiente contendo uma população de *landmarks* de acordo com a Figura 3.4.

Modelo de observação: Um veículo é equipado com um sensor com a possibilidade de tomar medidas da posição relativa entre algum *landmark* individual e o veículo de acordo com a Figura 3.4.




Figura 3. 4. Um veículo com um modelo cinemático conhecido é equipado com um sensor com a possibilidade de tomar medidas da posição relativa entre algum *landmark*, move-se através de um ambiente contendo uma população de *landmarks*.

Fonte: NEBOT (2002).

3.5.1 Modelo de processo

Segundo Newman (2002) é assumido um modelo linear do veículo. Se o estado do veículo é dado como \mathbf{x}_v então o modelo do veículo é:

$$\mathbf{x}_v(k+1) = \mathbf{F}_v(k)\mathbf{x}_v(k) + \mathbf{u}_v(k+1) + \mathbf{v}_v(k+1) \quad (3.2)$$

Onde:

- $\mathbf{F}_v k$ é a matriz de transição de estado;
- $\mathbf{x}_v k$ é um vetor de entradas de controle;
- $\mathbf{v}_v k$ é um vetor de erros não-correlatos de ruído do processo com media zero e covariâncias $\mathbf{Q}_v k$.

A equação de transição de estado para o i -ésimo *landmark* é:

$$\mathbf{p}_i(k+1) = \mathbf{p}_i(k) = \mathbf{p}_i \quad i = 1 \dots n \quad (3.3)$$

Sendo $\mathbf{x}(k)$ o vetor expandido de estado contendo tanto o estado do veículo, como o estado de todos os *landmarks* é:

$$\mathbf{x}(k) = [\mathbf{x}_v^T(k) \quad \mathbf{p}_1^T \quad \dots \quad \mathbf{p}_N^T]^T \quad (3.4)$$

Com isto, o vetor de transição de estado para o sistema completo torna-se:

$$\begin{bmatrix} \mathbf{x}_v(k+1) \\ \mathbf{p}_1 \\ \vdots \\ \mathbf{p}_n \end{bmatrix} = \begin{bmatrix} F_v(k) & 0 & \dots & 0 \\ 0 & I_{p_1} & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & 0 & I_{p_n} \end{bmatrix} \begin{bmatrix} \mathbf{x}_v(k) \\ \mathbf{p}_1 \\ \vdots \\ \mathbf{p}_n \end{bmatrix} + \begin{bmatrix} \mathbf{u}_v(k+1) \\ 0_{p_1} \\ \vdots \\ 0_{p_n} \end{bmatrix} + \begin{bmatrix} \mathbf{v}_v(k+1) \\ 0_{p_1} \\ \vdots \\ 0_{p_n} \end{bmatrix} \quad (3.5)$$

Onde:

I_{p_i} : é a matriz identidade do produto $\dim(\mathbf{p}_i) \times \dim(\mathbf{p}_i)$.

0_{p_i} : é o vetor nulo de $\dim(\mathbf{p}_i)$

O modelo de processo, também denominado modelo de movimentação do robô, é considerado um processo de Markov e em termos de distribuição probabilística pode ser descrito assim:

$$P(\mathbf{x}_v(k) | \mathbf{x}_v(k), \mathbf{u}_v(k)) \quad (3.6)$$

3.5.2 Modelo de observação

Assumindo que a observação é linear, o modelo de observação para o i -ésimo *landmark* é dado como:

$$\mathbf{z}_i(k) = \mathbf{H}_i \mathbf{x}_v(k) + \mathbf{w}_i(k) \quad (3.7)$$

Onde:

- $\mathbf{w}_i(k)$: vetor de erros não-correlatos com media zero e variância $\mathbf{R}_i(k)$.
- \mathbf{H}_i : matriz de observação que relaciona a saída $\mathbf{z}_i(k)$ do sensor ao vetor de estado.
- $\mathbf{x}_v(k)$: vetor expandido de estado contendo tanto o estado do veículo, como o estado de todos os *landmarks*.
- \mathbf{H}_{pi} : matriz de observação das partições dos *landmarks* de \mathbf{H}_i .
- \mathbf{H}_v : matriz de observação das partições do veiculo de \mathbf{H}_i .

É escrita como:

$$\mathbf{H}_i = [-\mathbf{H}_v, 0 \dots 0, \mathbf{H}_{pi}, 0 \dots 0] \quad (3.8)$$

A partir das expressões (3.5) (3.6) é obtido o modelo de observação:

$$\mathbf{z}_i(k) = \mathbf{H}_{pi}p - \mathbf{H}_v\mathbf{x}_v(k) + \mathbf{w}_i(k) \quad (3.9)$$

O modelo de observação, que diz respeito às observações do estado do ambiente, é descrito por um modelo probabilístico que obedece, tal como o modelo de processo, à propriedade de Markov:

$$P(\mathbf{z}_k | \mathbf{x}_k, m) \quad (3.10)$$

Para se atingir o mapeamento e localização simultâneos são usados o filtro de Bayes. Porém, para mapas tridimensionais acaba se tornando uma opção muito custosa computacionalmente. A alternativa para o filtro de Bayes é a utilização do filtro de Kalman, onde o estado \mathbf{x}_k do processo discreto no tempo precisa ser estimado com base nas medições \mathbf{z}_k pois esta definição é exatamente o filtro de Kalman.

3.6 FILTRO DE KALMAN

O filtro de Kalman é um processo de estimação recursiva ótimo para solução de problemas lineares relacionados à filtragem de dados, onde o erro quadrático é minimizado (KALMAN, 1960). Através da observação da variável denominada “variável de observação” outra variável, não observável, denominada “variável de estado ou processo” pode ser

estimada. Através desses cálculos recursivos estima-se o estado $\mathbf{x}_v(k)$, que evolui de acordo com os modelos do processo e de observação.

O filtro segue por três estágios:

4. Predição;
5. Observação;
6. Atualização.

3.6.1 Predição

Após inicializar o filtro, estabelecendo valores para $\hat{\mathbf{x}}_v(k)$ e \mathbf{P}_v a covariâncias de $\hat{\mathbf{x}}_v(k)$, uma predição é gerada através do estado estimado a priori:

$$\hat{\mathbf{x}}_v(k+1|k) = \mathbf{F}_v(k)\hat{\mathbf{x}}_v(k|k) + \mathbf{u}_v(k) \quad (3.11)$$

A observação a priori relativa ao i -ésimo landmark fica sendo:

$$\hat{\mathbf{z}}_i((k+1)|k) = \mathbf{H}_i(k)\hat{\mathbf{x}}_v(k+1|k) \quad (3.12)$$

O estado de covariância a priori, por exemplo, uma medida de quão incertos os estados calculados pelo processo são, é dado por:

$$\mathbf{P}_v(k+1|k) = \mathbf{F}_v(k)\mathbf{P}_v(k|k)\mathbf{F}_v^T(k) + \mathbf{Q}_v(k) \quad (3.13)$$

Sendo $\mathbf{Q}_v(k)$ covariâncias de $\mathbf{v}_v(k)$.

3.6.2 Observação

Seguindo a predição, uma observação $\mathbf{z}_i(k+1)$ do i -ésimo *landmark* é feita utilizando o modelo de observação. Uma inovação e uma matriz de covariância da inovação são calculadas, sendo que inovação é a discrepância entre a medida atual $\mathbf{z}_i(k)$ e a medida prevista $\hat{\mathbf{z}}_i(k)$.

$$\mathbf{w}_i(k+1) = \mathbf{z}_i(k+1) - \hat{\mathbf{z}}_i(k+1|k) \quad (3.14)$$

$$\mathbf{S}_i(k+1) = \mathbf{H}_i(k)\mathbf{P}(k+1|k)\mathbf{H}_i^T(k) + \mathbf{R}_i(k+1) \quad (3.15)$$

Sendo \mathbf{R}_i covariâncias de $\mathbf{w}_v(k)$

3.6.3 Atualização

O estado estimado e a covariância do estado estimado correspondente são então atualizados de acordo com:

$$\hat{\mathbf{x}}_v(k+1|k+1) = \hat{\mathbf{x}}_v(k+1|k) + \mathbf{K}(k+1)\mathbf{w}_i(k+1) \quad (3.16)$$

$$\mathbf{S}_i(k+1|k+1) = \mathbf{P}_v(k+1|k) - \mathbf{H}_i(k+1)\mathbf{S}_i(k+1)\mathbf{w}_i^T(k+1) \quad (3.17)$$

Onde a matriz de ganho $\mathbf{K}(k+1)$ é dada por:

$$\mathbf{K}(k+1) = \mathbf{P}_v(k+1|k)\mathbf{H}_i^T(k)\mathbf{S}_i^{-1}(k+1) \quad (3.18)$$

3.7 FILTRO DE KALMAN DISCRETO

Filtro de Kalman é um algoritmo recursivo, já que apenas o estado estimado a partir do passo de tempo anterior e a medida atual são necessários para calcular a estimativa para o estado atual, com isso define-se o Filtro de Kalman Discreto em dois modelos:

- Modelo de processo.
- Modelo de observação.

3.7.1 Modelo do Processo

Assumindo que o verdadeiro estado no tempo k evoluiu do estado $(k-1)$ de acordo com a equação 3.2 descrita anteriormente.

Assim:

$$p(w) \sim N(0, \mathbf{Q}_v) \quad (3.19)$$

Sendo \mathbf{Q} a matriz de covariância.

3.7.2 Modelo de Observação

No momento k , uma medida $\mathbf{z}_i(k)$ do estado real $\mathbf{x}_v(k)$ é feita de acordo com:

$$\mathbf{z}_i(k) = \mathbf{H}_i \mathbf{x}_v(k) + \mathbf{w}_i(k) \quad (3.20)$$

Onde:

- \mathbf{H}_i é a matriz de observação e relaciona a medida $\mathbf{z}_i(k)$ ao vetor de estado $\mathbf{x}_v(k)$;
- $\mathbf{w}_i(k)$ é o ruído de observação que é assumido como branco e tem uma distribuição de probabilidade normal.

Assim:

$$p(v) \sim N(0, \mathbf{R}_i) \quad (3.21)$$

Sendo \mathbf{R}_i a matriz de covariância.

O Filtro de Kalman Discreto é definido como um algoritmo recursivo, já que apenas o estado estimado a partir do passo de tempo anterior e a medida atual são necessários para calcular a estimativa para o estado atual. Onde o estado do filtro é representado através de duas variáveis, $\mathbf{x}_v(k)$ e $\mathbf{P}_v(k/k)$. Sendo $\mathbf{x}_v(k)$ a estimativa do estado no tempo k , e $\mathbf{P}_v(k/k)$ a matriz de covariância de erro (uma medida da precisão estimada do estado estimado).

No entanto, no caso em estudo os dados gerados pelos sensores e o resultado dos comandos executados com os dados de controle do robô às vezes não se comportam

linearmente, o que pode ocasionar erros no mapeamento, sendo o KF limitado a uma suposição linear, ineficiente para sistemas não-lineares. Portanto o Filtro de *Kalman* não poderia ser utilizado no caso em estudo.

3.8 FILTRO DE KALMAN ESTENDIDO

O filtro de Kalman Estendido (EKF) é uma variante do filtro de Kalman, adaptado para sistemas não lineares. Assim os modelos de processo e observação podem ambos ser não-lineares, e expressos da seguinte forma:

$$\mathbf{x}_v(k) = f(\mathbf{x}_v(k-1), \mathbf{u}_v(k-1), \mathbf{v}_v(k-1)) \quad (3.22)$$

$$\mathbf{z}_i(k) = h(\mathbf{x}_v(k), \mathbf{w}_i(k)) \quad (3.23)$$

Onde f e h são funções não-lineares.

3.8.1 Parâmetros de Ruídos

Na prática, não se sabe os valores de ruído \mathbf{w}_i e $\mathbf{v}_v(k)$ em todos os instantes. Assim, o estado e o vetor de medida são aproximados sem eles, da seguinte forma:

$$\tilde{\mathbf{x}}_v(k) = f(\hat{\mathbf{x}}(k-1), \mathbf{u}_v(k), 0) \quad (3.24)$$

$$\tilde{\mathbf{z}}_i(k) = h(\tilde{\mathbf{x}}_v(k), 0) \quad (3.25)$$

Sendo $\mathbf{x}_v(k)$ uma estimativa de estado posteriori.

Para estimar um processo não-linear, é necessário linearizar o sistema no estado atual, na forma:

$$\mathbf{x}_v(k) = \tilde{\mathbf{x}}_v(k) + \mathbf{A}(\mathbf{x}_v(k-1) - \hat{\mathbf{x}}_v(k-1)) + \mathbf{W}\mathbf{v}_v(k-1) \quad (3.26)$$

$$\mathbf{z}_i(k) = \tilde{\mathbf{z}}_i(k) + \mathbf{J}_h(\mathbf{x}_v(k) - \hat{\mathbf{x}}_v(k)) + \mathbf{V}\mathbf{w}_i(k) \quad (3.27)$$

Sendo:

- $\mathbf{x}_v(k)$:vetor de estado do veículo;
- $\mathbf{z}_i(k)$:vetor de observação para o i-ésimo *landmark*;
- $\tilde{\mathbf{x}}_v(k)$:vetor de erro de $\hat{\mathbf{x}}_v(k)$;
- $\tilde{\mathbf{z}}_i(k)$: vetor de erro de $\hat{\mathbf{z}}_i(k)$;
- $\hat{\mathbf{x}}(k)$: estimativa posteriori de $\mathbf{x}_v(k)$;
- $\mathbf{v}_v(k)$: vetor de erro de ruído do processo;
- $\mathbf{w}_i(k)$ vetor de erro de ruído de observação
- \mathbf{A} :matriz jacobiana das derivadas parciais de f, em função de $\mathbf{x}_v(k)$;
- \mathbf{W} :matriz jacobiana das derivadas parciais de f, em função de $\mathbf{v}_v(k)$;
- \mathbf{J}_h :matriz jacobiana das derivadas parciais de h, em função de $\tilde{\mathbf{x}}_v(k)$;
- \mathbf{V} :matriz jacobiana das derivadas parciais de h, em função de $\mathbf{w}_i(k)$.

Definindo as novas notações para os erros de predição e medida:

$$\tilde{\mathbf{e}}_x(k) = \mathbf{x}_v(k) - \tilde{\mathbf{x}}_v(k) \quad (3.28)$$

$$\tilde{\mathbf{e}}_z(k) = \mathbf{z}_i(k) - \tilde{\mathbf{z}}_i(k) \quad (3.29)$$

Então, tem-se:

$$\tilde{\mathbf{e}}(k) \approx \mathbf{A}(\mathbf{x}_v(k-1)\tilde{\mathbf{x}}_v(k-1)) + \varepsilon(k) \quad (3.30)$$

$$\tilde{\mathbf{e}}_z(k) \approx \mathbf{J}_h \tilde{\mathbf{e}}_x(k) + \eta(k) \quad (3.31)$$

Onde $\varepsilon(k)$ e $\eta(k)$ representam a nova variação do ruído, assim:

$$p(\varepsilon(k)) \sim N(0, \mathbf{W}\mathbf{Q}_v(k)\mathbf{W}^T) \quad (3.32)$$

$$p(\eta(k)) \sim N(0, \mathbf{V}\mathbf{R}_i(k)\mathbf{V}^T) \quad (3.33)$$

As equações anteriores são lineares e se assemelham de perto às equações de diferenças do KF discreto. Então, pode-se usar um segundo filtro de Kalman para calcular o erro de predição:

$$\hat{\mathbf{e}}_x(k) = \mathbf{e}(k)^- + \mathbf{K}_k(\mathbf{z}_i(k) - \tilde{\mathbf{z}}_i(k)) = \mathbf{K}_k \tilde{\mathbf{e}}_k(k) \quad (3.34)$$

$$\hat{\mathbf{e}}_x(k) = \hat{\mathbf{x}}_v(k) - \tilde{\mathbf{x}}_v(k) \quad (3.35)$$

Rearranjando os produtos de estimativa de erro preditos:

$$\hat{\mathbf{e}}_x(k) = \hat{\mathbf{x}}_v(k) - \tilde{\mathbf{x}}_v(k) \rightarrow \hat{\mathbf{x}}_v(k) = \tilde{\mathbf{x}}_v(k) + \hat{\mathbf{e}}_x(k) \quad (3.36)$$

Colocando dentro da expressão prévia de $\hat{\mathbf{e}}_x(k)$:

$$\hat{\mathbf{x}}_v(k) = \tilde{\mathbf{x}}_v(k) + \mathbf{K}_k \tilde{\mathbf{e}}_z(k) \rightarrow \hat{\mathbf{x}}_v(k) = \tilde{\mathbf{x}}_v(k) + \mathbf{K}_k(\mathbf{z}_i(k) - \tilde{\mathbf{z}}_i(k)) \quad (3.37)$$

A equação acima pode agora ser utilizada na atualização da medida no EKF. A seguir temos o resumo da notação utilizada no Filtro de Kalman Estendido:

Predição

- Estado predito:

$$\hat{\mathbf{x}}_v(k)^- = f(\hat{\mathbf{x}}_v(k-1), \mathbf{u}_v(k-1), 0) \quad (3.38)$$

- Covariância predita:

$$\mathbf{P}_v(k)^- = \mathbf{F}_v(k) \mathbf{P}_v(k-1) \mathbf{F}_v(k)^T + \mathbf{W}(k) \mathbf{Q}_v(k-1) \mathbf{W}(k)^T \quad (3.39)$$

Observação

- Inovação:

$$\tilde{\mathbf{y}}(k) = \mathbf{z}_i(k) - \mathbf{H}_i(k) \hat{\mathbf{x}}_v(k|k-1) \quad (3.40)$$

- Covariância da inovação:

$$\mathbf{S}_i(k) = \mathbf{J}_h(k) \mathbf{P}_v(k)^- \mathbf{J}_h(k)^T + \mathbf{V}(k) \mathbf{R}_i(k) \mathbf{V}(k)^T \quad (3.41)$$

Atualização

- Ganho ótimo de Kalman:

$$\mathbf{K}(k) = \mathbf{P}_i(k)^- \mathbf{J}_h(k)^T \mathbf{S}_i(k)^{-1} \quad (3.42)$$

- Estado atualizado:

$$\hat{\mathbf{x}}_v(k) = \hat{\mathbf{x}}_v(k)^- + \mathbf{K}(k)\tilde{\mathbf{y}}(k) \quad (3.43)$$

- Covariância atualizada:

$$\mathbf{P}_v(k) = (\mathbf{1} - \mathbf{K}(k)\mathbf{J}_h(k))\mathbf{P}_v(k)^- \quad (3.44)$$

Na Figura 3.5 é demonstrado á seqüência do funcionamento do Filtro de Kalman Estendido.

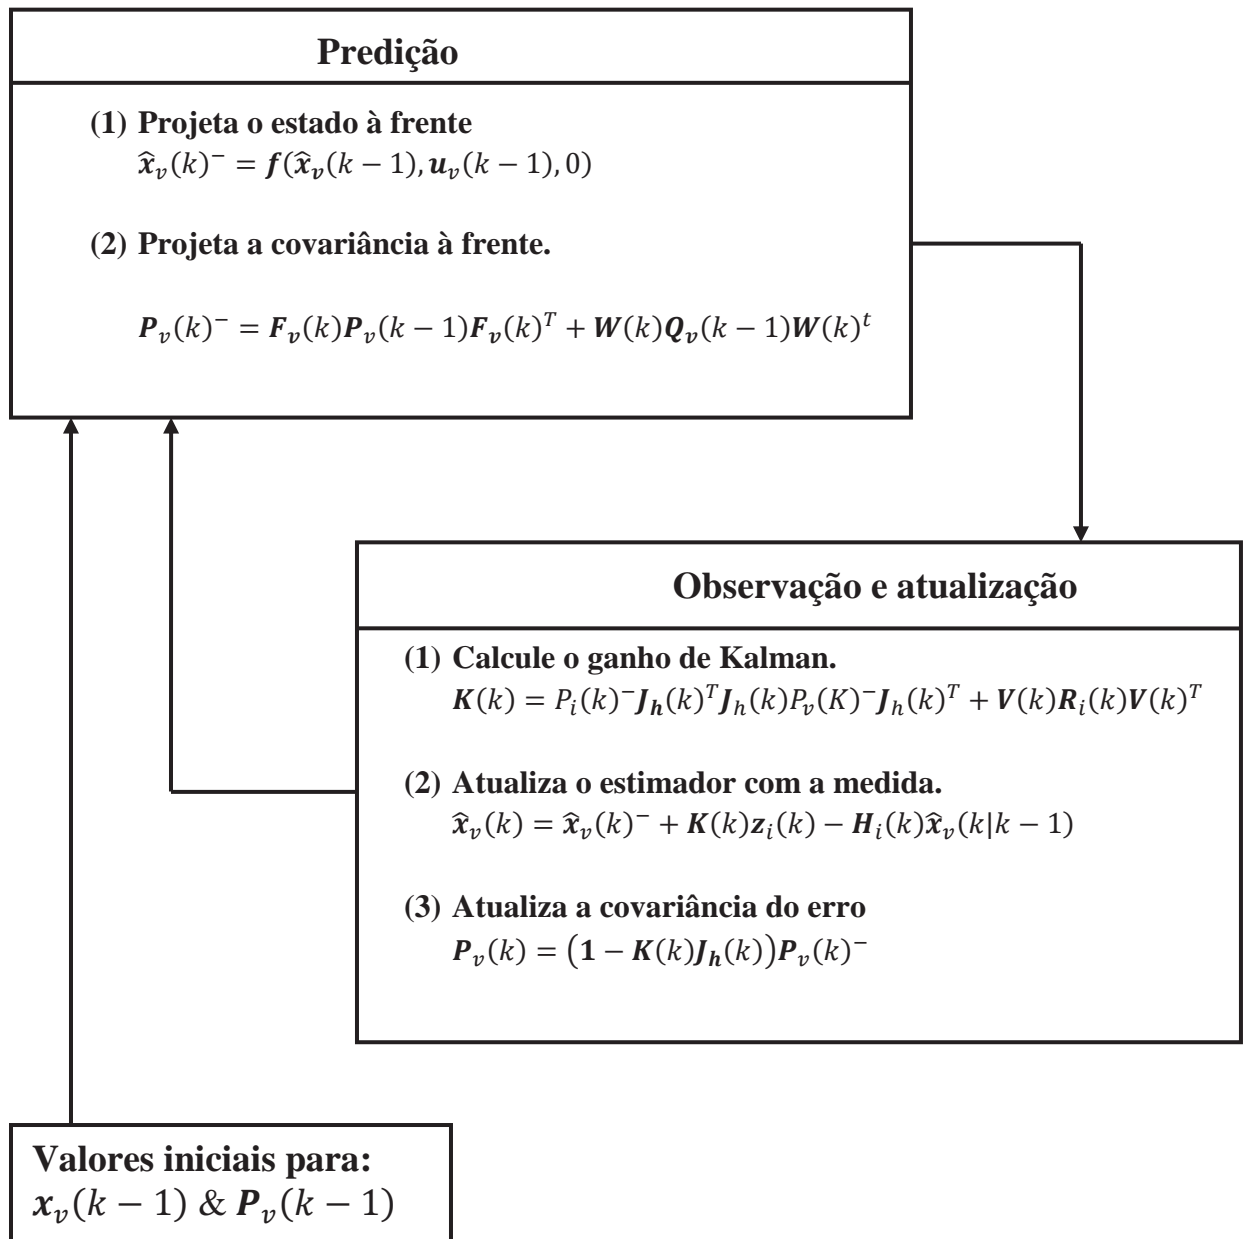


Figura 3. 5. Seqüência em bloco do funcionamento do fluxo dos dados no Filtro de Kalman Estendido.

3.8.2 Limitações do Filtro de Kalman Estendido

O EKF possui limitações. Ele apresenta certa dificuldade para administrar eficazmente ambigüidades na associação de dados. Desta forma, ambientes dinâmicos, atravancados, ou que apresentem semelhanças estruturais podem ser problemas complexos para este filtro. Assim sendo o EKF pode ser frágil, e falhar catastroficamente em algumas situações, já que só lida com distribuições unimodais (distribuições que possuem apenas um máximo local). Além do mais, o processo de linearização dos modelos pode corromper as estatísticas (Trun, 2002).

3.9 CONSIDERAÇÕES FINAIS

Neste capítulo, foram apresentados os conceitos das ferramentas utilizadas no desenvolvimento do trabalho. Dentre as ferramentas está o filtro de Kalman e filtro de Kalman Extendido, utilizado para realizar o SLAM. Na Figura 3.5 é demonstrado a sequência do funcionamento do Filtro de Kalman Estendido que foi utilizado na simulação do robô proposto neste trabalho.

Capítulo 4

4. MATERIAIS E MÉTODOS

Nesse capítulo é apresentada a descrição do Mapa do ambiente, a ferramenta de desenvolvimento dos aplicativos utilizados, o estudo de caso, o sensor de ultra-som utilizado, o sistema de simulação e o modelo do Robô que foram usados nos ensaios e simulações para o desenvolvimento deste trabalho.

4.1 MAPA DO AMBIENTE E O ESTUDO DE CASO PROPOSTO

Nas Figuras 4.1 e 4.2, é mostrado o ambiente industrial com tornos comuns e tornos com CNC onde são fabricadas as peças mecânicas que serviu como modelo de simulação para navegação do robô, onde foram feitos os testes do algoritmo do Filtro de Kalman Estendido usado para o mapeamento e localização simultâneos do robô.

O robô proposto tem possibilidade de navegar por todo ambiente sem nenhuma sinalização artificial para sua orientação.




Figura 4. 1. Visão geral do mapa do ambiente de navegação do robô.

Fonte: SENAI - L. Paulista

Com uso da técnica do Filtro de Kalman Estendido para o mapeamento e a localização do robô simultaneamente, tal método evita o uso de trabalho externo na alteração da infraestrutura para navegação do robô.

É apresentada também neste capítulo uma solução para o problema do SLAM que faz uso de um sensor de ultra-som para encontrar os *landmarks*.

O uso de sistemas de ultra-som permite a localização de *landmark* naturais do ambiente.

O estudo de caso que foi utilizado para simulação, é mostrado na figura abaixo onde o robô (trapézio amarelo) seguirá o caminho representado pela linha marrom utilizando os *landmarks* naturais (estrelas), ou seja, os cantos das máquinas para se orientar e navegar no ambiente.

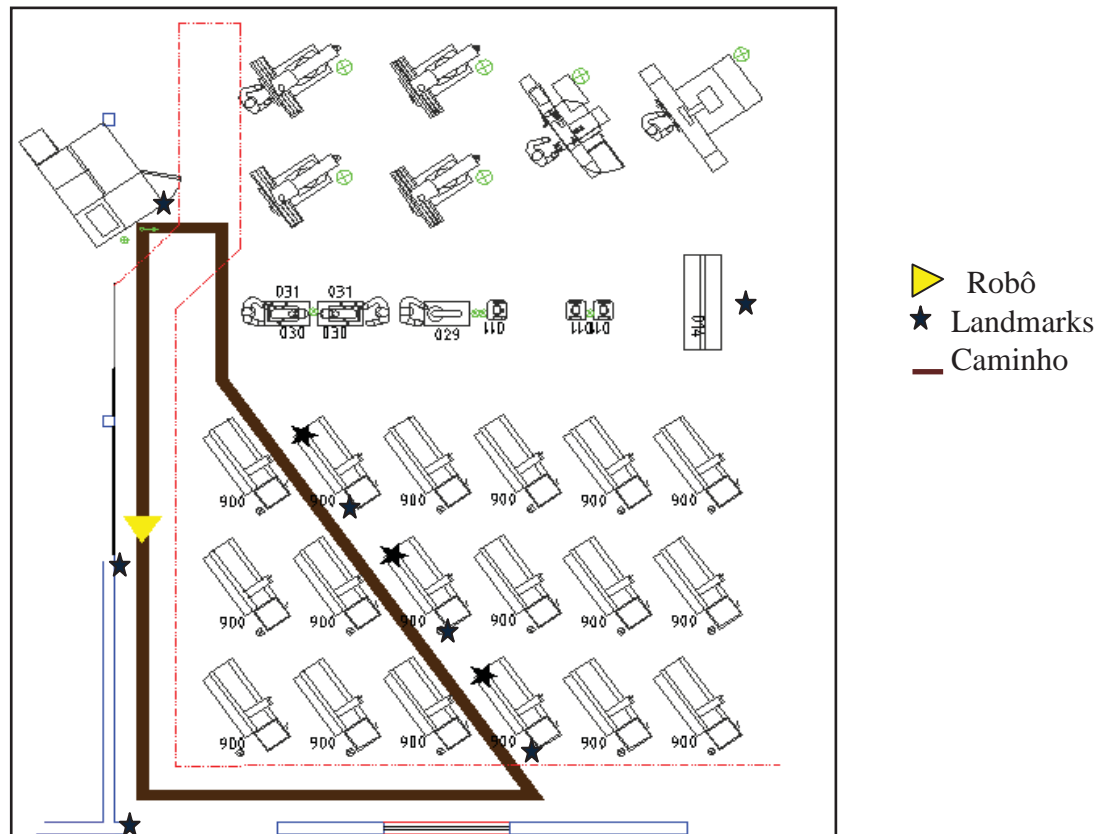


Figura 4. 2. Trajetória do ambiente estudado na simulação.

Fonte: SENAI - L. Paulista

4.2 MODELO DO ROBÔ UTILIZADO NA SIMULAÇÃO E NOS TESTES EM AMBIENTES REAIS

O diagrama de blocos do robô móvel utilizado neste trabalho como modelo é mostrado na Figura 4.3. Na Figura 4.4 é mostrado o diagrama de blocos do robô que foi construído para uso nos testes. A movimentação é efetuada através de duas rodas dianteiras operando em modo diferencial.



Figura 4. 3. Foto do Robô móvel usado nos ensaios e teste deste trabalho.

Fonte: SENAI - L. Paulista

Cada roda possui um *encoder* e um controlador inteligente para o motor de passo que permite controlar e medir sua velocidade angular. Na parte traseira existe uma terceira roda de apoio, que gira livremente.




Figura 4. 4. Robô móvel usado neste trabalho na forma de diagrama de blocos.

Fonte: SENAI - L. Paulista

O desenho do projeto em CAD do robô móvel que foi construído para ser utilizado nos testes em situações reais é mostrado na Figura 4.5. O processo de modelagem segue como descrito em Nebot (2002).



Figura 4. 5. Desenho em CAD do Robô móvel usado neste trabalho.

Fonte: SENAI - L. Paulista

4.3 AS EQUAÇÕES DA CINEMÁTICA DO ROBÔ

As equações do robô são definidas a partir de um veículo com um modelo cinemático conhecido que se move através de um ambiente contendo uma população de *landmarks* e é equipado com um sensor com a possibilidade de tomar medidas da posição relativa entre algum *landmark* individual e o veículo, como foi mostrado no capítulo 3 Figura 3.4. Em (NEBOT, 2002), como citado anteriormente, são proposto dois modelos:

- Modelo de processo;
- Modelo de observação.

Como descrito no capítulo três, tais modelos são propostos para minimizar o problema do SLAM que surge quando ambos os problemas apresentados de localização e mapeamento precisam ser resolvidos simultaneamente, pois o robô não conta com informações precisas referentes a nenhum deles.

Um mapa impreciso não será capaz de gerar uma estimativa precisa de localização, que por sua vez aumentará a incerteza de mapeamento. É necessário lidar com ambos os problemas simultaneamente, e os modelos propostos tentam minimizar globalmente as incertezas envolvidas.

4.4 MODELO DO SISTEMA DO RÔBO

Para calcular o modelo do sistema do Robô são necessárias algumas informações para a estimação do estado do robô por filtro de Kalman Estendido, ou seja, utiliza-se a postura inicial do robô, a incerteza inicial e o conhecimento sobre os modelos de movimento e de observação.

É demonstrado a seguir o modelo do sistema do Robô com *landmarks* utilizado na simulação onde são descritas as equações da cinemática proposta neste trabalho.

4.4.1 As equações da cinemática do robô

Dadas as entradas de controle $\mathbf{u}_v(k)$, que são obtidas através da odometria e $\mathbf{x}_v(k)$ que é o vetor de estado do robô no tempo k , pode-se calcular o $\mathbf{x}_v(k + 1)$ estimado, ou seja, a posição estimada do robô no tempo k .

Sendo $\mathbf{u}_v(k)$ representado, com base nas informações do sistema sensorial, por:

$$\mathbf{u}_v(k) = \begin{bmatrix} D(k) \\ \theta(k) \end{bmatrix} \quad (4.1)$$

Onde D é a medida do sensor de deslocamento (encoder) e θ é a orientação do sensor no tempo k , usados para estimar a posição do veículo em tempo $(k + 1)$. A Figura 4.6 apresenta a representação do sistema de coordenadas usado pelas equações da cinemática do robô:

$$\dot{x} = V \cos \theta \quad (4.2)$$

$$\dot{y} = V \sin \theta \quad (4.3)$$

$$\dot{\theta} = V \tan \theta \quad (4.4)$$

$$\begin{bmatrix} x(k+1) \\ y(k+1) \\ \theta(k+1) \end{bmatrix} = \begin{bmatrix} x(k) + D(k) \cos \theta(k) \\ y(k) + D(k) \sin \theta(k) \\ \theta(k) + D(k) \tan \theta(k) \end{bmatrix} + \mathbf{v}_v(k) \quad (4.5)$$




Figura 4. 6. Representação do sistema de coordenadas do veículo.

4.4.2 Landmark

Conforme descrito no capítulo dois, para localização do robô em ambientes que podem ser estruturados ou desestruturados utilizam-se os *landmarks* que são elementos externos ou internos.

As informações presentes no ambiente que podem ser caracterizadas como *landmarks* dependem do sensor utilizado pelo robô para adquirir os dados e do algoritmo de processamento adotado para interpretar esses dados de acordo com Figura 4.7.

A localização do *landmark* é representado por \mathbf{p}_i . O *SLAM* considera que todos os pontos de referência (*landmark*) são estacionários.




Figura 4. 7. A observação simultânea de dois landmarks por um robô móvel com representação do sistema de coordenadas.

Fonte: NEWMAN, 1999

No algoritmo de SLAM, *landmarks* são considerados estacionários. Por isso,

$$p_i(k+1) = p_i(k) \quad (4.6)$$



$$\begin{bmatrix} x_i(k+1) \\ y_i(k+1) \end{bmatrix} = \begin{bmatrix} x_i(k) \\ y_i(k) \end{bmatrix} \quad (4.7)$$



$$\begin{bmatrix} x_1(k+1) \\ y_1(k+1) \end{bmatrix} = \begin{bmatrix} x_1(k) \\ y_1(k) \end{bmatrix} \quad (4.8)$$

4.4.3 Modelo do processo

O estado do sistema é constituído pela localização e orientação do veículo em relação a posição dos *landmarks*. O modelo de transição de estado do veículo é dado por $x_v(k)$ que representa o movimento do veículo (robô) através do ambiente de acordo com o robô da

Figura 3.4 do capítulo 3. A seguir temos o modelo geral do sistema do robô com um *landmark*:

$$\begin{bmatrix} x(k+1) \\ y(k+1) \\ \theta(k+1) \\ x_1(k+1) \\ y_1(k+1) \end{bmatrix} = \begin{bmatrix} x(k) + D(k) \cos \theta(k) \\ y(k) + D(k) \sin \theta(k) \\ \theta(k) + D(k) \tan \theta(k) \\ x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} v_{vx} \\ v_{vy} \\ v_{v\theta} \\ 0 \\ 0 \end{bmatrix} \quad (4.9)$$

4.4.4 Modelo de observação

O modelo de observação é quando um veículo é equipado com um sensor que pode tomar medidas da posição relativa entre algum *landmark* individual e o veículo. O sensor utilizado retorna a distância $r_i(k)$ e tendo a orientação $\theta_i(k)$ para um *landmark* i . Assim, o modelo de observação é:

$$\mathbf{z}_i(k) = h(\mathbf{x}_v(k), \mathbf{w}_i(k)) \quad (4.10)$$

Pode-se definir $\mathbf{z}_i(k)$ também como:

$$\mathbf{z}_i(k) = \begin{bmatrix} r_i(k) \\ \theta_i(k) \end{bmatrix} \quad (4.11)$$

$$r_i(k) = \sqrt{(x_i - x_r(k))^2 + (y_i - y_r(k))^2} + w_{r_i}(k) \quad (4.12)$$

$$\theta_i(k) = \arctan\left(\frac{y_i - y_r(k)}{x_i - x_r(k)}\right) - \theta_i(k) + w_{\theta_i}(k) \quad (4.13)$$

Onde:

- $\mathbf{z}_i(k)$ é a saída do sensor referente ao estado do vetor $\mathbf{x}_v(k)$ ao observar um *landmark*.
- $\mathbf{v}_v(k)$ é um vetor de erros de observação não correlacionado com média zero e variância $\mathbf{R}_i(k)$.

- h é uma função não-linear que relaciona a saída do sensor $z_i(k)$ do estado do vetor $\mathbf{x}_v(k)$ ao observar um *landmark*.
- $r_i(k)$ é a distância retornada pelo sensor.
- $\theta_i(k)$ é a orientação para um *landmark* i
- \mathbf{w}_i é o vetor de erro de ruído de observação com os elementos wr_i e $w\theta_i$

4.5 PROCESSO DE ESTIMAÇÃO DO FILTRO DE KALMAN EXTENDIDO (EKF)

Uma das extensões do filtro de Kalman aplicado a sistemas não lineares é o filtro de Kalman estendido (EKF). A idéia do EKF é linearizar as funções em torno da estimação corrente usando as derivadas parciais do processo e das funções de medição para calcular as estimações, mesmo em face de relações não lineares. Através da observação da variável denominada “variável de observação”, outra variável, não observável, denominada “variável de estado ou processo”, pode ser estimada. Através desses cálculos recursivos estima-se o estado $\mathbf{x}_v(k)$, que evolui de acordo com os modelos do processo e de observação.

O filtro segue por três estágios, conforme citado anteriormente:

1. Predição
2. Observação
3. Atualização

4.5.1 Predição

Após inicializar o filtro, estabelecendo valores para $\hat{\mathbf{x}}_v(k)$ e \mathbf{P}_v uma predição é gerada através do estado estimado a priori:

Estado predito:

$$\hat{\mathbf{x}}_v(k)^- = f(\hat{\mathbf{x}}_v(k-1), \mathbf{u}_v(k-1), 0) \quad (4.14)$$

Modelo de processo com *landmarks*:

$$\begin{bmatrix} x(k+1) \\ y(k+1) \\ \theta(k+1) \\ x_1(k+1) \\ y_1(k+1) \end{bmatrix} = \begin{bmatrix} x(k) + V(k) \cos \theta(k) \\ y(k) + V(k) \sin \theta(k) \\ \theta(k) + V(k) \tan \theta(k) \\ x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} v_{vx} \\ v_{vy} \\ v_{v\theta} \\ 0 \\ 0 \end{bmatrix} \quad (4.15)$$

Calcula-se também a incerteza $\mathbf{P}_v(k)$ associada à postura estimada do robô.

$$\mathbf{P}_v(k)^- = \mathbf{F}_v(k) \mathbf{P}_v(k-1) \mathbf{F}_v(k)^T + \mathbf{W}(k) \mathbf{Q}(k-1) \mathbf{W}(k)^T \quad (4.16)$$

Sendo $\mathbf{F}_v(k)$ a matriz do modelo de movimento linearizada,

$$\mathbf{F}_v(k) = \begin{bmatrix} \frac{\partial f_1}{\partial x} & \frac{\partial f_1}{\partial y} & \frac{\partial f_1}{\partial \theta} & \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial y_1} \\ \frac{\partial f_2}{\partial x} & \frac{\partial f_2}{\partial y} & \frac{\partial f_2}{\partial \theta} & \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial y_1} \\ \frac{\partial f_3}{\partial x} & \frac{\partial f_3}{\partial y} & \frac{\partial f_3}{\partial \theta} & \frac{\partial f_3}{\partial x_1} & \frac{\partial f_3}{\partial y_1} \\ \frac{\partial f_4}{\partial x} & \frac{\partial f_4}{\partial y} & \frac{\partial f_4}{\partial \theta} & \frac{\partial f_4}{\partial x_1} & \frac{\partial f_4}{\partial y_1} \\ \frac{\partial f_5}{\partial x} & \frac{\partial f_5}{\partial y} & \frac{\partial f_5}{\partial \theta} & \frac{\partial f_5}{\partial x_1} & \frac{\partial f_5}{\partial y_1} \end{bmatrix} = \begin{bmatrix} 1 & 0 & -D(k) \sin \theta(k) & 0 & 0 \\ 0 & 1 & D(k) \cos \theta(k) & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (4.17)$$

Sendo $\mathbf{W}(k)$ matriz de linearização de ganho do processo de estimação.

$$\mathbf{W}(k) = \begin{bmatrix} \frac{\partial f_1}{\partial w_x} & \frac{\partial f_1}{\partial w_y} & \frac{\partial f_1}{\partial w_\theta} & \frac{\partial f_1}{\partial w_{x_1}} & \frac{\partial f_1}{\partial w_{y_1}} \\ \frac{\partial f_2}{\partial w_x} & \frac{\partial f_2}{\partial w_y} & \frac{\partial f_2}{\partial w_\theta} & \frac{\partial f_2}{\partial w_{x_1}} & \frac{\partial f_2}{\partial w_{y_1}} \\ \frac{\partial f_3}{\partial w_x} & \frac{\partial f_3}{\partial w_y} & \frac{\partial f_3}{\partial w_\theta} & \frac{\partial f_3}{\partial w_{x_1}} & \frac{\partial f_3}{\partial w_{y_1}} \\ \frac{\partial f_4}{\partial w_x} & \frac{\partial f_4}{\partial w_y} & \frac{\partial f_4}{\partial w_\theta} & \frac{\partial f_4}{\partial w_{x_1}} & \frac{\partial f_4}{\partial w_{y_1}} \\ \frac{\partial f_5}{\partial w_x} & \frac{\partial f_5}{\partial w_y} & \frac{\partial f_5}{\partial w_\theta} & \frac{\partial f_5}{\partial w_{x_1}} & \frac{\partial f_5}{\partial w_{y_1}} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (4.18)$$

4.5.2 Observação

Seguindo a predição, uma observação $\mathbf{z}_i(k+1)$ do i -ésimo *landmark* é feita utilizando o modelo de observação. No momento k , é feita uma medida $\mathbf{z}_i(k)$ do estado real $\mathbf{x}_v(k)$.

Ganho ótimo de Kalman $\mathbf{K}(k)$ é feita de acordo com:

$$\mathbf{K}(k) = \mathbf{P}_v(k)^- \mathbf{J}_h(k)^T (\mathbf{J}_h(k) \mathbf{P}_v(k)^- \mathbf{J}_h(k)^T + \mathbf{V}(k) \mathbf{R}_i(k) \mathbf{V}(k)^T)^{-1} \quad (4.19)$$

Onde:

Modelo de observação $z_i(k)$.

$$\mathbf{z}_i(k) = \begin{bmatrix} r_i(k) \\ \theta_i(k) \end{bmatrix} = \begin{bmatrix} \sqrt{(x_i - \hat{x}(k)^-)^2 + (y_i - \hat{y}(k)^-)^2} \\ \tan^{-1} \left(\frac{y_i - \hat{y}(k)^-}{x_i - \hat{x}(k)^-} \right) - \hat{\theta}(k)^- \end{bmatrix} + \mathbf{w}_i(k) \quad (4.20)$$

Matriz jacobiana das derivadas parciais de h , em função de \mathbf{x} ;

$$\mathbf{J}_h(k) = \begin{bmatrix} \frac{\partial h_1}{\partial x} & \frac{\partial h_1}{\partial y} & \frac{\partial h_1}{\partial \theta} & \frac{\partial h_1}{\partial x_1} & \frac{\partial h_1}{\partial x_2} \\ \frac{\partial h_2}{\partial x} & \frac{\partial h_2}{\partial y} & \frac{\partial h_2}{\partial \theta} & \frac{\partial h_2}{\partial x_1} & \frac{\partial h_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} \frac{x-x_i}{r} & \frac{y_i-y}{r} & 0 & \frac{x-x_i}{r} & \frac{y_i-y}{r} \\ \frac{y_i-y}{r^2} & \frac{x-x_i}{r^2} & -1 & \frac{y_i-y}{r^2} & \frac{x-x_i}{r^2} \end{bmatrix} \quad (4.21)$$

Onde r é distancia entre o robô e o *landmark* onde (x, y) localização do robô e (x_i, y_i) localização do *landmark*.

$$r = \sqrt{(x_i - x)^2 + (y_i - y)^2} \quad (4.22)$$

Matriz jacobiana das derivadas parciais de h , em função de $\mathbf{w}_i(k)$.

$$\mathbf{V}(k) = \begin{bmatrix} \frac{\partial h_1}{\partial v_r} & \frac{\partial h_1}{\partial v_\theta} \\ \frac{\partial h_2}{\partial v_r} & \frac{\partial h_2}{\partial v_\theta} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad (4.23)$$

Onde a incerteza $\mathbf{P}_v(k)$ é considerada a equação 4.16.

4.5.3 Atualização de medição

A equação acima pode agora ser utilizada na atualização da medida no EKF. Onde \mathbf{H}_i é a matriz de observação e relaciona a medida $\mathbf{w}_i(k)$ ao vetor de estado $\mathbf{x}_v(k)$;

Estado atualizado:

$$\hat{\mathbf{x}}_v(k) = \hat{\mathbf{x}}_v(k)^- + \mathbf{K}(k) \boxed{(\mathbf{z}_i(k) - \mathbf{H}_i(k))} \longrightarrow \text{Inovação} \quad (4.24)$$

Covariância atualizada:

$$\mathbf{P}_v(k) = (1 - \mathbf{K}(k)\mathbf{J}_h(k))\mathbf{P}_v(k)^- \quad (4.25)$$

Agora, se o *landmark* é observado em $t(k+1)$, o modelo de estado é atualizado

$$\begin{bmatrix} x(k+1) \\ y(k+1) \\ \theta(k+1) \\ x_1(k+1) \\ y_1(k+1) \end{bmatrix} = \begin{bmatrix} x(k) + D(k)\cos\theta(k) \\ y(k) + D(k)\sin\theta(k) \\ \theta(k) + D(k)\tan\theta(k) \\ x_1 \\ y_1 \end{bmatrix} + \begin{bmatrix} \mathbf{v}_{vx} \\ \mathbf{v}_{vy} \\ \mathbf{v}_{v\theta} \\ 0 \\ 0 \end{bmatrix} \quad (4.25)$$

$$x_1(k+1) = x(k) + r \cos \theta \quad (4.26)$$

$$y_1(k+1) = y(k) + r \sin \theta \quad (4.27)$$

4.6 SENSOR DE ULTRA-SOM

Sensor de ultra-som pertence à família dos sensores de alcance ativo. As primeiras aplicações foram na área marítima sendo utilizado como um instrumento de navegação auxiliar, de onde provém o outro nome com que também é conhecido, o de sonar, acrônimo das palavras em inglês *Sound Navigation and Ranging*. Ainda hoje é usado no estudo e pesquisa dos oceanos para determinar a profundidade ou depressões existentes no fundo do mar (LEONARD, 1992).

4.6.1 Funcionamento

De acordo com (LEONARD et al., 1992), os sensores de ultra-som têm a função de detectar ou medir a posição de determinado objeto através da emissão de pulsos de ultra-som. A superfície do alvo reflete o ultra-som, que retorna ao sensor como um eco. A variável medida é o tempo de trajeto (de ida e volta) do ultra-som entre a face do sensor e a superfície do objeto, cujo resultado é utilizado no cálculo da distância (levando-se ainda em conta que a

velocidade de propagação do ultra-som no ar é praticamente constante), na Figura 4.8 é indicado o local onde foi instalado o sensor de ultra-som.




Figura 4. 8. Foto do Robô móvel usado nos ensaios com o sensor de ultra-som.

Fonte: SENAI - L. Paulista

A faixa de medição mínima e máxima que o sensor (EZ-1) pode monitorar é de 1 a 6 m,. Já na área da robótica móvel, este sensor é muito utilizado para a detecção de obstáculos e para a construção de mapas a partir da exploração de ambientes. A razão de sua popularidade é seu baixo custo e a simplicidade da resposta que fornece, a qual consiste na distância que existe entre o sensor e o obstáculo presente no alcance deste. Nas Figuras 4.8 e 4.9 são mostradas as fotos do sensor de ultra-som (EZ-1,) usado neste trabalho.



Figura 4. 9. Foto do sensor de ultra-som (EZ-1) usado neste trabalho.

Características do Feixe

A detecção de pessoas requer alta sensibilidade. Ainda que um feixe estreito requeira baixa sensibilidade. O LV-MaxSonar®-EZ1™ combina de detecção de pessoas com um feixe de largura estreita.

Exemplos de medição são mostrados abaixo em um grid de 12 polegadas. O padrão de detecção é mostrado para:

- (A) Pino de 0.25 polegadas de diâmetro, veja o ângulo estreito para objetos pequenos.
- (B) Pino de 1 polegada de diâmetro, veja o padrão longo de detecção.
- (C) Tubo de 3.25 polegadas de diâmetro, veja o padrão longo e controlado de detecção.
- (D) Placa de 11 polegadas de largura movimentada de esquerda para a direita, paralela ao sensor e o sensor parado. Esta figura mostra a capacidade do sensor.

Note: The displayed beam width of (D) is a function of the specular nature of sonar and the shape of the board (i.e.


flat mirror like) and should never be confused with actual sensor beam width.

5V
3.3V


A



B



C



20 ft.
15 ft.
10 ft.
5 ft.

beam characteristics are approximate

Figura 4. 10. Padrão de propagação do sinal do sensor de ultra-som.

Através do diagrama na Figura 4.10, pode-se verificar o funcionamento de sensores deste tipo. Especificamente o sensor de ultra-som, segundo (LEONARD et al 1992), é um sensor de alcance ativo em tempo de voo, ou seja, usa a velocidade de propagação do sinal de ultra-som para calcular a distância entre o sensor e o objeto atingido.

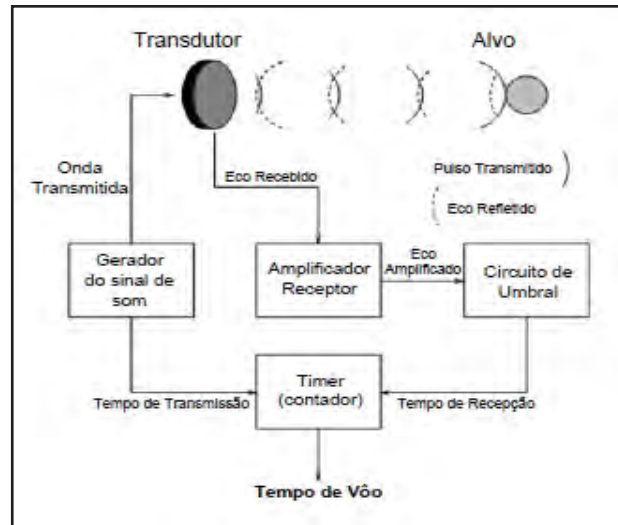


Figura 4. 11. Diagrama de bloco de um sensor de ultra-som.

Fonte: LEONARD (1992)

Portanto, a distância d entre o sensor e a fonte de reflexão (objeto atingido) pode ser calculada usando o tempo de vôo t e a velocidade de propagação do sinal de som, assim:

$$d = \frac{c \cdot t}{2} \quad (4.29)$$

A uma pressão ambiente normal e a uma temperatura aproximadamente igual aos 20°C, a velocidade de propagação do som c é aproximadamente igual a 343 m/s. Através de um servo motor, pode-se obter o posicionamento do sonar de 1 em 1 grau, totalizando uma varredura de 180 graus. A cinemática do robô é importante, pois pelo fato de ter as rodas de tração sobre o eixo que contém o centro de massa, pode-se girar sem alterar sua posição. Um fator que deve ser levado em conta é a velocidade da leitura dos sonares. Entre cada ciclo de leitura é necessário destinar um tempo de espera para que o eco do sinal retorne. O tempo destinado deve ser suficiente para que um eco de um objeto localizado no limite do alcance do sonar retorne.

4.6.2 Erros típicos do sensor

Como todos os sensores, o sonar possui algumas desvantagens que comprometem seu desempenho. Tipicamente, um sistema de sensoriamento baseado em sensores de ultra-som pode sofrer imprecisões nas leituras de distância, causados principalmente por erros relacionados com o circuito do transdutor, ou devido às características dos alvos a serem atingidos (LEONARD et al, 1992).

4.7 Modelo de predição para leituras do sonar

Alguns pesquisadores rejeitam o uso do sonar, devido aos erros que são gerados durante o processo de navegação do robô (DRUMHELLER, 1987). No entanto, estes erros devem-se essencialmente à falta de um modelo adequado capaz de fazer as predições de leituras de forma adequada (LEONARD, 1992). O modelo aqui apresentado baseia-se nos trabalhos realizados por Leonard (1992). Para iniciar a definição do modelo de predição das leituras do sonar é necessário definir que tipos de obstáculos do ambiente são relevantes sob o ponto de vista do sonar e que tipos de ecos produzem.

4.7.1 Modelamento dos alvos

Definição de alvo é todo o objeto característico do ambiente capaz de ser observado pelo sensor de ultra-som do robô. Sendo capaz de retornar ecos com uma medição referente à distância dos objetos, dada a posição do sonar. No modelo aqui apresentado, considera-se que o ambiente pode ser descrito por quatro tipos de alvos geométricos: planos, cantos, quinas e cilindros. Os alvos são divididos em duas categorias: os que produzem ecos especulares e os que produzem ecos difusos, de acordo com o tipo de reflexão que cada alvo. Os planos, cantos e cilindros produzem ecos especulares, enquanto as quinas produzem ecos difusos. A seguir é descrito a geometria de cada tipo de alvo o , caracterizada pelo vetor de parâmetros p_o , bem como pelo modelo de predição das leituras dos objetos. Nas Figuras a seguir, supõe-se que as leituras são feitas a partir de um sonar colocado na posição $(x_s(k), y_s(k), \alpha_s(k))$, onde α_s é o ângulo entre o eixo do sonar e a horizontal, $\hat{r}(k)$ que representa a distância mínima prevista entre o sonar e o alvo, $\phi_s(k)$.

O ângulo de visibilidade do alvo α , β_0 , corresponde ao valor da amplitude do cone dentro do qual a orientação do sonar tem de estar apontada de forma a retornar um eco válido. Este cone é definido por cone de visibilidade do alvo. Qualitativamente, o valor de β_0 é determinado pela capacidade de reflexão de energia acústica do alvo α . Quanto mais forte é o alvo, em termos de reflexão acústica, maior será o ângulo de visibilidade do mesmo. Calcular esse valor de forma precisa na prática torna-se complexo, uma vez que é extremamente dependente do circuito eletrônico do sonar. O que usualmente se faz para contornar esse problema é impor um limite superior para o seu valor, em vez de calculá-lo. Normalmente é usado um valor para β_0 igual para todos os alvos, cerca de 10° . O sonar é representado nas figuras por um retângulo escuro.

Plano:

É representado por uma linha e é caracterizado pelo vetor de parâmetros $p_\alpha = (p_R, p_\theta)$ e pelos pontos extremos da linha. p_R que representa a distância da reta orientada à origem do sistema de coordenadas que é medida na perpendicular, enquanto p_θ representa o ângulo perpendicular a reta de origem com a horizontal, compreendido entre os ângulos de 0° e 360° (figura 4.11).




Figura 4. 12. Alvo Plano

Fonte: LEONARD (1991)

À distância e o ângulo previstos são dados pelas equações:

$$\hat{r}(k) = p_r + x_s(k) \sin(p_\theta - \pi/2) - y_s(k) \cos(p_\theta - \pi/2) \quad (4.30)$$

$$\phi_s = p_\theta \quad (4.31)$$

Canto:

É representado por uma superfície côncava e é caracterizado pelo vetor de parâmetros $p_o = (p_x, p_y)$, onde p_x e p_y traduzem a sua posição cartesiana (Figura 4.12).




Figura 4. 13. Alvo canto.

Fonte: LEONARD , 1991

À distância e o ângulo previstos são dados pelas equações:

$$\hat{r}_s(k) = \sqrt{(p_x - x_s(k))^2 + (p_y - y_s(k))^2} \quad (4.32)$$

$$\phi_s(k) = \arctan\left(\frac{p_y - y_s(k)}{p_x - x_s(k)}\right) \quad (4.33)$$

Quina:

É representada por uma superfície convexa, como o canto, é caracterizada pelo vetor de parâmetros $p = (p_x, p_y)$, onde p_x e p_y traduzem a sua posição cartesiana (Figura 4.13). Pelo fato dos ecos gerados serem difusos, a energia das ondas é espalhada em várias direções, dando uma maior atenuação ao eco. Esta atenuação é proporcional a, $\sqrt{\frac{1}{\hat{r}_s(k)}}$. Logo as quinas provocam uma atenuação da energia do sinal superior aos alvos especulares, por isso são perceptíveis de posições próximas da sua localização.




Figura 4. 14. Alvo Quina

Fonte: LEONARD (1991)

A distância e o ângulo previstos são, da mesma forma, dados pelas equações (4.32) e (4.33).

Cilindro:

É representado por um arco circular e é caracterizado pelo vetor de parâmetros $p_o = (p_x, p_y, p_R)$ onde, p_x e p_y , são as coordenadas cartesianas do centro do círculo e p_R o raio do mesmo (Figura 4.14). Assume-se que o raio do círculo é maior que o comprimento de onda do sinal emitido pelo sonar, caso contrário não haveria reflexão.




Figura 4. 15. Alvo cilindro

Fonte: LEONARD (1991)

O ângulo previsto é dado pela equação (4.33), enquanto a distância é dada pela equação:

$$\hat{r}_s(k) = \sqrt{(p_x - x_s(k))^2 + (p_y - y_s(k))^2} - p_R \quad (4.34)$$

Este conjunto de equações, de (4.30) a (4.34), constitui um modelo matemático, desenvolvido geometricamente, que permite, dada a posição do sonar, determinar a distância e ângulo de cada tipo de alvos que é medido pelo sensor.

4.7.2 Algoritmo para selecionar os objetos do ambiente

O algoritmo proposto seleciona a partir da observação real entre os objetos do ambiente, aquele cuja orientação do sonar se encontra dentro do seu cone de visibilidade, à menor distância e cuja posição do sonar se encontra dentro da zona de visibilidade do alvo. A seguir é descrito a sequência do algoritmo proposto:

1 - Sonar

1. 1.1 Para todos os planos

1.1.1 Verificar se a orientação do sonar $\alpha_s(k)$, está dentro do cone de visibilidade do plano: $p_\theta - 10^\circ \leq \alpha_s(k) \leq p_\theta + 10^\circ$

1.1.2 Verificar se a posição do sonar $(x_s(k), y_s(k))$ está dentro da zona de visibilidade do plano.

1.1.3 No caso do eco ser válido, calcula a distância do sonar ao plano, $\hat{r}(k)$ de acordo com a equação (4.30).

1.2 Para todos os cantos, quinas e cilindros:

1.2.1- Calcular $\phi_s(k)$ usando equação (4.32)

1.2.2- Verificar se $\alpha_s(k)$, a orientação do sonar, está dentro do cone visibilidade do alvo: $\phi_s(k) - 10^\circ \leq \alpha_s(k) \leq \phi_s(k) + 10^\circ$

1.2.3- Verificar se a posição do sonar $(x_s(k), y_s(k))$ está dentro da zona de visibilidade do alvo.

1.2.4- No caso do eco ser válido, calcular a distância do sonar ao alvo, $\hat{r}_s(k)$, de acordo com equação (4.32) no caso dos cantos e das esquinas e de acordo com (4.34) no caso dos cilindros.

2- Escolher o menor eco válido, calculando o mínimo das distâncias $\hat{r}_s(k)$.

4.8 SIMULADOR EKF-SLAM

O simulador EKF SLAM conforme mostrado na Figura 4.15 é um ambiente para fins acadêmicos criado por Tim Bailey para implementação e simulação para o estudo do problema de SLAM usando o Filtro de Kalman Estendido (EKF) na navegação de robôs moveis. Também é possível criar os *landmarks* e os pontos de caminho para navegação do robô, pois fornece as ferramentas necessárias para criar o ambiente de simulação. Além disso, o programa EKF-SLAM tem sido projetado para suportar qualquer aplicação relacionada com a navegação de robôs e a partir de um tratamento no algoritmo pode-se adaptar o simulador para operações autônomas em ambientes reais. A linguagem utilizada na programação do simulador do EKF SLAM é o MATLAB da MATHWORKS.




Figura 4. 16. Representação do sistema de navegação do robô, simulado no EKF-SLAM .

4.9 SISTEMA DETECÇÃO POR MEIO DE SENSOR DE ULTRA-SOM PARA MEDIR A DISTÂNCIA ENTRE O ROBÔ E OS OBJETOS

O LabVIEW é uma ferramenta de programação criada pela National Instruments para facilitar a automação em atividades acadêmicas e industriais. Sendo o LabVIEW uma ferramenta de programação visual, os comandos e funções presentes em linguagens baseadas em texto (como Pascal e C, por exemplo) são substituídos por ícones e outras figuras interligadas de maneira semelhante a um diagrama em blocos como demonstrado na figura 4.12. E como o LabVIEW é uma linguagem gráfica de programação que usa ícones em vez de linhas de texto para criar aplicações. Em contraste com as linguagens de programação baseadas em texto, onde as instruções determinam execução de programa, o LabVIEW usa programação onde o fluxo de dados (dataflow) determina a forma da execução. A natureza de fluxo de dados do LabVIEW significa que qualquer código pode ter uma “ramificação” no fio ou uma sequência no diagrama de blocos. Em termos computacionais, isto é chamado “paralelismo implícito” porque não houve a necessidade de escrever o código especificamente para executar em paralelo; a linguagem gráfica LabVIEW gerencia um certo grau de paralelismo de maneira transparente. Com o uso da programação baseada em ícones, é possível um maior grau de abstração e desenvolvimento dos programas de forma mais rápida.

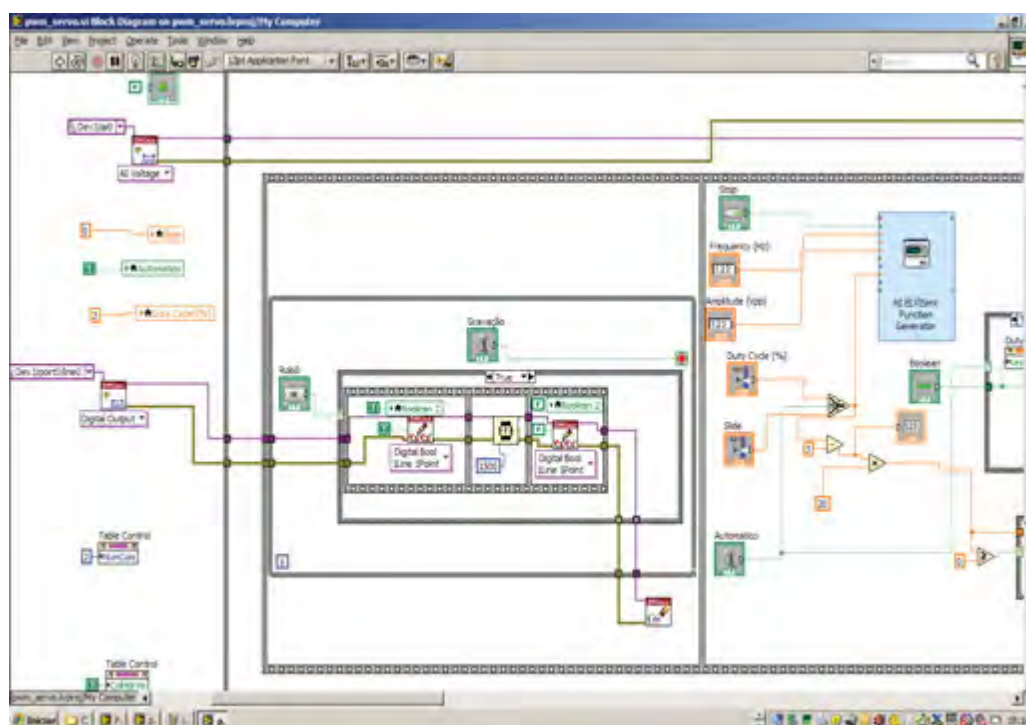


Figura 4. 17. Tela de controle do aplicativo feito Labview para aquisição de distância do sensor de ultra - som para detecção dos objetos.

4.9.1 Sistema de detecção desenvolvido

O sistema de detecção desenvolvido usa um sensor de ultra-som que é integrado a um computador (PC) por meio de uma placa de aquisição de dados programada com o software LabVIEW chamada de *MyDaq*. Desta forma, é possível a aquisição, armazenamento, processamento e visualização de objetos em tempo real. No sistema desenvolvido foram capturados sinais de ultra-som para medir a distância entre o robô e os objetos. Na Figura 4.17 e mostrado a tela do painel frontal do aplicativo de aquisição da medida de distância entre os objetos e o robô por meio do sensor de ultra - som .



Figura 4. 18. Tela do painel frontal do aplicativo de aquisição de distância do sensor de ultra-som para detecção dos objetos.

4.10 CONSIDERAÇÕES FINAIS

Mapa do ambiente, a ferramenta de desenvolvimento (Labview) dos aplicativos utilizados, o estudo de caso, o sensor de ultra-som, o sistema de simulação e o modelo do Robô foram descritos neste capítulo para o desenvolvimento dos testes e navegação do robô usando o algoritmo do Filtro de Kalman Estendido para o mapeamento e localização simultânea do robô. Para uso na simulação e navegação utilizou-se a integração, via filtro de Kalman, de dois sensores, odômetro com *encoders* e para medição das distâncias entre o Robô e os objetos foi utilizado um sensor de ultra-som.

Capítulo 5

5. RESULTADOS EXPERIMENTAIS

Visando testar a metodologia proposta, foram realizados vários experimentos, em ambiente de simulação. Os experimentos iniciais foram realizados usando a plataforma de simulação *EKF-SIM* para verificar o funcionamento do método de SLAM proposto neste trabalho. Os experimentos práticos foram realizados com dados reais de sonares e odometria tomados de aquisição das medidas pelo sensor de ultra-som pelo algoritmo desenvolvido na ferramenta *Labview* e processados em tempo de execução, ou seja, para um mapeamento online. Os testes práticos de navegação do robô realizados somente utilizando odometria servirão para validar a qualidade do robô construído.

5.1 SIMULAÇÃO DO ROBÔ NO CHÃO DE FÁBRICA

Na Figura 5.1, é mostrada a foto do ambiente industrial com tornos comuns e tornos com CNC onde são fabricadas as peças mecânicas que serviu como modelo de simulação para

navegação do robô, onde foram feitos os testes do algoritmo do Filtro de Kalman estendido usado para o mapeamento e localização simultâneos do robô.



Figura 5. 1. Foto do ambiente industrial com tornos comuns e tornos com CNC onde são fabricadas as peças mecânicas que serviu como modelo para a simulação.

Fonte: SENAI - L. Paulista

O robô construído, que serviu também como modelo de simulação, tem a possibilidade de navegar por todo ambiente sem nenhuma sinalização artificial para sua orientação, e é mostrado na Figura 5.2.



Figura 5. 2. Foto do robô construído que serviu como modelo para a simulação e coleta de dados experimentais.

Fonte: SENAI - L. Paulista

É mostrado na Figura 5.3 o ambiente industrial usado na simulação no qual foi utilizado como estudo de caso com a representação do ambiente com a localização dos tornos comuns e dos tornos com CNC .

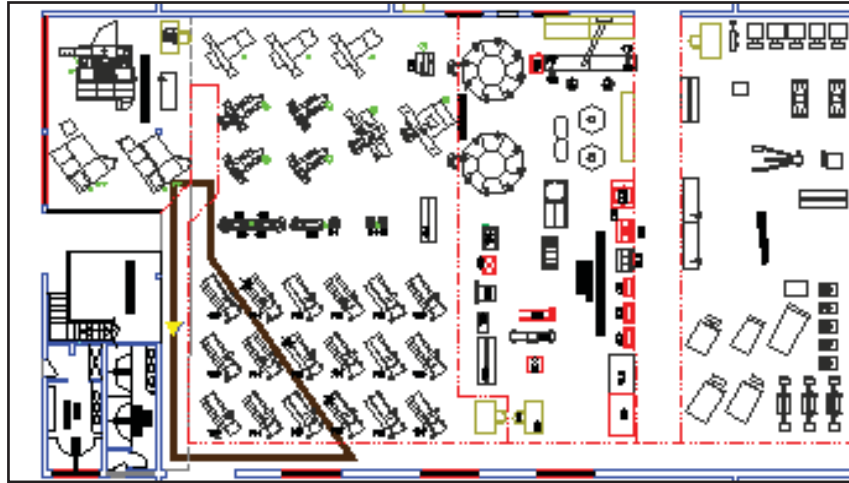


Figura 5. 3. Representação do ambiente industrial com a localização dos tornos comuns e tornos com CNC que serviu como modelo para simulação.

Fonte: SENAI - L. Paulista

Na Figura 5.4 é mostrado o caminho onde o robô (trapézio amarelo) seguirá o caminho representado pela linha marrom utilizando os *landmarks* naturais (estrelas), ou seja, os cantos das máquinas para se orientar e navegar no ambiente.




Figura 5. 4. Representação do ambiente industrial com a localização dos tornos comuns e tornos com CNC que serviu como modelo para simulação do caminho de navegação do robô.

5.2 SIMULAÇÃO DO ESTUDO DE CASO

A simulação feita no EKF-SIM foi realizada com a representação da Figura. 5.4, considerando também o modelo cinemático do robô da Figura 5.2 com o caminho da Figura 5.4, considerando os seguintes parâmetros para simulação:

- v : velocidade do robô em metros por segundo.
- $MAXG$: ângulo máximo de direção de varredura do sensor de ultra-som (180°) em radianos.
- $RATEG$: taxa de variação máxima do ângulo de direção em radianos por segundo.
- $WHEELBASE$: Distância entre as rodas traseiras e dianteiras do robô em cm.
- $DT_CONTROLS$: intervalo de tempo, entre os sinais de controle.

Parâmetros de controle usados na simulação:

- $v = 0.4$;
- $MAXG = 360 * \pi / 180$;
- $RATEG = 20 * \pi / 180$;
- $WHEELBASE = 0.3$ cm;
- $DT_CONTROLS = 0.025$;




Figura 5. 5. Trajetória de navegação do robô que foi simulado no EKF-SIM.

O ponto de origem da trajetória é na coordenada (0,0), onde está o centro de usinagem CNC. O robô deve caminhar para a coordenada (0,-20), perfazendo o trecho A e, em seguida, virar à esquerda, caminhando para a coordenada (10,-20), perfazendo o trecho B. Em seguida deve fazer uma curva de mais de 90 graus para a esquerda dirigindo-se para a coordenada (2,-6), perfazendo o trecho C. Por fim, deve caminhar para a coordenada (2,0), perfazendo o trecho D, retornando à origem (ponto O), que é o trecho E. O trecho C é o corredor dos tornos onde o robô poderá fazer paradas para alimentar ou recolher peças.

Uma segunda volta neste mesmo caminho é realizada para se avaliar a melhora das informações sobre a localização do robô no ambiente e os *landmarks*. A melhora é observada pelo valor das variâncias das variáveis de estado do robô x , y e θ . O robô possui 30 cm de comprimento e na velocidade de 0,4 m/s desempenhou uma trajetória com um erro muito pequeno. Para verificação dos limites do EKF na correção de trajetória, simulou-se o robô a uma velocidade de 3 m/s (que é a velocidade máxima do robô real), obtendo-se 1497 passos de simulação para análise, apresentados nas Figuras 5.6 e Figuras 5.7.

5.2.1 Resultados da simulação

Os resultados das Figuras. 5.6 e 5.7 mostram que o robô pode se locomover neste espaço sem se chocar com os maquinários e paredes do ambiente. O maior erro de trajetória ocorreu na curva fechada à esquerda logo após o ponto B, que chegou a quase 30 cm. Ao longo da trajetória, a observação dos *landmarks* vai aprimorando os valores de posicionamento tanto do robô como dos *landmarks*. Quanto mais tempo o robô ficava sem ver um landmark, sua incerteza ia aumentando. Normalmente após as curvas, novos landmarks eram observados e as variâncias começavam a cair. A segunda volta no ambiente (A2, B2, C2, D2) também demonstrou que os valores de variância ficaram menores. Desta forma os resultados foram positivos e serão realizados os trabalhos de implementação do robô projetado. A unidade de medida utilizado nos gráficos das Figuras 5.6, 5.7 e 5.8 é o cm.




Figura 5. 6. Erro de posição(em metros) em relação ao desejado durante a trajetória com 1497 passos de simulação (máx ~30 cm).




Figura 5. 7. Variância do ângulo de posicionamento teta (em graus) de orientação do robô ao longo dos 1497 passos de simulação.




Figura 5. 8. Variação da matriz de covariâncias do estado do robô. A curva vermelha que vai até 0,75 é a variância da variável de estado do robô x ; A curva azul com dois pequenos picos nos pontos B e B2 representa a variância da variável de estado do robô y ; a curva rasteira verde no gráfico representa a variância da variável de estado θ que também é a curva apresentada na Figura 5.7.

5.3 EXPERIMENTOS PRÁTICOS

Os experimentos práticos realizados com o robô são apresentados nesta seção. Assim, os testes foram agrupados em duas categorias:

- Avaliação das medidas de distância entre o robô e os objetos para construção do mapa do ambiente.
- Avaliação experimental da qualidade da construção do robô usando apenas as informações de odometria.

5.3.1 Avaliação Experimental da coleta de dados referente a medidas de distância para construção do mapa do ambiente

Neste passo, foram feitas 16 medidas do corredor trecho C da Figura 5.9, a partir da leitura do sensor de ultra-som (sonar) colocado na frente do robô, onde a cada 50 cm foram

coletadas 180 medidas do sensor de ultra-som em uma varredura de 180 graus relativo à parte frontal do robô. Na Figura 5.10 é demonstrado no diagrama polar o formato do ambiente a partir dos dados obtidos da tabela 5.1, referente a uma medida do corredor.

Neste trabalho o mapa é uma lista de *landmarks* (marcos) representados por $H = \{p_1; p_2; p_3...; p_i\}$, em que cada elemento possui uma localização global, designada por $p_{i,x}$ e $p_{i,y}$. A matriz H do mapa é preenchida com as medidas z_i referentes às distâncias dos objetos do ambiente. As distâncias são obtidas através do sensor de ultra-som que correspondem às 180 medidas de observações dos *landmarks* feitas a cada 50 cm de movimento do robô encontrados no ambiente. A tabela 5.1 contém as 180 medidas de distância que representam o ambiente de navegação do robô.



Figura 5. 9. Corredor de onde os dados foram obtidos a partir da leitura do sensor de ultra-som (sonar) colocado na frente do Robô, a cada 50 cm com 180 medidas do sensor de ultra-som em uma varredura de 180 graus relativo a parte frontal do robô, para construção do mapa do ambiente.

Fonte: SENAI - L. Paulista




Figura 5. 10. . Leitura do sensor de ultra-som (sonar) colocado na frente do Robô, em uma varredura de 180 graus relativo a parte frontal do robô é demonstrado no diagrama polar o formato do ambiente a partir dos dados obtidos.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	32,30	30	34,73	60	45,00	90	140,80	120	110,65	150	646,38
1	32,55	31	34,81	61	42,33	91	135,37	121	110,73	151	645,79
2	32,55	32	34,98	62	42,41	92	133,37	122	110,57	152	646,46
3	32,39	33	34,64	63	42,41	93	130,95	123	110,82	153	608,96
4	32,39	34	34,73	64	42,58	94	131,11	124	113,24	154	646,46
5	32,39	35	34,89	65	57,61	95	131,11	125	113,24	155	646,55
6	32,39	36	34,89	66	57,61	96	130,78	126	113,24	156	645,71
7	32,22	37	35,06	67	57,61	97	131,03	127	113,24	157	645,79
8	32,14	38	39,99	68	57,61	98	113,16	128	113,16	158	378,43
9	32,30	39	39,74	69	57,78	99	113,32	129	113,32	159	378,60
10	32,47	40	37,40	70	57,53	100	113,41	130	146,15	160	375,26
11	32,47	41	37,32	71	57,70	101	113,16	131	146,15	161	378,35
12	32,47	42	36,98	72	57,53	102	113,07	132	154,17	162	376,18
13	32,47	43	37,40	73	57,70	103	112,99	133	166,36	163	378,26
14	32,22	44	37,57	74	57,61	104	113,32	134	166,36	164	375,84
15	32,05	45	37,48	75	57,86	105	113,07	135	166,36	165	375,67
16	34,64	46	38,48	76	57,61	106	113,24	136	166,28	166	378,76
17	32,39	47	39,99	77	60,03	107	110,65	137	176,22	167	378,18
18	32,47	48	39,82	78	60,20	108	110,73	138	176,30	168	339,34
19	32,47	49	39,65	79	60,03	109	111,90	139	176,63	169	257,32
20	32,30	50	40,16	80	87,85	110	113,24	140	189,16	170	378,01
21	32,22	51	40,07	81	88,18	111	110,65	141	189,16	171	375,34
22	32,22	52	39,90	82	135,96	112	110,65	142	189,75	172	257,49
23	32,39	53	39,99	83	135,87	113	110,57	143	586,41	173	257,40
24	32,55	54	39,90	84	135,79	114	110,57	144	586,57	174	254,56
25	34,98	55	39,99	85	135,96	115	110,73	145	645,46	175	257,07
26	34,98	56	40,07	86	138,38	116	110,65	146	646,46	176	254,90
27	34,73	57	39,90	87	138,30	117	110,48	147	645,96	177	254,48
28	34,81	58	39,74	88	138,46	118	110,65	148	646,63	178	232,35
29	34,98	59	44,92	89	140,89	119	110,65	149	646,55	179	232,26

Tabela 5. 1. Tabela com os ângulos e medidas de distância obtidas pelo sensor de ultra-som (sonar) da medida 01.

A ferramenta utilizada para aquisição das medidas do sensor de ultra-som (sonar) foi desenvolvida no *software labview*. As medidas coletadas são armazenadas em uma matriz que contem o ângulo do sensor e a medida da distância. Depois de coletados as 180 medidas, são gravadas em um arquivo para geração de um gráfico do tipo radar. É mostrada na Figura 5.11 a tela do aplicativo desenvolvido para aquisição das medidas de distâncias obtidas através do sensor de ultra-som.



Figura 5. 11. Aplicativo desenvolvido para aquisição das medidas de distância obtidas através do sensor de ultra-som.

5.3.2 Resultados dos experimentos práticos do sensor de ultra-som

Neste passo, depois de coletadas as 16 medidas do corredor e gravadas em arquivo, os quais foram gerados os gráficos do tipo diagrama polar que foram sobrepostos com o caminho de navegação do robô são demonstrados nas Figuras 5.12 e 5.13. Foi observada a imprecisão da medição do sensor de ultra-som em alguns pontos, como por exemplo, a medida do corredor com mais de 6 metros referente à Figura 5.12. Com relação à Figura 5.13 observou-se uma maior imprecisão nas medições do sensor de ultra-som, já que a maioria das medições realizadas não representava o ambiente. Drumbeheller (1987) descreve em seu artigo sobre localização de robôs móveis usando sensores de ultra-som esse mesmo problema de imprecisão de medição com sensores de ultra-som. Já Leonard (1992) defende que essa incapacidade de medição se deve, genericamente, à falta de um modelo adequado capaz de prever as leituras do mesmo. De acordo com o trabalho de Leonard (1992) e Durrant-Whyte (1992), são propostos no capítulo 4 os modelos de predição necessários para definir que tipos de obstáculos do ambiente são relevantes sob o ponto de vista do sensor de ultra-som e que tipos de eco produzem.




Figura 5. 12. Diagrama polar sobreposto com o caminho de navegação do robô onde é observada a imprecisão de medição do sensor de ultra-som.




Figura 5. 13. Diagrama polar sobreposto com o caminho de navegação do robô onde é observado uma maior imprecisão nas medições do sensor de ultra-som, a maioria das medições realizadas não representam o ambiente do local onde robô está.

5.3.3 As medidas coletadas do ambiente

Para coletar as informações do corredor da Figura 5.9, é executada uma trajetória de exploração onde o módulo de sensoriamento (ultra-som) é ativado para adquirir as medições de distância dos objetos detectados. Foram feitas 16 medidas do corredor a partir da leitura do sensor de ultra-som colocado na frente do robô, onde a cada 50 cm é coletando 180 medidas do sensor de ultra-som em uma varredura de 180 graus relativo à parte frontal do robô, para construção do mapa do corredor. Todas as 16 medidas estão registradas nas tabelas abaixo com o seu diagrama polar.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 01											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	32,30	30	34,73	60	45,00	90	140,80	120	110,65	150	646,38
1	32,55	31	34,81	61	42,33	91	135,37	121	110,73	151	645,79
2	32,55	32	34,98	62	42,41	92	133,37	122	110,57	152	646,46
3	32,39	33	34,64	63	42,41	93	130,95	123	110,82	153	608,96
4	32,39	34	34,73	64	42,58	94	131,11	124	113,24	154	646,46
5	32,39	35	34,89	65	57,61	95	131,11	125	113,24	155	646,55
6	32,39	36	34,89	66	57,61	96	130,78	126	113,24	156	645,71
7	32,22	37	35,06	67	57,61	97	131,03	127	113,24	157	645,79
8	32,14	38	39,99	68	57,61	98	113,16	128	113,16	158	378,43
9	32,30	39	39,74	69	57,78	99	113,32	129	113,32	159	378,60
10	32,47	40	37,40	70	57,53	100	113,41	130	146,15	160	375,26
11	32,47	41	37,32	71	57,70	101	113,16	131	146,15	161	378,35
12	32,47	42	36,98	72	57,53	102	113,07	132	154,17	162	376,18
13	32,47	43	37,40	73	57,70	103	112,99	133	166,36	163	378,26
14	32,22	44	37,57	74	57,61	104	113,32	134	166,36	164	375,84
15	32,05	45	37,48	75	57,86	105	113,07	135	166,36	165	375,67
16	34,64	46	38,48	76	57,61	106	113,24	136	166,28	166	378,76
17	32,39	47	39,99	77	60,03	107	110,65	137	176,22	167	378,18
18	32,47	48	39,82	78	60,20	108	110,73	138	176,30	168	339,34
19	32,47	49	39,65	79	60,03	109	111,90	139	176,63	169	257,32
20	32,30	50	40,16	80	87,85	110	113,24	140	189,16	170	378,01
21	32,22	51	40,07	81	88,18	111	110,65	141	189,16	171	375,34
22	32,22	52	39,90	82	135,96	112	110,65	142	189,75	172	257,49
23	32,39	53	39,99	83	135,87	113	110,57	143	586,41	173	257,40
24	32,55	54	39,90	84	135,79	114	110,57	144	586,57	174	254,56
25	34,98	55	39,99	85	135,96	115	110,73	145	645,46	175	257,07
26	34,98	56	40,07	86	138,38	116	110,65	146	646,46	176	254,90
27	34,73	57	39,90	87	138,30	117	110,48	147	645,96	177	254,48
28	34,81	58	39,74	88	138,46	118	110,65	148	646,63	178	232,35
29	34,98	59	44,92	89	140,89	119	110,65	149	646,55	179	232,26

Tabela 5. 2. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 01.




Figura 5. 14. Diagrama polar da medida 01.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medição 02											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	37,40	30	37,40	60	90,44	90	171,62	120	70,14	150	131,53
1	37,23	31	37,65	61	90,35	91	171,46	121	70,39	151	143,48
2	37,23	32	37,40	62	95,62	92	171,62	122	70,22	152	143,14
3	37,48	33	37,48	63	88,02	93	171,46	123	70,06	153	140,89
4	37,32	34	37,57	64	42,49	94	136,21	124	70,22	154	323,39
5	37,40	35	39,99	65	42,74	95	169,03	125	70,39	155	143,64
6	37,40	36	39,90	66	98,12	96	168,28	126	70,31	156	143,73
7	37,48	37	39,90	67	95,53	97	135,96	127	70,22	157	645,54
8	37,57	38	40,16	68	95,53	98	135,96	128	70,31	158	630,34
9	37,06	39	90,35	69	93,11	99	136,13	129	70,22	159	645,79
10	37,32	40	93,19	70	92,86	100	135,96	130	70,31	160	353,12
11	37,48	41	92,86	71	92,94	101	115,49	131	70,22	161	372,33
12	37,48	42	93,11	72	95,45	102	115,66	132	70,22	162	363,31
13	37,57	43	93,11	73	95,53	103	115,66	133	70,22	163	362,64
14	37,23	44	92,94	74	95,53	104	115,66	134	70,22	164	320,72
15	37,57	45	92,78	75	95,37	105	87,76	135	70,39	165	344,69
16	37,57	46	90,27	76	95,62	106	87,85	136	70,39	166	373,59
17	37,40	47	92,86	77	93,03	107	88,18	137	70,22	167	373,50
18	37,40	48	90,35	78	93,03	108	87,93	138	70,06	168	373,00
19	37,48	49	90,69	79	93,03	109	87,85	139	70,22	169	373,42
20	37,32	50	90,60	80	92,94	110	88,02	140	70,31	170	373,17
21	37,48	51	90,69	81	92,94	111	88,02	141	70,31	171	373,34
22	37,48	52	90,52	82	95,37	112	88,02	142	70,31	172	373,34
23	37,57	53	90,60	83	95,78	113	88,02	143	70,22	173	373,25
24	37,23	54	90,35	84	292,48	114	87,93	144	70,31	174	373,67
25	37,40	55	87,85	85	290,06	115	98,04	145	70,31	175	373,59
26	37,48	56	87,93	86	105,64	116	97,54	146	131,03	176	370,66
27	37,57	57	88,18	87	104,97	117	70,39	147	131,11	177	373,17
28	37,48	58	90,44	88	171,29	118	70,47	148	130,70	178	373,34
29	37,57	59	90,44	89	171,71	119	70,14	149	130,95	179	358,97

Tabela 5. 3. Tabela com os ângulos e medidas de distância obtida pelo sensor de ultra-som (sonar) da medida 02.




Figura 5. 15. Diagrama polar da medida 02.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	47,59	30	57,61	60	52,52	90	253,56	120	67,64	150	44,83
1	47,59	31	55,02	61	52,43	91	255,15	121	67,80	151	45,00
2	47,51	32	55,19	62	52,60	92	254,81	122	67,72	152	44,83
3	47,59	33	55,11	63	52,52	93	256,90	123	67,72	153	44,83
4	47,51	34	54,86	64	52,52	94	156,76	124	67,72	154	44,83
5	47,17	35	55,11	65	52,43	95	156,09	125	60,28	155	44,92
6	47,67	36	54,77	66	52,52	96	134,12	126	60,03	156	45,00
7	47,76	37	54,86	67	52,68	97	133,70	127	60,03	157	44,92
8	47,67	38	52,77	68	55,02	98	132,28	128	60,03	158	44,83
9	47,51	39	52,60	69	54,94	99	131,11	129	60,12	159	44,92
10	47,67	40	52,68	70	55,19	100	133,37	130	77,57	160	45,00
11	47,67	41	52,35	71	55,19	101	131,11	131	52,60	161	45,17
12	47,67	42	52,52	72	54,94	102	130,95	132	52,77	162	44,92
13	47,51	43	52,68	73	55,27	103	93,03	133	52,43	163	45,08
14	47,76	44	52,77	74	55,02	104	93,11	134	52,27	164	44,92
15	47,51	45	52,52	75	55,02	105	93,03	135	77,91	165	45,00
16	47,76	46	52,60	76	72,73	106	92,78	136	49,93	166	44,83
17	47,59	47	52,85	77	72,90	107	92,94	137	47,42	167	44,92
18	47,51	48	52,60	78	72,81	108	92,94	138	47,51	168	45,17
19	47,67	49	52,60	79	72,81	109	80,33	139	47,51	169	44,92
20	47,51	50	52,43	80	72,81	110	80,33	140	47,59	170	44,75
21	47,84	51	52,60	81	72,73	111	80,41	141	47,25	171	44,83
22	49,84	52	52,43	82	256,57	112	80,33	142	44,92	172	45,08
23	50,01	53	52,27	83	257,15	113	80,50	143	44,75	173	45,00
24	50,09	54	52,52	84	257,49	114	80,50	144	44,92	174	44,75
25	50,09	55	52,27	85	257,40	115	79,66	145	44,75	175	45,00
26	50,09	56	52,43	86	256,90	116	80,50	146	44,75	176	45,08
27	50,18	57	52,68	87	254,65	117	77,83	147	44,83	177	45,00
28	50,09	58	52,68	88	254,81	118	67,38	148	45,00	178	44,92
29	50,09	59	52,60	89	254,98	119	79,66	149	44,92	179	44,83

Tabela 5. 4. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 03.




Figura 5. 16. Diagrama polar da medida 03.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 04											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	32,55	30	39,99	60	263,17	90	196,35	120	65,05	150	47,59
1	32,55	31	40,07	61	209,29	91	196,76	121	79,41	151	47,67
2	32,39	32	39,90	62	196,60	92	196,60	122	82,67	152	47,42
3	32,30	33	39,99	63	198,52	93	196,43	123	65,05	153	47,51
4	32,30	34	39,90	64	196,60	94	196,93	124	67,72	154	47,67
5	32,30	35	42,33	65	196,51	95	194,43	125	65,21	155	47,59
6	32,47	36	42,41	66	196,43	96	196,35	126	82,92	156	47,51
7	32,39	37	42,58	67	196,60	97	194,09	127	92,69	157	47,59
8	32,39	38	42,41	68	196,68	98	206,87	128	92,78	158	47,59
9	32,39	39	42,08	69	191,67	99	205,28	129	73,82	159	47,51
10	34,81	40	42,74	70	191,59	100	206,79	130	75,32	160	44,92
11	34,81	41	42,41	71	196,51	101	206,70	131	57,61	161	45,33
12	34,89	42	42,66	72	191,42	102	206,70	132	55,02	162	44,83
13	34,56	43	224,16	73	189,83	103	208,71	133	57,61	163	45,00
14	35,06	44	227,08	74	188,91	104	125,43	134	57,86	164	45,17
15	34,81	45	227,00	75	192,59	105	124,93	135	57,61	165	45,00
16	34,73	46	226,75	76	193,26	106	93,53	136	57,78	166	45,00
17	34,81	47	227,25	77	189,33	107	90,44	137	57,53	167	44,75
18	34,73	48	248,05	78	193,09	108	93,03	138	109,31	168	44,83
19	34,73	49	244,46	79	194,26	109	55,52	139	55,19	169	45,00
20	34,89	50	249,30	80	194,43	110	90,44	140	50,09	170	45,00
21	34,73	51	249,47	81	189,41	111	90,35	141	50,01	171	44,92
22	40,24	52	249,80	82	194,18	112	90,35	142	47,42	172	45,08
23	39,32	53	249,72	83	194,26	113	52,77	143	47,59	173	44,83
24	39,90	54	262,33	84	194,34	114	52,60	144	47,59	174	44,83
25	39,99	55	246,88	85	194,01	115	90,52	145	47,42	175	45,00
26	39,65	56	244,62	86	194,43	116	90,19	146	47,67	176	45,00
27	39,99	57	244,87	87	194,43	117	82,92	147	47,59	177	45,00
28	39,40	58	244,79	88	196,35	118	65,13	148	47,51	178	44,83
29	39,90	59	249,72	89	196,51	119	65,13	149	47,51	179	44,83

Tabela 5. 5. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 04.





Figura 5. 17. Diagrama polar da medida 04.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	204,62	30	206,62	60	145,98	90	142,72	120	55,02	150	47,42
1	204,45	31	207,04	61	138,63	91	145,90	121	55,27	151	47,34
2	204,45	32	206,54	62	138,63	92	143,48	122	67,55	152	47,51
3	204,03	33	206,54	63	138,38	93	158,34	123	55,11	153	47,51
4	204,03	34	206,79	64	138,38	94	159,01	124	55,19	154	47,42
5	204,45	35	209,46	65	138,63	95	158,59	125	55,27	155	47,51
6	204,37	36	209,38	66	138,30	96	158,68	126	65,30	156	47,51
7	204,37	37	232,18	67	138,63	97	158,59	127	65,05	157	47,51
8	204,53	38	231,84	68	138,63	98	160,26	128	65,13	158	47,76
9	204,28	39	239,61	69	138,46	99	262,50	129	65,30	159	47,51
10	204,20	40	239,45	70	140,89	100	264,67	130	64,88	160	47,42
11	204,45	41	203,11	71	138,55	101	291,82	131	65,30	161	47,59
12	204,11	42	239,28	72	138,55	102	274,28	132	65,13	162	47,51
13	204,11	43	238,86	73	138,71	103	97,45	133	65,13	163	47,51
14	196,76	44	239,95	74	138,63	104	94,11	134	65,05	164	47,42
15	194,34	45	199,52	75	138,63	105	95,45	135	52,52	165	47,59
16	194,09	46	199,10	76	138,63	106	55,27	136	49,84	166	47,51
17	204,11	47	196,85	77	138,55	107	54,94	137	49,93	167	47,51
18	204,20	48	199,19	78	138,46	108	55,27	138	49,93	168	47,51
19	204,53	49	196,85	79	143,39	109	55,02	139	49,93	169	47,34
20	204,28	50	195,01	80	138,46	110	55,19	140	49,93	170	47,51
21	204,53	51	199,52	81	141,22	111	55,19	141	50,01	171	47,42
22	204,20	52	158,34	82	140,13	112	54,94	142	50,09	172	47,34
23	204,11	53	146,23	83	138,63	113	54,61	143	50,01	173	47,51
24	204,03	54	146,32	84	141,14	114	55,19	144	47,59	174	47,51
25	204,20	55	145,90	85	139,97	115	55,11	145	47,51	175	47,51
26	204,28	56	145,81	86	143,48	116	55,02	146	47,34	176	47,59
27	204,28	57	145,81	87	143,22	117	55,02	147	47,42	177	47,34
28	204,62	58	146,06	88	143,73	118	54,94	148	47,51	178	47,59
29	206,79	59	145,90	89	142,31	119	67,72	149	47,59	179	47,09

Tabela 5. 6. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 05.



Figura

5. 18. Diagrama polar da medida 05.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 06											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	199,35	30	151,08	60	93,19	90	97,79	120	206,87	150	47,34
1	199,35	31	151,16	61	89,35	91	97,62	121	229,67	151	47,42
2	199,44	32	150,91	62	90,69	92	225,16	122	257,40	152	47,67
3	199,35	33	151,16	63	90,52	93	209,71	123	218,06	153	47,51
4	199,60	34	151,08	64	90,27	94	206,62	124	148,82	154	47,51
5	199,44	35	150,99	65	90,44	95	207,04	125	148,49	155	47,34
6	199,10	36	150,99	66	90,52	96	206,87	126	148,40	156	47,67
7	199,35	37	151,16	67	90,27	97	206,79	127	148,82	157	47,67
8	199,27	38	151,16	68	90,44	98	206,70	128	148,74	158	47,59
9	199,44	39	151,24	69	90,60	99	207,04	129	148,90	159	47,59
10	199,44	40	99,79	70	90,27	100	206,70	130	148,57	160	47,51
11	199,19	41	97,95	71	90,19	101	204,70	131	153,50	161	47,59
12	199,60	42	97,95	72	90,02	102	206,62	132	154,33	162	47,59
13	199,77	43	98,04	73	90,44	103	207,04	133	151,33	163	47,59
14	199,19	44	95,62	74	92,69	104	206,54	134	128,52	164	47,59
15	199,19	45	95,53	75	93,11	105	206,87	135	66,05	165	47,67
16	199,27	46	95,53	76	90,94	106	206,95	136	133,87	166	47,51
17	199,35	47	93,11	77	93,03	107	206,62	137	52,93	167	47,51
18	199,35	48	92,94	78	93,11	108	206,95	138	52,68	168	47,42
19	201,02	49	92,86	79	92,94	109	206,62	139	50,01	169	47,42
20	201,86	50	93,11	80	95,45	110	206,95	140	50,09	170	47,51
21	201,69	51	92,86	81	95,70	111	206,87	141	50,18	171	47,51
22	201,78	52	92,94	82	95,45	112	207,12	142	49,93	172	47,59
23	201,94	53	93,11	83	95,70	113	205,95	143	50,09	173	47,51
24	154,58	54	93,19	84	95,53	114	206,70	144	47,51	174	47,42
25	201,44	55	93,03	85	95,53	115	205,79	145	47,59	175	47,59
26	158,26	56	93,03	86	95,45	116	206,79	146	47,42	176	47,51
27	151,16	57	93,03	87	95,45	117	206,87	147	47,42	177	47,51
28	151,08	58	92,86	88	94,53	118	206,62	148	47,51	178	47,51
29	150,16	59	90,94	89	98,04	119	206,79	149	47,67	179	47,42

Tabela 5. 7. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 06.




Figura 5. 19. Diagrama polar da medida 06.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	209,88	30	52,60	60	57,61	90	181,48	120	222,07	150	100,38
1	209,63	31	52,43	61	57,70	91	182,90	121	246,96	151	100,54
2	209,54	32	52,60	62	57,78	92	179,06	122	248,05	152	100,63
3	209,21	33	52,68	63	57,70	93	178,81	123	247,46	153	100,38
4	209,46	34	52,52	64	57,61	94	171,96	124	247,46	154	100,63
5	207,54	35	52,52	65	57,61	95	158,76	125	247,55	155	100,46
6	110,73	36	52,52	66	57,70	96	158,59	126	174,63	156	100,63
7	110,73	37	52,43	67	57,70	97	158,84	127	217,06	157	100,46
8	110,82	38	52,43	68	57,78	98	158,43	128	216,56	158	100,63
9	110,82	39	52,43	69	57,61	99	158,51	129	158,18	159	100,54
10	60,03	40	52,60	70	57,78	100	158,84	130	155,42	160	100,63
11	57,70	41	52,43	71	57,86	101	158,59	131	217,31	161	100,54
12	57,61	42	52,52	72	57,95	102	158,59	132	131,95	162	100,54
13	57,53	43	52,60	73	60,12	103	158,84	133	216,64	163	95,11
14	57,61	44	52,68	74	60,12	104	158,93	134	122,68	164	72,90
15	54,94	45	52,68	75	70,22	105	158,76	135	645,54	165	72,81
16	55,19	46	52,60	76	70,31	106	158,59	136	643,37	166	70,31
17	54,77	47	52,60	77	72,81	107	158,59	137	121,17	167	72,81
18	54,94	48	55,27	78	72,81	108	158,93	138	121,09	168	72,65
19	55,02	49	55,02	79	72,73	109	158,84	139	131,20	169	65,05
20	55,02	50	55,36	80	72,73	110	158,68	140	246,96	170	75,32
21	55,19	51	55,02	81	72,90	111	176,13	141	249,72	171	64,96
22	55,02	52	55,11	82	72,98	112	175,88	142	213,64	172	65,13
23	55,11	53	54,86	83	72,98	113	173,04	143	128,11	173	62,79
24	55,11	54	55,19	84	72,65	114	176,22	144	128,02	174	62,54
25	52,52	55	57,86	85	72,81	115	158,68	145	128,44	175	62,71
26	52,68	56	57,53	86	73,23	116	170,37	146	122,43	176	62,71
27	52,60	57	57,61	87	181,65	117	159,60	147	102,72	177	62,62
28	52,43	58	57,86	88	181,56	118	178,97	148	100,38	178	65,38
29	52,18	59	57,61	89	181,65	119	245,96	149	100,54	179	62,96

Tabela 5. 8. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 07.




Figura 5. 20. Diagrama polar da medida 07.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	32,39	30	34,89	60	39,82	90	133,45	120	110,65	150	93,19
1	32,30	31	34,89	61	39,90	91	133,62	121	110,73	151	93,03
2	32,30	32	34,89	62	42,41	92	133,29	122	117,83	152	93,19
3	32,47	33	34,73	63	52,43	93	133,70	123	118,00	153	93,11
4	32,47	34	34,98	64	52,68	94	133,37	124	115,91	154	93,03
5	32,55	35	34,81	65	52,52	95	135,96	125	115,66	155	93,11
6	32,47	36	34,81	66	54,86	96	138,38	126	115,75	156	93,03
7	32,39	37	34,89	67	54,94	97	131,11	127	115,49	157	93,11
8	32,47	38	34,81	68	55,27	98	130,86	128	118,17	158	92,94
9	32,05	39	34,81	69	54,86	99	130,78	129	118,50	159	93,19
10	32,39	40	34,64	70	55,02	100	131,03	130	118,25	160	93,11
11	32,22	41	34,73	71	55,19	101	130,86	131	118,25	161	93,11
12	32,97	42	40,16	72	54,94	102	130,78	132	111,23	162	93,03
13	35,06	43	37,23	73	54,61	103	130,86	133	120,84	163	92,94
14	34,98	44	37,48	74	82,75	104	113,49	134	143,31	164	93,03
15	34,39	45	37,48	75	82,92	105	113,32	135	143,39	165	93,11
16	34,73	46	37,57	76	82,84	106	113,07	136	143,56	166	92,86
17	34,81	47	37,48	77	83,00	107	113,32	137	141,14	167	93,11
18	34,73	48	39,74	78	85,43	108	113,16	138	140,97	168	93,03
19	34,81	49	39,82	79	85,51	109	111,57	139	118,33	169	93,11
20	34,89	50	39,82	80	85,26	110	111,07	140	118,33	170	93,11
21	35,14	51	39,82	81	133,54	111	113,24	141	118,17	171	92,19
22	34,89	52	39,82	82	133,45	112	113,24	142	118,17	172	92,53
23	34,89	53	39,99	83	133,45	113	110,65	143	95,62	173	93,03
24	34,81	54	39,99	84	135,21	114	110,57	144	95,37	174	93,19
25	34,81	55	39,99	85	135,71	115	110,57	145	95,53	175	93,03
26	34,98	56	39,99	86	136,04	116	110,82	146	92,78	176	92,86
27	35,06	57	39,82	87	135,62	117	110,65	147	93,03	177	92,94
28	34,81	58	40,16	88	136,04	118	110,65	148	93,11	178	93,03
29	34,73	59	39,82	89	133,79	119	110,57	149	92,94	179	92,94

Tabela 5. 9. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 08.




Figura 5. 21. Diagrama polar da medida 08.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	37,73	30	37,48	60	85,34	90	200,77	120	67,72	150	72,81
1	37,32	31	37,57	61	85,43	91	163,77	121	67,72	151	87,35
2	37,48	32	37,32	62	85,43	92	164,02	122	67,72	152	88,02
3	37,32	33	37,57	63	85,43	93	185,99	123	67,89	153	87,85
4	34,64	34	37,48	64	85,43	94	163,86	124	67,55	154	88,02
5	34,89	35	37,32	65	85,51	95	166,19	125	67,89	155	88,02
6	35,06	36	37,40	66	85,43	96	163,77	126	67,97	156	88,02
7	34,98	37	37,57	67	85,34	97	163,61	127	67,89	157	87,85
8	34,98	38	37,40	68	85,09	98	162,44	128	67,80	158	88,18
9	34,73	39	39,99	69	85,43	99	163,69	129	67,80	159	87,93
10	35,06	40	40,07	70	85,01	100	163,86	130	67,72	160	85,43
11	34,98	41	39,90	71	90,77	101	132,62	131	67,80	161	85,43
12	34,98	42	39,99	72	92,86	102	132,87	132	67,72	162	85,43
13	34,98	43	84,59	73	93,19	103	118,33	133	67,97	163	85,26
14	34,81	44	84,67	74	92,94	104	132,03	134	67,72	164	85,43
15	34,73	45	85,09	75	93,11	105	133,03	135	67,89	165	85,34
16	35,06	46	85,51	76	93,03	106	132,62	136	67,64	166	85,43
17	34,73	47	85,43	77	90,60	107	88,27	137	67,97	167	85,34
18	34,64	48	85,43	78	90,60	108	95,62	138	67,89	168	85,51
19	34,98	49	85,43	79	93,03	109	87,85	139	67,72	169	85,51
20	35,14	50	85,43	80	90,69	110	88,10	140	67,80	170	85,34
21	34,81	51	83,42	81	90,35	111	88,02	141	67,89	171	85,43
22	34,89	52	85,26	82	90,52	112	88,02	142	72,98	172	85,34
23	34,89	53	85,34	83	93,03	113	88,02	143	67,80	173	85,34
24	34,64	54	85,51	84	93,03	114	87,85	144	68,05	174	85,51
25	34,64	55	85,43	85	90,35	115	88,02	145	75,32	175	85,43
26	34,98	56	85,34	86	90,52	116	70,14	146	72,81	176	85,76
27	34,64	57	85,43	87	93,03	117	70,06	147	72,90	177	85,26
28	34,81	58	85,68	88	95,45	118	70,06	148	72,73	178	85,34
29	34,98	59	85,43	89	92,94	119	67,64	149	72,81	179	88,02

Tabela 5. 10. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 09.




Figura 5. 22. Diagrama polar da medida 09.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	22,20	30	40,07	60	47,51	90	232,10	120	52,60	150	45,00
1	22,45	31	40,07	61	47,59	91	231,93	121	52,60	151	44,92
2	22,28	32	39,82	62	47,59	92	232,35	122	52,52	152	45,00
3	22,36	33	40,16	63	47,51	93	158,68	123	71,64	153	45,00
4	22,28	34	40,24	64	47,67	94	158,84	124	71,81	154	45,17
5	24,79	35	39,90	65	57,78	95	156,25	125	69,14	155	45,25
6	24,87	36	40,07	66	57,95	96	156,09	126	70,39	156	45,17
7	24,87	37	40,07	67	57,70	97	64,96	127	70,47	157	44,92
8	27,46	38	40,07	68	57,70	98	52,60	128	68,89	158	45,17
9	27,46	39	39,90	69	209,29	99	52,52	129	52,68	159	44,83
10	27,38	40	39,99	70	212,22	100	52,85	130	52,60	160	45,08
11	27,54	41	39,90	71	229,59	101	52,60	131	50,26	161	45,00
12	39,99	42	40,07	72	214,39	102	52,77	132	50,26	162	45,08
13	39,99	43	40,07	73	214,47	103	52,43	133	47,51	163	45,00
14	39,90	44	39,82	74	214,64	104	52,68	134	47,84	164	45,33
15	39,82	45	39,90	75	214,64	105	50,18	135	47,76	165	45,17
16	39,90	46	39,90	76	214,72	106	50,18	136	47,59	166	44,92
17	39,90	47	39,90	77	214,81	107	50,18	137	47,59	167	45,08
18	39,90	48	40,07	78	214,56	108	50,26	138	47,59	168	45,08
19	42,66	49	39,90	79	214,81	109	50,01	139	47,67	169	45,08
20	42,74	50	40,07	80	214,56	110	50,18	140	44,83	170	45,17
21	42,66	51	42,74	81	214,47	111	50,01	141	45,08	171	45,17
22	39,99	52	42,41	82	214,81	112	49,93	142	45,17	172	45,08
23	39,82	53	42,66	83	216,98	113	50,09	143	45,08	173	45,08
24	40,07	54	42,49	84	229,67	114	50,18	144	45,00	174	45,17
25	39,99	55	42,66	85	229,92	115	50,09	145	45,08	175	45,08
26	40,24	56	42,58	86	229,67	116	52,85	146	45,08	176	45,00
27	39,99	57	45,08	87	232,18	117	52,52	147	45,00	177	45,00
28	40,07	58	44,83	88	232,26	118	52,77	148	45,00	178	45,00
29	39,99	59	45,17	89	232,18	119	52,85	149	45,08	179	45,00

Tabela 5. 11. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 10.




Figura 5. 23. Diagrama polar da medida 10.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 11											
em graus	Distância em cm	em graus	Distância em cm	em graus	Distância em cm	em graus	Distância em cm	em graus	Distância em cm	em graus	Distância em cm
0	42,49	30	110,65	60	93,28	90	184,40	120	72,98	150	42,41
1	42,58	31	110,90	61	95,62	91	184,32	121	72,98	151	42,58
2	45,17	32	110,73	62	95,78	92	184,15	122	75,32	152	42,49
3	45,00	33	113,41	63	95,70	93	181,65	123	74,65	153	42,49
4	44,92	34	113,49	64	95,53	94	181,65	124	50,35	154	42,58
5	45,17	35	113,32	65	166,03	95	282,04	125	50,09	155	42,49
6	44,92	36	113,24	66	169,12	96	279,79	126	50,09	156	42,58
7	44,92	37	113,41	67	166,61	97	282,71	127	62,79	157	42,41
8	45,00	38	113,41	68	168,95	98	283,05	128	62,87	158	42,74
9	45,00	39	90,77	69	165,11	99	119,34	129	62,79	159	42,74
10	45,00	40	90,60	70	169,12	100	125,85	130	72,90	160	42,41
11	47,59	41	90,60	71	168,87	101	118,42	131	72,81	161	42,41
12	93,11	42	90,60	72	169,20	102	118,25	132	72,73	162	42,58
13	95,78	43	92,53	73	169,03	103	178,22	133	72,90	163	42,49
14	83,00	44	90,69	74	169,95	104	180,89	134	72,98	164	42,49
15	80,33	45	90,69	75	168,37	105	176,63	135	72,81	165	42,33
16	80,25	46	90,60	76	168,87	106	180,14	136	72,56	166	42,66
17	80,33	47	90,35	77	167,70	107	90,60	137	47,67	167	42,49
18	80,58	48	90,44	78	168,53	108	90,60	138	44,92	168	42,58
19	80,50	49	93,11	79	171,21	109	90,52	139	44,92	169	42,49
20	80,58	50	93,19	80	171,54	110	90,60	140	45,00	170	42,49
21	80,33	51	100,63	81	171,37	111	90,52	141	45,17	171	42,58
22	80,58	52	98,04	82	171,87	112	72,90	142	45,00	172	42,33
23	80,50	53	97,70	83	171,04	113	72,90	143	44,92	173	42,49
24	80,50	54	98,21	84	170,29	114	72,81	144	45,17	174	42,58
25	80,00	55	98,04	85	171,62	115	73,06	145	45,08	175	42,58
26	80,25	56	95,70	86	170,29	116	72,90	146	44,92	176	42,83
27	80,41	57	95,53	87	172,79	117	73,15	147	45,08	177	42,58
28	80,92	58	95,11	88	177,97	118	72,90	148	44,75	178	42,58
29	110,65	59	95,62	89	184,40	119	72,90	149	42,41	179	42,41

Tabela 5. 12. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 11




Figura 5. 24. Diagrama polar da medida 11.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	60,37	30	62,71	60	108,31	90	125,94	120	47,76	150	42,41
1	60,20	31	62,96	61	108,31	91	153,92	121	57,78	151	42,91
2	60,12	32	62,79	62	110,40	92	153,67	122	57,78	152	42,49
3	60,20	33	63,12	63	108,23	93	153,92	123	83,59	153	42,66
4	60,12	34	75,32	64	108,31	94	156,51	124	54,86	154	42,58
5	60,28	35	75,32	65	108,23	95	227,08	125	48,93	155	42,83
6	60,37	36	75,49	66	108,40	96	232,26	126	55,36	156	42,49
7	60,28	37	75,32	67	108,40	97	126,10	127	55,27	157	42,74
8	60,45	38	75,15	68	108,14	98	125,94	128	55,19	158	42,33
9	60,37	39	75,49	69	108,06	99	126,10	129	55,27	159	42,66
10	60,28	40	78,08	70	108,14	100	126,35	130	55,44	160	39,99
11	60,20	41	75,40	71	108,40	101	176,47	131	55,44	161	40,24
12	60,20	42	93,78	72	105,97	102	126,19	132	52,68	162	40,16
13	60,20	43	113,24	73	105,72	103	151,66	133	52,35	163	39,99
14	60,20	44	111,65	74	105,89	104	232,68	134	52,77	164	40,24
15	60,28	45	113,41	75	105,72	105	232,43	135	52,77	165	39,99
16	60,28	46	113,16	76	105,56	106	234,94	136	52,77	166	39,99
17	60,20	47	100,88	77	105,81	107	48,51	137	55,19	167	40,07
18	60,12	48	113,07	78	105,72	108	48,26	138	47,42	168	40,32
19	60,20	49	156,34	79	105,89	109	48,09	139	45,25	169	40,24
20	60,20	50	167,28	80	108,31	110	234,77	140	45,17	170	40,16
21	60,37	51	158,01	81	123,43	111	221,24	141	45,25	171	40,24
22	60,28	52	118,50	82	123,51	112	48,26	142	42,66	172	40,32
23	60,28	53	123,43	83	123,51	113	47,84	143	42,74	173	40,07
24	62,71	54	121,93	84	123,51	114	47,76	144	42,66	174	40,49
25	62,71	55	123,43	85	123,35	115	47,59	145	42,74	175	40,41
26	63,04	56	123,60	86	123,51	116	47,59	146	42,66	176	40,07
27	62,87	57	123,51	87	123,43	117	47,76	147	42,41	177	40,24
28	62,79	58	123,43	88	123,76	118	210,21	148	42,74	178	40,16
29	62,87	59	123,51	89	125,85	119	47,76	149	42,49	179	40,24

Tabela 5. 13. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 12.




Figura 5. 25. Diagrama polar da medida 12.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medição 13											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	57,61	30	62,37	60	62,87	90	78,24	120	257,32	150	45,08
1	57,86	31	66,97	61	73,98	91	75,40	121	365,57	151	45,00
2	57,61	32	75,49	62	62,46	92	75,49	122	324,89	152	45,00
3	57,28	33	77,83	63	77,99	93	75,40	123	268,93	153	45,17
4	57,70	34	62,87	64	76,57	94	82,25	124	409,84	154	44,83
5	57,70	35	63,04	65	77,91	95	77,99	125	245,13	155	44,92
6	57,86	36	62,71	66	77,99	96	178,39	126	244,37	156	45,00
7	57,78	37	77,07	67	77,91	97	78,16	127	252,48	157	44,83
8	57,70	38	77,41	68	77,99	98	78,24	128	252,48	158	44,92
9	57,70	39	77,83	69	80,25	99	181,56	129	252,39	159	45,17
10	57,36	40	75,40	70	80,41	100	180,14	130	252,48	160	44,92
11	58,86	41	75,32	71	80,41	101	181,73	131	253,81	161	45,00
12	60,12	42	74,90	72	80,66	102	181,73	132	62,71	162	45,00
13	57,61	43	75,15	73	80,50	103	181,81	133	62,96	163	45,08
14	60,37	44	75,32	74	78,74	104	181,56	134	59,87	164	44,92
15	60,03	45	75,32	75	77,99	105	181,65	135	60,37	165	44,92
16	60,20	46	75,57	76	77,91	106	181,65	136	60,37	166	44,92
17	60,03	47	74,99	77	77,83	107	181,81	137	60,28	167	44,83
18	60,20	48	75,49	78	77,99	108	181,48	138	60,12	168	45,08
19	60,12	49	75,24	79	78,08	109	181,48	139	47,67	169	45,17
20	60,12	50	62,79	80	77,83	110	181,73	140	47,51	170	44,92
21	60,12	51	62,79	81	77,91	111	181,81	141	47,67	171	45,08
22	60,28	52	62,79	82	77,99	112	181,73	142	47,76	172	45,08
23	59,87	53	63,12	83	77,91	113	184,32	143	44,83	173	45,08
24	60,20	54	64,38	84	75,49	114	181,65	144	44,83	174	44,92
25	60,03	55	74,57	85	77,99	115	183,99	145	45,00	175	45,17
26	60,12	56	75,40	86	77,99	116	181,48	146	45,00	176	45,00
27	60,20	57	62,79	87	77,74	117	184,07	147	45,00	177	45,00
28	59,78	58	62,79	88	77,74	118	203,53	148	45,08	178	45,17
29	60,28	59	72,40	89	77,91	119	257,15	149	45,00	179	45,08

Tabela 5. 14. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 13.




Figura 5. 26. Diagrama polar da medida 13.

Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	27,71	30	45,08	60	57,36	90	139,22	120	133,45	150	118,42
1	27,21	31	45,17	61	57,70	91	136,21	121	133,62	151	118,42
2	27,38	32	45,25	62	57,78	92	136,29	122	133,70	152	118,25
3	27,21	33	45,00	63	57,78	93	133,37	123	133,70	153	118,33
4	47,59	34	45,00	64	57,95	94	133,62	124	133,79	154	118,25
5	47,67	35	44,83	65	57,86	95	133,54	125	135,71	155	115,91
6	47,51	36	45,33	66	57,78	96	133,54	126	136,04	156	115,58
7	47,51	37	45,17	67	60,12	97	133,37	127	171,87	157	115,75
8	47,67	38	47,42	68	60,03	98	133,37	128	187,49	158	115,83
9	47,59	39	47,76	69	62,79	99	133,79	129	173,96	159	115,91
10	47,59	40	47,42	70	62,79	100	133,45	130	171,62	160	116,08
11	47,59	41	47,92	71	77,99	101	133,20	131	183,99	161	115,91
12	47,67	42	47,67	72	77,99	102	133,45	132	183,65	162	115,91
13	47,51	43	47,76	73	77,91	103	133,54	133	187,24	163	116,00
14	47,67	44	47,76	74	78,08	104	133,54	134	251,81	164	115,83
15	47,59	45	47,67	75	77,74	105	133,37	135	307,94	165	115,75
16	47,42	46	47,76	76	87,85	106	133,70	136	307,77	166	115,66
17	47,67	47	47,59	77	88,02	107	133,62	137	247,13	167	115,91
18	47,59	48	47,51	78	88,02	108	133,62	138	245,96	168	115,75
19	47,59	49	47,84	79	111,82	109	133,62	139	227,25	169	115,83
20	47,51	50	47,51	80	112,57	110	133,54	140	228,92	170	115,66
21	47,67	51	47,59	81	144,90	111	133,37	141	207,04	171	115,91
22	47,34	52	47,59	82	145,98	112	133,54	142	206,70	172	115,91
23	47,34	53	50,09	83	143,89	113	133,45	143	206,79	173	115,75
24	47,51	54	49,76	84	146,06	114	133,45	144	206,62	174	115,66
25	45,00	55	57,61	85	143,73	115	133,54	145	206,79	175	115,91
26	45,08	56	54,94	86	143,56	116	133,45	146	206,45	176	115,58
27	44,92	57	57,61	87	143,64	117	133,54	147	206,20	177	80,41
28	45,00	58	57,70	88	143,39	118	133,62	148	118,59	178	80,16
29	45,17	59	57,78	89	143,559	119	133,54	149	118,25	179	115,33

Tabela 5. 15. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 14.




Figura 5. 27. Diagrama polar da medida 14.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 15											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	42,58	30	50,09	60	75,32	90	98,21	120	85,34	150	207,04
1	42,08	31	50,09	61	75,40	91	98,12	121	85,43	151	204,20
2	42,49	32	47,76	62	77,83	92	98,37	122	85,68	152	180,39
3	42,41	33	47,59	63	77,91	93	98,29	123	85,59	153	115,83
4	42,49	34	47,17	64	77,74	94	98,04	124	88,18	154	115,75
5	42,66	35	45,08	65	77,99	95	98,29	125	87,93	155	115,75
6	42,58	36	44,92	66	78,08	96	98,12	126	85,51	156	115,66
7	42,58	37	45,08	67	119,75	97	97,95	127	85,59	157	115,75
8	42,49	38	44,92	68	120,59	98	98,12	128	85,51	158	115,75
9	42,58	39	47,34	69	120,09	99	98,12	129	88,27	159	115,66
10	42,58	40	47,42	70	113,41	100	98,12	130	88,10	160	116,00
11	42,58	41	47,59	71	113,32	101	98,29	131	89,02	161	115,83
12	42,33	42	47,25	72	112,99	102	97,95	132	97,95	162	115,75
13	42,49	43	47,76	73	100,46	103	98,12	133	98,29	163	115,66
14	42,49	44	47,59	74	100,54	104	88,52	134	98,12	164	113,49
15	42,41	45	49,93	75	100,63	105	98,21	135	98,12	165	115,66
16	42,74	46	50,18	76	100,71	106	88,27	136	98,29	166	113,41
17	42,49	47	49,93	77	100,54	107	88,27	137	200,44	167	113,41
18	42,49	48	50,09	78	100,88	108	88,27	138	255,48	168	113,07
19	42,49	49	50,18	79	97,87	109	88,10	139	153,92	169	113,41
20	42,58	50	50,09	80	98,12	110	87,93	140	256,99	170	113,32
21	42,91	51	50,09	81	98,04	111	87,85	141	257,32	171	113,41
22	42,58	52	52,68	82	97,95	112	87,93	142	267,76	172	113,41
23	42,49	53	52,60	83	98,21	113	88,10	143	270,85	173	113,16
24	42,58	54	52,68	84	97,95	114	87,10	144	127,44	174	113,07
25	42,41	55	52,60	85	97,70	115	87,85	145	267,34	175	113,32
26	42,58	56	52,52	86	97,87	116	88,27	146	236,77	176	113,24
27	44,92	57	75,24	87	97,29	117	85,43	147	209,79	177	113,41
28	45,00	58	75,49	88	97,95	118	88,10	148	209,46	178	113,24
29	44,92	59	75,07	89	98,04	119	85,68	149	211,46	179	113,32

Tabela 5. 16. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som (sonar) da medida 15.




Figura 5. 28. Diagrama polar da medida 15.

Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som- Medida 16											
Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm	Ângulos em graus	Distância em cm
0	27,21	30	75,32	60	75,82	90	60,54	120	62,62	150	49,93
1	27,04	31	72,90	61	77,99	91	107,73	121	62,79	151	50,18
2	27,21	32	72,81	62	77,83	92	111,40	122	60,37	152	50,18
3	27,29	33	72,73	63	77,74	93	60,54	123	62,71	153	49,84
4	27,21	34	72,81	64	80,50	94	60,03	124	59,95	154	50,09
5	27,46	35	72,65	65	80,16	95	57,78	125	59,95	155	50,01
6	27,13	36	72,81	66	72,90	96	57,53	126	60,03	156	49,93
7	55,11	37	72,81	67	73,06	97	57,53	127	59,95	157	50,26
8	55,11	38	75,24	68	80,41	98	57,86	128	60,37	158	49,93
9	54,94	39	70,31	69	72,81	99	57,70	129	60,20	159	50,09
10	55,27	40	72,48	70	72,90	100	57,70	130	50,01	160	50,01
11	55,27	41	72,98	71	72,98	101	57,61	131	50,01	161	50,09
12	55,11	42	72,90	72	72,90	102	67,80	132	49,93	162	50,09
13	55,02	43	73,06	73	82,59	103	68,05	133	49,93	163	50,35
14	54,86	44	72,90	74	72,98	104	67,97	134	50,01	164	50,35
15	55,11	45	73,06	75	75,49	105	67,64	135	50,09	165	50,18
16	55,02	46	72,90	76	73,06	106	67,89	136	49,93	166	98,12
17	71,81	47	73,15	77	72,90	107	67,89	137	50,09	167	97,95
18	72,90	48	72,90	78	75,24	108	65,38	138	50,09	168	98,21
19	72,90	49	72,81	79	80,41	109	67,89	139	50,09	169	97,87
20	72,90	50	72,90	80	80,16	110	67,97	140	50,18	170	98,04
21	72,81	51	72,98	81	80,33	111	70,31	141	50,18	171	98,12
22	72,73	52	70,56	82	80,50	112	70,22	142	50,09	172	98,12
23	73,15	53	70,39	83	80,50	113	72,73	143	50,26	173	100,54
24	72,90	54	70,14	84	80,41	114	72,48	144	50,09	174	100,63
25	75,49	55	70,22	85	80,41	115	62,79	145	50,35	175	100,54
26	75,32	56	70,31	86	80,41	116	62,71	146	50,09	176	100,71
27	75,40	57	72,81	87	80,41	117	62,62	147	50,01	177	100,79
28	75,40	58	72,90	88	82,34	118	62,71	148	50,01	178	100,63
29	75,32	59	72,73	89	81,75	119	62,62	149	50,09	179	100,63

Tabela 5. 17. Tabela com os ângulos e medidas de distância obtido pelo sensor de ultra-som(sonar) da medida 16.




Figura 5. 29. Diagrama polar da medida 16.

5.3.4 Avaliação Experimental do Robô

Para avaliar experimentalmente a qualidade da construção do robô, fez-se uso do teste UMBmark (University of Michigan Benchmark) que permite avaliar quantitativamente os erros sistemáticos e não sistemáticos referentes à odometria obtida do deslocamento do robô móvel com acionamento diferencial. A realização desse teste consiste em comandar o robô para percorrer uma trajetória quadrada, partindo de um dos vértices do quadrado considerado como ponto inicial e voltando para o ponto de onde partiu considerando agora como ponto final, tanto no sentido horário quanto anti-horário, avaliando a posição e orientação do ponto final em relação ao inicial (BORENSTEIN et al., 1996). Na Figura 5.30 demonstra-se como realizar o teste, a fim de se avaliar os erros sistemáticos e não sistemáticos referentes à odometria do deslocamento do robô. O trajeto de teste é um quadrado de 150 cm de lado.

- Realizam-se dois testes com 10 trajetórias, no sentido horário e anti-horário e medem-se as poses finais;

- Nos testes realizados obtêm-se a média para o conjunto de medidas verificadas no sentido horário e anti-horário;
- Verifica-se a distância das médias obtidas para o ponto final planejado da trajetória. A medida de maior valor oferece uma avaliação quantitativa dos erros sistemáticos que incidem no robô ao realizar o trajeto;
- Para o conjunto de medidas descritas acima, calcula-se o desvio padrão, o qual representa uma medida quantitativa dos erros não sistemáticos que incidem na execução do trajeto pelo robô no ambiente proposto.




Figura 5. 30. Teste para avaliar quantitativamente os erros sistemáticos e não sistemáticos referentes a odometria obtida do deslocamento do robô móvel construído.

Fonte: BORENSTEIN (1996)

5.3.5 Resultados dos experimentos práticos

Os resultados foram obtidos a partir da execução da trajetória pelo robô usando o método UMBmark. Em cada posição dessa trajetória registrou-se o valor medido pela odometria da navegação do robô.

Medições	Erro de posição (cm)	
	Horário	Anti-Horário
1	23,19	24,23
2	8,69	22,40
3	20,53	21,73
4	22,03	28,36
5	20,59	23,82
6	12,45	25,21
7	13,37	28,78
8	15,47	28,49
9	16,11	24,86
10	19,43	23,48
Média	17,18	25,13
Desvio Padrão	4,72	2,56

Tabela 5. 18. Resultado do teste 01 UMBmark de navegação do robô por odometria.

Medições	Erro de posição (cm)	
	Horário	Anti-Horário
1	18,11	23,05
2	24,79	23,49
3	24,31	20,51
4	17,63	15,33
5	18,85	24,55
6	18,77	15,31
7	24,02	22,24
8	26,49	18,36
9	22,77	16,94
10	13,58	15,64
Média	20,932	19,54
Desvio Padrão	4,10999	3,65

Tabela 5. 19. Resultado do teste 02 UMBmark de navegação do robô por odometria.

Os experimentos realizados com resultados apresentados nas tabelas 5.18 e 5.19 demonstram que o erro em torno de 20 cm é muito grande para que o robô navegue de forma

satisfatória nos corredores entre os tornos. Desta forma, ajustes mecânicos nas rodas, nos eixos e nos passos mecânicos devem ser feitos para diminuir o erro de navegação. Estes ajustes estão em andamento e em trabalhos futuros os resultados serão apresentados.

5.4 CONSIDERAÇÕES FINAIS

Neste capítulo foram apresentados os testes realizados de simulação do robô usando como modelo o chão de fábrica e utilizaram-se as informações fornecidas pelo sistema de odometria e para medição da distância entre o robô e os objetos, foram utilizados um sensor de ultra-som, essas informações foram combinadas através da aplicação do Filtro de Kalman Estendido (EKF). Nos experimentos práticos realizados com o robô somente usando odometria os resultados mostram um desempenho insatisfatório, pois o erro de posição estava em torno de 20 cm e o corredor que o robô deve navegar é de 100 cm. Também foi descrito neste capítulo o método e o aplicativo utilizado para aquisição dos dados das medidas de distância obtidas através do sensor de ultra-som para construção do mapa do ambiente.

Capítulo 6

6. CONCLUSÕES

Um sistema para navegação de robôs móveis autônomos usando o algoritmo do filtro de Kalman Estendido para o mapeamento e localização simultânea do robô foi proposto, simulado e avaliado neste trabalho. Para simulação de navegação utilizou-se integração, via filtro de Kalman Estendido, de dois sensores, odômetro com sensor de ultra-som. No experimento de coleta de dados das medidas dos objetos do ambiente a principal dificuldade constatada foi lidar com o largo ângulo de dispersão do sonar EZ-1 para medição das distâncias, já que a dimensão do ambiente do experimento é muito grande, o que dificulta garantir a qualidade das medidas dos *landmarks* do ambiente para que possam ser extraídos com precisão aceitável. No teste de navegação do robô somente usando odometria os resultados mostram um desempenho insatisfatório, pois o erro de posição estava em torno de 20 cm e o corredor que o robô deve navegar é de 100 cm. Cada vez mais os robôs móveis estão sendo empregados para tarefas específicas de monitoramento, inspeção, e para auxílio humano complementar em tarefas que exigem precisão ou que são difíceis de serem executadas devido ao seu ambiente de atuação inóspito. Adicionalmente, cada vez mais se faz necessário o uso de sensores de baixo custo em tais robôs. Assim, este projeto vem ao

encontro com uma necessidade emergente de mercado, onde robôs móveis, autônomos com sensores ultra-som (para uso em diversas tarefas), estão sendo cada vez mais solicitados por muitas empresas. Dentro deste contexto, o projeto em desenvolvimento procura atender esta demanda, incorporando inovações tecnológicas no desenvolvimento do hardware e do software de um robô que, simultaneamente, navega, mapeia e se localiza num ambiente desestruturado, utilizando sensor de ultra-som. A plataforma de controle do robô foi desenvolvida com o emprego de um computador do tipo notebook com processador Core 2 Duo, considerando-se aspectos de desempenho, quanto de flexibilidade de implementação. Trata-se de um trabalho com resultados preliminares, que tem como contribuições, a realização das medições do ambiente e a navegação autônoma usando apenas um robô com encoder e sonar rotativo. Outra contribuição é o uso de controladores inteligentes para motores de micro passo usados na construção do robô proposto. O SLAM com sonar possibilita a substituição do tradicional sensor laser range finder por sensores de ultra-som, que são mais compactos e têm menor consumo de energia, menor custo e demandam menor processamento computacional. Com os testes e simulações que foram realizados, este trabalho contribuiu também com o uso de robôs móveis em chão de fábrica ao invés de AGVs (Automated Guided Vehicles) usando a técnica do Filtro de Kalman Estendido para o mapeamento e a localização simultânea do robô. O uso desse método evita trabalhos de adaptação do ambiente com *landmarks* artificiais ou instalação de faixas, correias ou luzes para auxiliar na navegação, tornando possível trabalhar com *landmarks* naturais.

6.1 As sugestões de trabalhos futuros incluem:

- Desenvolver estudos para o problema de SLAM (Simultaneous Localization and Mapping), com o uso de duas fontes de informação das observações do ambiente, além das comumente usadas como as de estimativas de posição de referência do robô, para melhorar o processo de associação das observações realizadas pelo robô.
- A implementação desta técnica usando um sensor laser range finder, já que esse oferece informação de distância direcionada, favorecendo a definição de orientação do marco em relação ao robô e comparar o desempenho e custo do sistema.

- Investigar a abordagem usando fusão de dois mapas: um construído a partir de um laser range finder e outro a partir de um sonar.
- Realizar o mapeamento de um ambiente por um único robô. Depois dividir o ambiente em partes, e mapear cada parte por robôs independentes, e ao final fundir os mapas para comparação com o mapa obtido por um único robô.

7. REFERÊNCIAS

AYACHE, N.; FAUGERAS, O. D. Hyper: A new approach for the representation and positioning of two-dimensional objects. **Transactions on Pattern Analysis and Machine Intelligence**, IEEE v., ed.1, p.44-54, 1986.

BAILEY, T. **Mobile robot localisation and mapping in extensive outdoor environments**. PhD thesis. Australian Centre for Field Robotics, University of Sydney, August 2002.

BAILEY, T.; DURRANT-WHYTE, H. F. Simultaneous Localisation and Mapping (SLAM): part I the essential algorithms. **Robotics & Automation Magazine**, IEEE v.13, ed. 2, p.99–110, june 2006a

BAILEY, T.; DURRANT-WHYTE, H. F. Simultaneous Localisation and Mapping (SLAM): part II state of the art. **Robotics & Automation Magazine**, IEEE v.13, ed. 3, p.108–117, september 2006b.

BAILEY T., NIETO J., GUIVANT J., STEVENS M., AND NEBOT E.; **Consistency of the EKF-SLAM Algorithm**. In IEEE/RSJ International Conference on Intelligent Robots and Systems, presented at IEEE/RSJ International Conference on Intelligent Robots and Systems, Beijing, P.R. China, 9 - 15 October 2006, 10.1109/IROS.2006.281644, 7 pages, 2006c.

BORENSTEIN, J.; EVERETT, H.R.; FENG, L. **Where am I? Sensors and methods for mobile robot positioning**, University of Michigan, USA, 1996.

BORENSTEIN, J. AND FENG. L. , “**UMBmark: A Benchmark Test for Measuring Dead-Reckoning Errors in Mobile Robots.**” *1995 SPIE Conference on Mobile Robots*, Philadelphia, 1995.

BURGARD, W. et al. **The interactive museum tour-guide robot**. In: National Conference on Artificial Intelligence. **Proceedings**, 1998.

CASTELLANOS J. A., MONTIEL J. M. M., NEIRA J., AND TRADÓS J. D.; **The SPmap: A probabilistic framework for simultaneous localization and map building**. In IEEE Transactions on Robotics and Automation, IEEE v.15, ed.5, p. 948 - 952, october 1999.

CARRERA G., ANGELI A. AND. DAVISON A. J. **SLAM-Based Automatic Extrinsic Calibration of a Multi-Camera Rig** , ICRA 2011.

CSORBA, M.; **Simultaneous localization and map building**. PHD thesis, University of Oxford, 1997.

DISSANAYAKE, M. W. M. G.; NEWMAN, P.; CLARK S.; DURRANT-WHYTE H.; CSORBA, M.. **A solution to the simultaneous localization and map building (SLAM) problem**. In IEEE Transactions on Robotics and Automation, IEEE v.17, ed.3, p. 229 - 241, junho 2001.

DRUMHELLER, M. ; **Mobile Robot Localization Using Sonar**, IEEE, Transactions on Pattern Analysis and Machine Intelligence, IEEE PAMI-9, ed.2, p. 325 - 332, january 2009.

DURRANT-WHYTE H., RYE D., AND NEBOT E.; **Localization on automatic guided vehicles**. In G. Giralt and G. Hirzinger, editors, Robotics Research: The 7th International Symposium (ISRR'95), 1996.

GUIVANT, J. E., NEBOT E. M., AND BAIKER S.; **Localization and map building using laser range sensors in outdoor applications**. Journal of Robotic Systems, 2000.

GUIVANT, J. E.; **Efficient Simultaneous Localization And Mapping in Large Environments**. PHD thesis, Australian Centre for Field Robotics, 2002.

HEINEN, F. J., **Sistema de Controle Híbrido para Robôs Móveis Autônomos**. 130 f. Mestrado (Dissertação) - UNISINOS - Universidade do Vale do Rio dos Sinos, 2002

JULIER, S. J.; UHLMANN, J. K. **A counter example to the theory of simultaneous localization and map building**. In Proc ICRA, IEEE v.4, ed. 2001, p. 4238 - 4243, July 2003

KALMAN, R. E. A new approach to linear filtering and prediction problems. **Journal of Basic Engineering**, 1960.

LAGES, W. F., **Controle e Estimação de Posição e Orientação de Robôs Móveis**. 180 f. Doutorado (Tese) – ITA - Instituto Tecnológico de Aeronáutica ,dezembro, 1998.

LEONARD, J. J. et al. **Direct sonar sensing for mobile robot navigation**. Kluwer Academic Publishers, 1992.

MATARIC, M. J. **A distributed model for mobile robot environment-learning and navigation**. Cambridge, 1990.

MONTERMELO, M. et al.; **FastSLAM: a factored solution to the simultaneous localization and mapping problem**. In: National Conference On Artificial Intelligence. Proceedings. Edmonton (Canada), 2002.

MORAVEC, H. P.; ELFES, A. **High resolution maps from wide angle sonar**. In: International Conference on Robotics And Automation. **Proceedings**. IEEE, 1985.

NEIRA, J., AND TARDÓS, J.D.; **“Data Association in Stochastic Mapping Using the Joint Compatibility Test”**, IEEE Transactions on Robotics and Automation, 2001.

NEWMAN, P. M.; **On the Structure and Solution of the Simultaneous Localization and Map Building Problem**. PhD thesis, ACFR, Univ of Sydney, Australia, March 1999.

NIETO, J.; **Detailed environment representation for the SLAM problem**. PHD thesis, Australian Centre for Field Robotics, 2005.

NIETO, J.; GUIVANT, J.; NEBOT, E.; THRUN, S. **Real Time Data Association for fastSLAM**. *Proceedings of IEEE, International Conference on Robotics and Automation (ICRA)*. IEEE v.17, ed. 6, p. 890 - 897, dezembro 2001

OLIVEIRA, J. R. **Um sistema integrado para navegação autônoma de robôs móveis.** 2010. 100 f. Dissertação (Mestrado) – Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos, 2010.

SASIADEK J. Z., AND HARTANA P.; **Sensor Fusion for dead-reckoning mobile robot navigation.** Proceeding of the 6th IFAC Symposium on Robot Control, SYROCO, 2000.

SASIADEK J. Z., AND HARTANA P.; **Odometry and sensor data fusion for mobile robot navigation.** Proceeding of the 6th IFAC Symposium on Robot Control, SYROCO, 2000.

SMITH, R., SELF M., AND CHEESMAN P.; **Estimating uncertain spatial relationships in robotics.** In **Autonomous robot vehicles**, I. J. Coxand, G. T. Wilforn, Ed., 1990.

SMITH, R., SELF, M., AND P. CHEESEMAN. **A stochastic map for uncertain spatial relationships.** In 4th International Symposium on Robotics Research. MIT Press, 1987.

SMITH, R., AND CHEESMAN, P., “**On the representation of spatial uncertainty,**” Int. J. Robot. Res., 1987.

THRUN, S. **Robotic mapping: a survey.** CMU-CS-02-111, School of Computer Science - Carnegie Mellon University, 2002.

THRUN, S.; BURGARD, W.; FOX, D. A probabilistic approach to concurrent mapping and localization for mobile robotics. **Machine Learning**, Hingham, 1998.

THRUN, S., FOX, D., AND BURGARD, W., **Markov localization for mobile robots in dynamic environments.** Journal of Artificial Intelligence Research, 1999.

THRUN, S. et al. Autonomous exploration and mapping of abandoned mines. **IEEE Robotics and Automation Magazine**, New York, n. 4, p. 79-91, December, 2004a.

THRUN, S., FOX D., AND BURGARD W.; **A real-time algorithm for mobile robot mapping with applications to multi-robot and 3d mapping.** IEEE International Conference on Robotics and Automation, San Francisco, April 2000.